

Hoja de ruta operativa 1: datos continuos con Iris

Hoja de ruta operativa: Iris

Objetivo

El análisis multivariado suele enseñarse como una sucesión de métodos: PCA, PCoA, NMDS, t-SNE, UMAP, entre otros. Sin embargo, muchas veces no se explicita que estos métodos forman parte de una estructura de decisiones que se va construyendo a medida que avanza el análisis.

Esta hoja de ruta busca ordenar los principales métodos de reducción de dimensionalidad y ordenamiento usando un dataset simple de variables continuas: `iris`.

La idea no es solo correr métodos, sino entender qué entrada usa cada uno, qué transformación necesita, qué estructura intenta conservar y cómo se interpreta su salida.

Analizaremos el dataset mediante una estructura de capas. Cada capa representa una pregunta distinta dentro del flujo de análisis: primero reconocemos los datos, luego decidimos si necesitamos transformarlos, después evaluamos distancias, elegimos métodos de ordenamiento, interpretamos los gráficos, validamos lo observado y finalmente tomamos una decisión analítica.

No todas las capas son obligatorias en todos los análisis. Algunas pueden estar presentes de manera explícita, como cuando calculamos una matriz de distancias antes de un PCoA o un NMDS. Otras pueden estar presentes de manera implícita, como en PCA, donde no elegimos manualmente una distancia, pero sí trabajamos dentro de una geometría euclidiana.

La estructura de capas será la siguiente:

Capa	Pregunta guía	Resultado esperado
Capa 1	¿Qué estructura inicial muestra el dataset?	Reconocer la estructura física del dataset: qué representan las filas y columnas, qué tipo de variables tenemos, si hay una variable de grupo disponible y qué relaciones iniciales aparecen entre las variables.
Capa 2	¿Necesito transformar, centrar, escalar o limpiar los datos antes de aplicar métodos multivariados?	Obtener una matriz de datos adecuada para el análisis
Capa 3	¿Cómo voy a medir el parecido o la diferencia entre las observaciones?	Definir una distancia, disimilitud o semejanza si corresponde

Capa 4	¿Qué método uso para ordenar o reducir dimensión?	Aplicar PCA, PCoA, NMDS, t-SNE o UMAP
Capa 5	¿Qué tan confiable es la representación?	Validar con varianza explicada, stress, correlación de distancias o estabilidad

CAPA 1: Estructura inicial de los datos

Pregunta guía

¿Qué estructura física tiene el dataset?

1.1 Carga del dataset y exploracion inicial

```
data(iris)
```

```
dim(iris)
```

```
[1] 150    5
```

```
str(iris)
```

```
'data.frame':  150 obs. of  5 variables:
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species      : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
 ...
```

```
summary(iris)
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300
Median :5.800	Median :3.000	Median :4.350	Median :1.300
Mean :5.843	Mean :3.057	Mean :3.758	Mean :1.199
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500

```

Species
setosa      :50
versicolor:50
virginica   :50
```

```
head(iris)
```

```
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5         1.4         0.2  setosa
2          4.9         3.0         1.4         0.2  setosa
3          4.7         3.2         1.3         0.2  setosa
4          4.6         3.1         1.5         0.2  setosa
5          5.0         3.6         1.4         0.2  setosa
6          5.4         3.9         1.7         0.4  setosa
```

```
# Revision de valores faltantes
colSums(is.na(iris))
```

```
Sepal.Length  Sepal.Width Petal.Length  Petal.Width      Species
           0           0           0           0           0
```

El dataset `iris` tiene 150 observaciones y 5 variables. Cada fila representa una flor. Las primeras cuatro columnas son variables numéricas continuas relacionadas con medidas de sépalos y pétalos. La quinta variable, `Species`, es categórica e identifica la especie.

En esta hoja de ruta, las cuatro variables numéricas serán las variables activas del análisis. La variable `Species` no se usará para construir los métodos de ordenamiento, sino como referencia externa para colorear los gráficos e interpretar si la estructura encontrada coincide con grupos conocidos.

1.2 Separación entre variables activas y variables de grupo

```
X <- iris[, 1:4]
grupo <- iris$Species

str(X)
```

```
'data.frame':  150 obs. of  4 variables:
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
```

```
table(grupo)
```

```
grupo
  setosa versicolor  virginica
      50         50         50
```

Separamos las variables numéricas en el objeto `x`, porque serán la matriz principal de análisis. La variable `grupo` conserva la especie de cada observación y será usada solo para interpretación visual.

Esta separación es importante porque evita confundir un análisis no supervisado con uno supervisado. PCA, PCoA, NMDS + SNE y t-SNE no usarán la especie para construir la

supervisado. PCA, PCoA, NMDS, t-SNE y UMAP no usarán la especie para construir la ordenación; la especie se usará después para colorear los puntos.

1.3 Exploración inicial univariada: histogramas


```
par(mfrow = c(2, 2))

hist(X$Sepal.Length,
     main = "Sepal.Length",
     xlab = "Largo del sépal")

hist(X$Sepal.Width,
     main = "Sepal.Width",
     xlab = "Ancho del sépal")

hist(X$Petal.Length,
     main = "Petal.Length",
     xlab = "Largo del pétalo")

hist(X$Petal.Width,
     main = "Petal.Width",
     xlab = "Ancho del pétalo")
```



```
par(mfrow = c(1, 1))
```

Los histogramas permiten observar la distribución individual de cada variable. En [iris](#), las

variables asociadas al pétalo suelen mostrar una separación más marcada entre grupos, mientras que las variables del sépalo presentan mayor solapamiento.

Esta observación todavía no constituye un método multivariado, pero anticipa que las variables de pétalo podrían tener mayor capacidad para separar especies.

1.4 Exploración visual por grupo: boxplots


```
par(mfrow = c(2, 2))



boxplot(Sepal.Length ~ Species,
        data = iris,
        main = "Sepal.Length por especie",
        xlab = "Especie",
        ylab = "Sepal.Length")

boxplot(Sepal.Width ~ Species,
        data = iris,
        main = "Sepal.Width por especie",
        xlab = "Especie",
        ylab = "Sepal.Width")

boxplot(Petal.Length ~ Species,
        data = iris,
        main = "Petal.Length por especie",
        xlab = "Especie",
        ylab = "Petal.Length")

boxplot(Petal.Width ~ Species,
        data = iris,
        main = "Petal.Width por especie",
        xlab = "Especie",
        ylab = "Petal.Width")
```






```
par(mfrow = c(1, 1))
```

Los boxplots permiten observar cómo se comporta cada variable según la especie. En este dataset, las variables relacionadas con los pétalos muestran diferencias más claras entre especies, especialmente para separar **setosa** de las otras dos. Las variables de sépalo muestran más solapamiento, por lo que parecen menos discriminantes de manera individual.

Esta exploración sugiere que la estructura de grupos puede estar más fuertemente asociada a las variables de pétalo.

1.5 Relación y correlación entre variables

```
pairs(X,
      col = as.numeric(grupo), pch = 19,
      main = "Relaciones entre variables en iris")
```



```
cor(X)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Sepal.Length	1.0000000	-0.1175698	0.8717538	0.8179411
Sepal.Width	-0.1175698	1.0000000	-0.4284401	-0.3661259
Petal.Length	0.8717538	-0.4284401	1.0000000	0.9628654
Petal.Width	0.8179411	-0.3661259	0.9628654	1.0000000

El gráfico de pares permite observar relaciones bivariadas entre todas las variables numéricas. En varios cruces se observa una separación clara de **setosa**, mientras que **versicolor** y **virginica** aparecen más próximas y con cierto solapamiento.

También se observan relaciones lineales fuertes entre algunas variables, especialmente entre **Petal.Length** y **Petal.Width**. Esto anticipa que un método como PCA puede ser útil, porque PCA resume bien información cuando existen variables correlacionadas.

La matriz de correlación resume numéricamente lo que ya se observa en el gráfico de pares. Las variables de pétalo presentan una correlación alta entre sí. También hay asociación entre variables de sépalo y pétalo, aunque no todas las relaciones tienen la misma intensidad.

Este punto es importante porque PCA trabaja muy bien cuando varias variables comparten información. Si las variables estuvieran completamente desconectadas entre sí, PCA tendría menos capacidad para resumir la estructura en pocos componentes.

1.6 Conclusiones de la Capa 1

En esta primera capa reconocimos que **iris** es un dataset de variables continuas, con una variable categórica externa que permite colorear e interpretar los resultados. La exploración inicial mostró que las variables de pétalo separan mejor las especies que las variables de sépalo, y que existen correlaciones importantes entre algunas variables.

Esto permite anticipar que los métodos de reducción dimensional podrían encontrar una estructura clara, especialmente una separación fuerte de **setosa** y una separación más parcial entre **versicolor** y **virginica**.

Hasta este punto no aplicamos todavía ningún método multivariado de ordenamiento. Solo construimos una lectura inicial del terreno.

CAPA 2: Transformación, escala y limpieza

Pregunta inicial de la capa

¿Necesito limpiar, transformar, centrar o escalar los datos antes de aplicar métodos multivariados?

En esta segunda capa todavía no aplicamos métodos de ordenamiento. El objetivo es revisar si la matriz de datos de la Capa 1 necesita algún tratamiento previo.

En análisis multivariado, esta etapa es importante porque muchos métodos son sensibles a la escala de las variables. Si una variable tiene una dispersión mucho mayor que otra, puede

dominar el análisis aunque no sea necesariamente más importante desde el punto de vista conceptual.

En el caso de **iris**, las cuatro variables son continuas y están medidas en la misma unidad general, pero no tienen exactamente la misma variabilidad. Por eso vamos a comparar los datos originales con una versión estandarizada.

2.1 Revisión de medias y desvíos estandar

```
resumen_escalado <- data.frame(  
  media = apply(X, 2, mean),  
  desvio = apply(X, 2, sd),  
  rango = apply(X, 2, max) - apply(X, 2, min)  
)  
  
round(resumen_escalado, 2)
```

	media	desvio	rango
Sepal.Length	5.84	0.83	3.6
Sepal.Width	3.06	0.44	2.4
Petal.Length	3.76	1.77	5.9
Petal.Width	1.20	0.76	2.4

Esta tabla permite observar la escala inicial de las variables. Aunque todas las variables están expresadas en medidas comparables, no tienen la misma media ni el mismo desvío estándar.

Esto es importante porque algunos métodos, como PCA o las distancias euclidianas, pueden verse influidos por la magnitud y la dispersión de las variables. Una variable con mayor varianza puede tener más peso en el resultado final, no porque sea conceptualmente más importante, sino porque numéricamente varía más.

2.2 Centrado y escalado

```
X_escalado <- scale(X, center = TRUE, scale = TRUE)  
  
apply(X_escalado, 2, mean)
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
-4.484318e-16	2.034094e-16	-2.895326e-17	-3.663049e-17

```
apply(X_escalado, 2, sd)
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
1	1	1	1

Centrar significa restar a cada variable su media. Después de centrar, cada variable queda con media igual a 0. Escalar significa dividir cada variable por su desvío estándar. Después de escalar, cada variable queda con desvío estándar igual a 1.

Cuando hacemos ambas cosas, obtenemos variables estandarizadas:

valor estandarizado = (valor original - media) / desvío estándar


Luego de la estandarización, todas las variables tienen media aproximadamente igual a 0 y desvío estándar igual a 1. Esto permite que ninguna variable domine el análisis únicamente por tener una escala o dispersión mayor. A partir de este punto, los métodos que dependan de distancias euclidianas o de varianza trabajarán sobre una matriz más equilibrada.

2.3 Comparación visual antes y después del escalado

```
par(mfrow = c(1, 2))

boxplot(X,
  main = "Datos originales",
  ylab = "Valor original",
  las = 2)

boxplot(X_escalado,
  main = "Datos estandarizados",
  ylab = "Valor estandarizado",
  las = 2)
```



```
par(mfrow = c(1, 1))
```

La comparación visual muestra que, en los datos originales, las variables tienen distintos centros y rangos. Luego del escalado, todas quedan expresadas en una escala común, con

centros y rangos. Luego del escalado, todas quedan expresadas en una escala común, con centro aproximado en 0 y dispersión comparable.

Esto no significa que las observaciones se vuelvan iguales ni que se eliminen las diferencias entre especies. Lo que cambia es la forma en que cada variable contribuye al análisis posterior.

2.4 Conclusiones de la capa 2

Para esta hoja de ruta trabajaremos principalmente con la matriz estandarizada `X_escalado`.

La decisión se justifica porque queremos comparar varios métodos bajo una base común. PCA, PCoA con distancia euclidiana, NMDS con distancia euclidiana, t-SNE y UMAP pueden verse afectados por la escala de las variables.

Aunque las variables de `iris` están medidas en unidades similares, estandarizarlas permite que cada una tenga el mismo peso inicial en el análisis. De esta forma, las diferencias entre métodos se deberán más a la lógica de cada método que a diferencias de escala entre variables.

CAPA 3: Distancia, disimilitud o semejanza

Pregunta inicial de la capa

¿Cómo medimos similitud o diferencia entre observaciones?

En esta capa todavía no aplicamos métodos de ordenamiento ni reducción dimensional. El objetivo es detenernos en una decisión previa: cómo medir la relación entre observaciones.

En análisis multivariado, cada observación puede pensarse como un punto ubicado en un espacio definido por varias variables. En iris, cada flor queda descripta por cuatro medidas. Por lo tanto, comparar dos flores implica comparar simultáneamente esas cuatro variables.

La distancia o disimilitud elegida define qué entendemos por “parecido” o “diferente”. Distintas medidas pueden resaltar distintos aspectos de la estructura de los datos.

3.1 Medidas según tipo de dato

No todas las distancias sirven para todos los datos. Antes de calcular una distancia, debemos mirar la naturaleza de las variables.

Tipo de dato	Medida habitual	Uso principal	Cuidado
Variables continuas	Euclidiana	Comparar observaciones en un espacio numérico	Sensible a escala y valores extremos
Variables continuas	Manhattan	Sumar diferencias	Cambia la geometría

		absolutas entre variables	respecto de Euclidiana
Variables continuas correlacionadas	Mahalanobis	Medir alejamiento considerando covarianza	Requiere matriz de covarianza estable
Frecuencias / perfiles	Chi-cuadrado	Comparar perfiles o tablas de contingencia	No es una distancia genérica para cualquier dato
Abundancias	Bray-Curtis	Comparar composición y abundancia	No considera ausencias compartidas
Presencia / ausencia	Jaccard	Comparar presencias compartidas	Ignora coincidencias de ausencia
Presencia / ausencia	Sørensen / Dice	Comparar presencias dando más peso a coincidencias	Similar a Jaccard, pero con otra ponderación
Datos mixtos	Gower	Combinar variables numéricas, categóricas, ordinales y binarias	Depende de buena codificación previa

Para **iris**, las variables activas son continuas. Por lo tanto, las medidas más apropiadas para explorar esta capa son Euclidiana, Manhattan y Mahalanobis.

No utilizaremos Bray-Curtis, Jaccard, Sørensen ni Gower como medidas principales en esta hoja, porque responden mejor a otros tipos de datos. Esas medidas serán más relevantes en la hoja de ruta con **dune**, donde trabajaremos con abundancias y presencia/ausencia.

3.2 Distancia euclidiana

La distancia euclidiana mide la separación directa entre dos observaciones considerando todas las variables numéricas.

```
dist_euc <- dist(X_escalado, method = "euclidean")
dist_euc_mat <- as.matrix(dist_euc)

dist_euc_mat[1:6, 1:6]
```

	1	2	3	4	5	6
1	0.0000000	1.1722914	0.8427840	1.0999999	0.2592702	1.0349769
2	1.1722914	0.0000000	0.5216255	0.4325508	1.3818560	2.1739229
3	0.8427840	0.5216255	0.0000000	0.2829432	0.9882608	1.8477070
4	1.0999999	0.4325508	0.2829432	0.0000000	1.2459861	2.0937597
5	0.2592702	1.3818560	0.9882608	1.2459861	0.0000000	0.8971079
6	1.0349769	2.1739229	1.8477070	2.0937597	0.8971079	0.0000000

Mostramos solo una pequeña parte de la matriz, porque imprimir las 150 por 150 distancias completas no sería útil en el documento.

La diagonal vale cero porque una flor tiene distancia cero consigo misma. La matriz es simétrica porque la distancia de la flor A a la flor B es igual a la distancia de la flor B a la flor A.

3.3 Distancia Manhattan

La distancia Manhattan también compara observaciones numéricas, pero lo hace sumando diferencias absolutas entre variables.

```
dist_man <- dist(X_escalado, method = "manhattan")
dist_man_mat <- as.matrix(dist_man)

dist_man_mat[1:6, 1:6]
```

	1	2	3	4	5	6
1	0.0000000	1.3886674	1.2279853	1.5781768	0.3501915	1.712331
2	1.3886674	0.0000000	0.7570306	0.6483657	1.4973323	3.100998
3	1.2279853	0.7570306	0.0000000	0.4634868	1.3366502	2.940316
4	1.5781768	0.6483657	0.4634868	0.0000000	1.6868417	3.177212
5	0.3501915	1.4973323	1.3366502	1.6868417	0.0000000	1.603666
6	1.7123309	3.1009983	2.9403162	3.1772124	1.6036660	0.000000


En este caso también obtenemos una matriz de distancias entre flores. La diferencia está en cómo se calcula cada celda.

3.4 Comparación entre Euclidiana y Manhattan

Como ambas distancias son apropiadas para variables continuas, podemos compararlas para ver si ordenan las diferencias entre flores de manera similar.

```
plot(as.vector(dist_euc), as.vector(dist_man),
     pch = 19, xlab = "Distancia euclidiana", ylab = "Distancia Manhattan")
```





```
cor(as.vector(dist_euc), as.vector(dist_man), method = "spearman")
```

```
[1] 0.9893318
```

3.3 Distancia euclidiana en iris

En este contexto, la distancia euclidiana mide qué tan diferentes son dos flores considerando simultáneamente sus cuatro variables estandarizadas.

La distancia euclidiana resume en un solo número la diferencia multivariada entre dos observaciones.

```
dist_euc <- dist(X_escalado, method = "euclidean")

dist_euc_mat <- as.matrix(dist_euc)

dist_euc_mat[1:5, 1:5]
```

	1	2	3	4	5
1	0.0000000	1.1722914	0.8427840	1.0999999	0.2592702
2	1.1722914	0.0000000	0.5216255	0.4325508	1.3818560
3	0.8427840	0.5216255	0.0000000	0.2829432	0.9882608
4	1.0999999	0.4325508	0.2829432	0.0000000	1.2459861
5	0.2592702	1.3818560	0.9882608	1.2459861	0.0000000

Cada celda de la matriz contiene la distancia entre dos flores. La diagonal vale cero porque la distancia de una flor consigo misma es cero. La matriz es simétrica porque la distancia de la flor A a la flor B es igual a la distancia de la flor B a la flor A.

Mostramos solo una pequeña parte de la matriz porque la matriz completa tiene 150 filas y 150 columnas.


3.4 Visualización de la matriz de distancias

Una forma de explorar la matriz de distancias es mediante un mapa de calor. Este gráfico solo permite ver patrones generales de similitud o diferencia entre observaciones.

```
heatmap(dist_euc_mat,
        symm = TRUE,
        main = "Distancias euclidianas entre flores – Iris",
        Rowv = NA,
```

```
Colv = NA)
```

Distancias euclidianas entre flores — Iris



Como el dataset **iris** está ordenado por especie, el mapa de calor puede mostrar bloques de menor o mayor distancia asociados a ese orden. Esto puede ayudar a detectar que algunas flores son más parecidas dentro de ciertos grupos.

Sin embargo, el patrón visual depende del orden de las filas y columnas. Por eso este gráfico debe interpretarse como una exploración inicial de la matriz de distancias, no como una prueba formal.

3.5 Comparación entre distancia euclidiana y Manhattan


Para datos continuos también podríamos usar distancia Manhattan. La diferencia es que Manhattan suma diferencias absolutas entre variables, mientras que Euclidiana resume las diferencias usando la lógica geométrica de la distancia directa.

No esperamos que ambas distancias sean idénticas, pero en un dataset simple y continuo como **iris** deberían estar bastante relacionadas.

```
dist_man <- dist(X_escalado, method = "manhattan")

plot(as.vector(dist_euc),
     as.vector(dist_man),
     pch = 20,
     xlab = "Distancia euclidiana",
     ylab = "Distancia Manhattan",
     main = "Comparación entre distancias")
```

Comparación entre distancias



```
cor(as.vector(dist_euc),  
    as.vector(dist_man),  
    method = "spearman")
```

```
[1] 0.9893318
```

La comparación permite evaluar si dos medidas de distancia ordenan de manera parecida las diferencias entre flores. Una correlación alta indica que los pares de flores que son cercanos según Euclidiana también tienden a ser cercanos según Manhattan.

Esto no significa que ambas distancias sean equivalentes, sino que para este dataset producen una lectura similar de la estructura general.

3.5 Distancia de Mahalanobis al centroide

La distancia de Mahalanobis permite medir qué tan lejos está cada observación respecto de un centro multivariado, considerando la estructura de covarianza entre las variables.

A diferencia de la distancia euclidiana y Manhattan calculadas entre pares de flores, aquí usaremos Mahalanobis para medir el alejamiento de cada flor respecto del centroide general del conjunto de datos.

Esto sirve para explorar dispersión multivariada y posibles observaciones atípicas.

```
centro = colMeans(X_escalada)
```

```

centro <- colMeans(X_escalado)
S <- cov(X_escalado)

dist_maha <- mahalanobis(X_escalado, center = centro, cov = S)

iris_maha <- data.frame(
  obsrevacion = 1:nrow(iris),
  Species = iris$Species,
  dist_maha = dist_maha
)

# Flores mas alejadas

iris_maha[order(iris_maha$dist_maha, decreasing = TRUE), ][1:10, ]

```

	obsrevacion	Species	dist_maha
132	132	virginica	13.101093
135	135	virginica	12.880331
118	118	virginica	12.813073
142	142	virginica	12.441384
42	42	setosa	11.424029
115	115	virginica	11.410573
107	107	virginica	10.137804
16	16	setosa	9.712790
136	136	virginica	9.656936
146	146	virginica	9.063950


```


# Visualizar

plot(dist_maha,
     pch = 19,
     col = as.numeric(iris$Species),
     xlab = "Observación",
     ylab = "Distancia de Mahalanobis al centroide",
     main = "Distancia de Mahalanobis – Iris")
legend("topright",
     legend = levels(iris$Species),
     col = 1:3,
     pch = 19)

```

Distancia de Mahalanobis — Iris





Las observaciones con mayor distancia de Mahalanobis son las más alejadas del centro multivariado general. Esta distancia no mide solamente si una flor tiene valores grandes o pequeños, sino si su combinación de valores resulta poco común considerando la relación entre las variables.

Por eso Mahalanobis es útil para detectar observaciones multivariadamente alejadas.

3.6 Comparación conceptual entre las medidas usadas

Medida	Qué compara en esta hoja	Resultado que produce	Uso en esta capa
Euclidiana	Flor contra flor	Matriz de distancias entre pares	Medida principal para variables continuas estandarizadas
Manhattan	Flor contra flor	Matriz de distancias entre pares	Comparación alternativa para variables continuas
Mahalanobis	Flor contra centroide	Distancia de cada flor al centro multivariado	Medida de dispersión y posible atipicidad

Euclidiana y Manhattan responden a la pregunta: ¿qué tan diferentes son dos flores entre sí?

Mahalanobis, en este uso, responde a otra pregunta: ¿qué tan alejada está una flor del centro multivariado del conjunto de datos?

Por eso no deben interpretarse exactamente de la misma manera, aunque todas pertenezcan a la capa de distancias.

3.7 Decisión operativa de la Capa 3

Para esta hoja de ruta, la distancia euclidiana sobre **X-escalado** será la medida principal de diferencia entre pares de flores.

La distancia Manhattan se calculó como comparación, para observar si una medida alternativa

para datos continuos produce una estructura similar.

La distancia de Mahalanobis se utilizó como medida de alejamiento respecto del centroide general, no como matriz principal entre pares de observaciones. Su función en esta hoja es explorar dispersión multivariada y posibles observaciones alejadas.

Esta capa nos permite separar tres ideas:

- medir diferencia entre pares de observaciones;
- comparar distintas definiciones de distancia;
- medir alejamiento respecto de un centro multivariado.

3.8 Cierre de la Capa 3

En esta capa trabajamos exclusivamente sobre el problema de medir parecido, diferencia o alejamiento entre observaciones.

Primero revisamos qué medidas suelen utilizarse según el tipo de dato. Luego aplicamos al dataset **iris** las medidas apropiadas para variables continuas: Euclidiana, Manhattan y Mahalanobis.

La distancia euclidiana quedó como medida principal entre pares de flores. Manhattan permitió comprobar si una geometría alternativa producía una lectura similar. Mahalanobis permitió analizar la distancia de cada observación al centro multivariado, considerando la covarianza entre variables.

Recién en la próxima capa usaremos estas ideas para entrar en métodos de ordenamiento y reducción dimensional.

CAPA 4: Ordenamiento, reducción dimensional e interpretación visual

Pregunta inicial de la capa

¿Cómo puedo representar la estructura multivariada de los datos en menos dimensiones?

Hasta ahora trabajamos sobre la estructura de los datos, su escala y las formas posibles de medir distancia o diferencia entre observaciones.

Ahora buscamos representar esa estructura en un espacio más simple para poder visualizarla e interpretarla.

Reducir dimensiones significa construir una representación más compacta de la estructura de los datos. Cada método lo hace de una manera distinta y, por lo tanto, conserva aspectos diferentes de la información original.

¿Qué aporta cada método?

Antes de aplicar los métodos conviene distinguir qué ventaja ofrece cada uno. Todos pueden producir un gráfico en dos dimensiones, pero no todos responden la misma pregunta

producen un gráfico en dos dimensiones, pero no todos responden la misma pregunta.

Método	Pregunta que responde mejor	Ventaja principal	Cuándo usarlo	Cuándo tener cuidado
PCA	¿Qué combinación de variables explica la mayor variación?	Es interpretable: permite leer observaciones y variables	Variables continuas, relaciones aproximadamente lineales, interés en reducción e interpretación	Si hay relaciones no lineales fuertes, outliers importantes o variables en escalas muy distintas sin escalar
PCoA	¿Cómo representar objetos a partir de una distancia elegida?	Permite usar distintas distancias según el tipo de dato	Cuando la distancia es una decisión central: Euclidiana, Bray-Curtis, Jaccard, Gower, etc.	Si la distancia no es euclidiana pueden aparecer autovalores negativos; requiere justificar la distancia
NMDS	¿Puedo conservar el orden relativo de las disimilitudes?	Muy flexible para datos ecológicos, abundancias y distancias no euclidianas	Cuando importan más los rangos de similitud que las distancias exactas	Es iterativo, puede cambiar entre corridas y necesita revisar el stress
t-SNE	¿Existen vecindades locales o grupos compactos?	Muy bueno para visualizar estructura local	Datos de alta dimensión, exploración visual de clusters	No interpretar distancias entre grupos ni ejes; sensible a parámetros
UMAP	¿Hay vecindades locales y cierta conectividad global?	Suele equilibrar mejor estructura local y global que t-SNE	Alta dimensión, exploración de estructura compleja, visualización de agrupamientos	No interpretar ejes como variables ni distancias como exactas; sensible a parámetros

Regla práctica de elección

PCA es la primera opción cuando tengo **variables numéricas continuas** y quiero una **representación interpretable**. Es especialmente útil si hay correlación entre variables, porque puede resumir información redundante en pocos componentes.

PCoA conviene cuando quiero partir de **una distancia explícita**. Su ventaja es que permite adaptar el análisis al tipo de dato: distancia euclidiana para continuas, **Bray-Curtis para abundancias**, **Jaccard para presencia/ausencia** o **Gower para datos mixtos**.

NMDS conviene cuando la distancia exacta es difícil de conservar, pero sí me interesa mantener el **orden relativo de las similitudes**. Por eso es muy usado con datos ecológicos y matrices de disimilitud no euclidianas.

t-SNE y UMAP convienen más como herramientas exploratorias de visualización, especialmente cuando hay muchas variables o estructuras no lineales. Sirven para ver **vecindarios o agrupamientos**, pero no para interpretar ejes ni distancias globales como si fueran mapas métricos.

Una forma simple de ordenar la decisión es:

- Si quiero interpretar variables, empiezo por PCA;
- Si quiero elegir explícitamente una distancia, uso PCoA o NMDS;
- Si quiero conservar distancias lo mejor posible, uso PCoA;
- Si quiero conservar el orden relativo de las disimilitudes, uso NMDS;

4.1.1 PCA: reducción lineal basada en varianza

Como ya habíamos estandarizado los datos en la Capa 2, aplicamos PCA directamente sobre `X_escalado`.

```
pca_iris <- prcomp(X_escalado, center = FALSE, scale. = FALSE)

summary(pca_iris)
```

Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.7084	0.9560	0.38309	0.14393
Proportion of Variance	0.7296	0.2285	0.03669	0.00518
Cumulative Proportion	0.7296	0.9581	0.99482	1.00000

```
round(pca_iris$rotation, 3)
```


	PC1	PC2	PC3	PC4
Sepal.Length	0.521	-0.377	0.720	0.261
Sepal.Width	-0.269	-0.923	-0.244	-0.124
Petal.Length	0.580	-0.024	-0.142	-0.801
Petal.Width	0.565	-0.067	-0.634	0.524

4.1.2 Scores: ubicación de las flores en el nuevo espacio

```
scores_pca <- pca_iris$x

plot(scores_pca[, 1], scores_pca[, 2], col = as.numeric(grupo),
     pch = 19, xlab = "PC1", ylab = "PC2", main = "PCA de Iris")

legend("topright", legend = levels(grupo), col = 1:nlevels(grupo), pch = 19)
```



En el gráfico de PCA, cada punto representa una flor proyectada sobre los dos primeros componentes principales. La especie no fue usada para construir el PCA, solo se usa para colorear los puntos.

La lectura principal es observar si la estructura encontrada por PCA coincide con los grupos conocidos. En *iris*, suele observarse una separación clara de *setosa* y una separación parcial entre *versicolor* y *virginica*.

Visualmente, PCA muestra una estructura relativamente continua. Esto es importante: el método no fuerza grupos, sino que proyecta las observaciones sobre las direcciones de mayor variación.

La separación de *setosa* aparece como una estructura fuerte del dataset. En cambio, *versicolor* y *virginica* quedan más próximas, lo que sugiere que su diferenciación existe, pero es menos marcada.

Como PCA permite interpretar los ejes mediante los loadings, podemos conectar la posición de

las flores con las variables originales. En este caso, la separación principal está asociada sobre todo a las variables de pétalo, coherente con lo observado en la exploración inicial.

4.1.3 Loadings: relación entre variables originales y componentes

```
pca_iris$rotation
```

	PC1	PC2	PC3	PC4
Sepal.Length	0.5210659	-0.37741762	0.7195664	0.2612863
Sepal.Width	-0.2693474	-0.92329566	-0.2443818	-0.1235096
Petal.Length	0.5804131	-0.02449161	-0.1421264	-0.8014492
Petal.Width	0.5648565	-0.06694199	-0.6342727	0.5235971


Los loadings indican cómo participa cada variable original en la construcción de los componentes principales.

Valores grandes en valor absoluto indican que una variable tiene fuerte peso en ese componente. El signo indica dirección dentro del eje, pero debe interpretarse de manera relativa: si varias variables tienen el mismo signo, se mueven juntas en ese componente; si tienen signos opuestos, se ubican en direcciones contrarias.

En PCA no interpretamos solo la posición de los puntos. También interpretamos qué variables explican la formación de los ejes.

4.1.4 Biplot: observaciones y variables en el mismo gráfico

```
biplot(pca_iris, main = "Biplot PCA — Iris")
```



El biplot combina en una misma figura las observaciones y las variables originales.

- Los puntos representan flores proyectadas sobre los dos primeros componentes principales.
- Las flechas representan las variables originales y muestran hacia qué dirección aumentan sus valores dentro del espacio del PCA.

En este gráfico los ejes se interpretan como componentes principales. Las flechas ayudan a entender qué variables contribuyen a la separación de las observaciones.

En **iris**, las variables asociadas al pétalo suelen tener un papel central en la separación entre especies. Si **Petal.Length** y **Petal.Width** apuntan en direcciones similares, eso indica que ambas variables están asociadas y contribuyen de manera parecida a la estructura del PCA.

El biplot debe leerse como una síntesis visual. Para una interpretación más ordenada conviene analizar primero los scores de las observaciones y luego los loadings de las variables.

4.2 PCoA: ordenamiento basado en distancias

PCoA parte de una matriz de distancias. En esta hoja usamos la distancia euclidiana calculada sobre **X_escalado**.


```
pcoa_iris <- cmdscale(dist_euc, k = 4, eig = TRUE)


scores_pcoa <- pcoa_iris$points

plot(scores_pcoa[, 1], scores_pcoa[, 2], col = as.numeric(grupo),
     pch = 19, xlab = "PCoA1", ylab = "PCoA2", main = "PCoA euclidiana — Iris")

legend("topright", legend = levels(grupo), col = 1:nlevels(grupo), pch = 19)
```

PCoA euclidiana — Iris





En PCoA los ejes no son variables originales, pero sí son coordenadas principales derivadas de una matriz de distancias.

Con distancia euclidiana, PCoA suele producir una representación muy parecida a PCA. Esto ocurre porque ambos métodos están trabajando dentro de una geometría compatible.

La diferencia conceptual es importante: PCA parte de variables y varianza; PCoA parte de una matriz de distancias.

Visualmente, PCoA con distancia euclidiana produce una organización muy similar a PCA. Esto refuerza la idea de que, para datos continuos estandarizados y con distancia euclidiana, ambos métodos pueden recuperar una estructura parecida.

La utilidad de PCoA no se aprecia completamente en `iris`, porque estamos usando una distancia euclidiana sobre variables continuas. Su ventaja se vuelve más clara cuando necesitamos usar otras distancias, por ejemplo Bray-Curtis para abundancias, Jaccard para presencia/ausencia o Gower para datos mixtos.

PCoA permite ver cómo cambia el análisis cuando el punto de partida ya no son directamente las variables, sino una matriz de distancias entre observaciones.

4.3 NMDS: ordenamiento no métrico

NMDS también trabaja desde distancias o disimilitudes, pero no intenta conservar las distancias exactas. **Intenta conservar el orden relativo de las distancias.**

Es decir, si una flor A es más parecida a B que a C en el espacio original, NMDS intenta mantener esa relación de orden en el espacio reducido.

```
library(vegan)
```

Cargando paquete requerido: permute

```
set.seed(42)

nmds_iris <- metaMDS(X_escalado, distance = "euclidean", k = 2, trymax = 100,
                    autotransform = FALSE, trace = FALSE)
```

'comm' has negative data: 'autotransform', 'noshare' and 'wascores' set to FALSE

```
nmds_iris
```


Call:

```
metaMDS(comm = X_escalado, distance = "euclidean", k = 2, trymax = 100,  
autotransform = FALSE, trace = FALSE)
```

global Multidimensional Scaling using monoMDS

Data: X_escalado

Distance: euclidean

Dimensions: 2

Stress: 0.04212487

Stress type 1, weak ties

Best solution was repeated 14 times in 20 tries


The best solution was from try 1 (random start)

Scaling: centring, PC rotation

Species: scores missing

```
scores_nmds <- scores(nmds_iris)  
  
plot(scores_nmds[, 1], scores_nmds[, 2], col = as.numeric(grupo),  
      pch = 19, xlab = "", ylab = "", xaxt="n", yaxt="n", main = "NMDS euclidiana")  
  
legend("topright", legend = levels(grupo), col = 1:nlevels(grupo), pch = 19)
```

NMDS euclidiana



En NMDS los ejes no se interpretan como variables ni como componentes principales. Lo importante es la posición relativa de los puntos.

El valor de **stress** indica qué tan difícil fue representar en dos dimensiones el orden de las distancias originales.

Visualmente, NMDS debe leerse con más cautela que PCA o PCoA. La orientación del gráfico, la escala y la posición exacta de los ejes no tienen interpretación directa.

Lo importante es observar qué puntos quedan cerca y qué puntos quedan lejos en términos relativos. Si **setosa** aparece separada, eso indica que sus observaciones mantienen una diferencia clara respecto de las otras especies en el orden de las disimilitudes.

NMDS es especialmente útil cuando no necesitamos conservar distancias exactas, sino la estructura de semejanzas y diferencias relativas. Por eso será más importante en la hoja de ruta con **dune**, donde trabajaremos con abundancias y disimilitudes ecológicas.

4.4 t-SNE: visualización de vecindades locales

t-SNE es un método no lineal pensado principalmente para visualizar vecindades locales. No intenta conservar distancias globales ni producir ejes interpretables.

En datasets simples como **iris**, puede separar grupos visualmente, pero no necesariamente representa mejor la geometría global que PCA.

```
library(Rtsne)

set.seed(42)


tsne_iris <- Rtsne(X_escalado, dims = 2, perplexity = 20, verbose = FALSE,
                  check_duplicates = FALSE)

scores_tsne <- tsne_iris$Y

plot(scores_tsne[, 1], scores_tsne[, 2], col = as.numeric(grupo), pch = 19,
     xlab = "", ylab = "", xaxt="n", yaxt="n", main = "t-SNE — Iris")

legend("topright",
      legend = levels(grupo),
      col = 1:nlevels(grupo),
      pch = 19)
```

t-SNE — Iris





La interpretación de t-SNE debe centrarse en vecindades locales: puntos cercanos en el gráfico tienden a representar observaciones similares.

No conviene interpretar las distancias entre grupos como distancias reales del espacio original. Tampoco se interpretan los ejes t-SNE1 y t-SNE2 como variables.

Visualmente, t-SNE puede producir grupos más compactos o separados que PCA. Esto puede ser útil para detectar vecindades locales, pero también puede generar una impresión excesiva de separación.

Por eso, si dos grupos aparecen muy separados en t-SNE, no debemos concluir automáticamente que esa distancia entre grupos representa una distancia real del espacio original. La lectura correcta es más limitada: puntos cercanos dentro del gráfico tienden a ser vecinos o similares en el espacio original.

En [iris](#), t-SNE puede ayudar a visualizar agrupamientos, pero no reemplaza a PCA cuando el objetivo es interpretar variables o explicar ejes.

4.5 UMAP: vecindades y conectividad global

UMAP también es un método no lineal de visualización. Construye una representación basada en relaciones de vecindad entre observaciones.

En comparación con t-SNE, suele intentar mantener algo más de estructura global, aunque sus ejes tampoco son interpretables como variables.

```
library(umap)

set.seed(42)

umap_iris <- umap(X_escalado)


scores_umap <- umap_iris$layout

plot(scores_umap[, 1], scores_umap[, 2], col = as.numeric(grupo), pch = 19,
      xlab = "", ylab = "", xaxt="n", yaxt="n", main = "UMAP - Iris")

legend("topright",
      legend = levels(grupo),
```

```
col = 1:nlevels(grupo),  
pch = 19)
```

UMAP — Iris



UMAP puede mostrar una separación visual clara entre grupos, pero eso no significa que las distancias del gráfico sean distancias reales del espacio original.

La lectura más prudente es observar vecindades, agrupamientos y continuidad entre grupos.

Visualmente, UMAP suele ofrecer una representación clara de vecindades y posibles agrupamientos. En comparación con t-SNE, puede conservar algo mejor ciertas relaciones globales, pero sigue siendo una visualización no lineal.

En `iris`, UMAP puede mostrar una separación clara entre especies, especialmente de `setosa`. Sin embargo, al igual que en t-SNE, no debemos interpretar los valores de los ejes ni medir distancias entre clusters como si fueran distancias reales.

4.6 Comparación visual inicial

Ahora comparamos visualmente las cinco representaciones obtenidas. Esta comparación todavía es exploratoria: observamos cómo cada método organiza las mismas flores en dos dimensiones.

```
par(mfrow = c(2, 3))  
  
plot(scores_pca[, 1], scores_pca[, 2],  
     col = as.numeric(grupo), pch = 19,  
     xlab = "PC1", ylab = "PC2",
```

```

main = "PCA")

plot(scores_pcoa[, 1], scores_pcoa[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "PCoA1", ylab = "PCoA2",
     main = "PCoA")


plot(scores_nmds[, 1], scores_nmds[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "", ylab = "", xaxt="n", yaxt="n",
     main = "NMDS")

plot(scores_tsne[, 1], scores_tsne[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "", ylab = "", xaxt="n", yaxt="n",
     main = "t-SNE")

plot(scores_umap[, 1], scores_umap[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "", ylab = "", xaxt="n", yaxt="n",
     main = "UMAP")

plot.new()
legend("center",
      legend = levels(grupo),
      col = 1:nlevels(grupo),
      pch = 19,
      title = "Species")

```



```
par(mfrow = c(1, 1))
```

En los métodos NMDS, t-SNE y UMAP las coordenadas no deben interpretarse como variables ni como magnitudes con significado propio. Por esta razón, en los gráficos de estos métodos se ocultan los valores numéricos de los ejes.

La comparación visual permite observar que todos los métodos detectan, en mayor o menor medida, la separación de *setosa*. Esto coincide con la exploración inicial de la Capa 1.

Las diferencias aparecen sobre todo en la forma en que cada método representa la relación entre *versicolor* y *virginica*.

- PCA y PCoA tienden a conservar una estructura más continua y global.
- t-SNE y UMAP pueden generar separaciones visuales más marcadas, pero no deben interpretarse como mapas métricos exactos.
- NMDS se ubica en una lógica intermedia: no conserva distancias exactas, sino el orden relativo de las distancias.

Desde una lectura transversal, pueden distinguirse dos niveles de estructura:

1. **Estructura fuerte:** la separación de *setosa*.
Esta separación aparece en todos o casi todos los métodos, por lo que parece ser una característica robusta del dataset.
2. **Estructura más débil o gradual:** la separación entre *versicolor* y *virginica*.
Estas especies aparecen más cercanas entre sí y su separación cambia más según el método. Esto sugiere que la diferencia existe, pero no es tan fuerte como la separación de *setosa*.

Esta comparación permite evitar una lectura ingenua de los gráficos. Un método puede mostrar grupos visualmente más separados, pero eso no significa necesariamente que CAPA 5: Validación, contraste y explicación represente mejor la geometría original de los datos.

4.7 Cierre de la Capa 4

En esta capa aplicamos distintos métodos de ordenamiento y reducción dimensional sobre el mismo dataset. El objetivo no fue elegir automáticamente un método ganador, sino observar cómo distintos métodos construyen mapas diferentes de una misma estructura multivariada.

La comparación muestra que *setosa* aparece separada de manera consistente. Esta es la estructura visual más fuerte del dataset. En cambio, *versicolor* y *virginica* muestran una relación más cercana y variable, lo que indica una separación más débil o gradual.

Cada método aporta una mirada distinta:

- **PCA** fue el método de referencia porque trabaja naturalmente con variables continuas y permite interpretar variables mediante loadings.

- **PCoA** permitió representar las observaciones a partir de una matriz de distancias.
- **NMDS** mostró una representación basada en el orden relativo de las distancias, sin interpretar directamente los ejes.
- **t-SNE** resaltó vecindades locales y posibles agrupamientos.
- **UMAP** ofreció una visualización no lineal basada en vecindades y conectividad.

Una conclusión importante de esta capa es que un gráfico más separado o visualmente más claro no necesariamente es una representación más fiel de la estructura original. La claridad visual debe contrastarse con criterios de validación.

La elección posterior del método dependerá de la pregunta analítica:

- si quiero interpretar variables, PCA es el punto de partida natural;
- si quiero trabajar desde una distancia explícita, PCoA o NMDS son más adecuados;
- si quiero conservar distancias, PCoA es más directo;
- si quiero conservar el orden relativo de las disimilitudes, NMDS es más apropiado;
- si quiero explorar vecindades locales o agrupamientos complejos, t-SNE y UMAP pueden ser útiles.

La validación formal de estas representaciones quedará para la siguiente capa, donde compararemos varianza explicada, stress, correlación entre distancias originales y reducidas, y sensibilidad a parámetros.

CAPA 5: Validación, contraste y decisión analítica

Pregunta inicial de la capa

¿Qué tan confiables son las representaciones obtenidas y qué decisión analítica podemos tomar a partir de ellas?

En la Capa 4 construimos distintas representaciones bidimensionales del mismo dataset. También realizamos una primera interpretación visual. Sin embargo, una representación visualmente clara no necesariamente es una representación fiel de la estructura original.

Por eso, en esta capa buscamos contrastar lo observado visualmente con medidas de validación. La idea no es encontrar un método ganador automático, sino entender qué tan bien cada método conserva aquello que promete conservar.

5.1 PCA: varianza explicada


En PCA podemos evaluar qué tan buena es la reducción mirando cuánta varianza explican los primeros componentes.

```
summary(pca_iris)
```

Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.7084	0.9560	0.38309	0.14393
Proportion of Variance	0.7296	0.2285	0.03669	0.00518
Cumulative Proportion	0.7296	0.9581	0.99482	1.00000

```
plot(pca_iris,
     type = "lines",
     main = "Scree plot — PCA Iris")
```



Si los dos primeros componentes explican una proporción alta de la variabilidad total, entonces el gráfico PC1 vs PC2 resume bien la estructura global de los datos.

PCA permite cuantificar cuánta información queda resumida en los primeros componentes. Esta es una ventaja importante frente a métodos como t-SNE o UMAP, donde no tenemos una medida equivalente de varianza explicada por eje.

5.2 PCoA: autovalores y representación de distancias

En PCoA también podemos mirar autovalores. Estos indican cuánta variación de la matriz de distancias queda representada en cada coordenada principal.

Como en esta hoja usamos distancia euclidiana, esperamos que PCoA tenga un comportamiento muy parecido a PCA.


```
cumsum(pcoa_iris$eig / sum(pcoa_iris$eig))[1:5]
```

```
[1] 0.7296215 0.0581221 0.0048212 1.0000000 1.0000000
```



```
[1] 0.7290245 0.9581521 0.9940215 1.0000000 1.0000000
```

```
plot(cumsum(pcoa_iris$eig / sum(pcoa_iris$eig))[1:10], type = "b", pch = 19,  
     xlab = "Eje PCoA", ylab = "Acumulado",  
     main = "Varianza Acumulada — PCoA Iris")
```



Los dos primeros ejes acumulan una proporción alta, entonces el gráfico PCoA1 vs PCoA2 resume bien la estructura de distancias entre flores.

PCoA permite evaluar cuánto de la estructura de distancias queda resumida en los primeros ejes. En este caso, al usar distancia euclidiana sobre datos estandarizados, la representación debería ser muy cercana a la de PCA.

En otros datasets, especialmente con distancias no euclidianas, esta evaluación puede ser más delicada porque pueden aparecer autovalores negativos.

5.3 NMDS: stress

En NMDS, la medida principal para evaluar la calidad de la representación es el **stress**.

El stress indica qué tan difícil fue representar en pocas dimensiones el orden relativo de las distancias originales. Cuanto más bajo es el stress, mejor logra el NMDS representar la estructura de disimilitudes en el espacio reducido.

En NMDS no preguntamos:


¿el mapa en dos dimensiones conserva razonablemente el orden de semejanza entre las

observaciones?

```
nmds_iris$stress
```

[1] 0.04212487

```
stressplot(nmds_iris)
```



Como regla práctica, podemos interpretar el stress de esta manera:

Stress	Interpretación orientativa
< 0.05	Representación excelente
0.05 - 0.10	Buena representación
0.10 - 0.20	Representación aceptable, pero con cautela
> 0.20	Representación pobre o difícil de interpretar

Estos valores no deben tomarse como reglas absolutas, pero ayudan a decidir si el gráfico NMDS es confiable como representación visual.

Si el stress es bajo o aceptable, podemos usar el gráfico NMDS como una representación razonable del orden relativo de las distancias entre flores.

Sin embargo, aunque el stress sea bueno, los ejes NMDS no se interpretan como variables. La

interpretación sigue estando centrada en la proximidad relativa entre puntos y en la estructura visual general.

A diferencia de PCA, NMDS no se valida por varianza explicada. Se valida preguntando si el orden de las distancias originales fue conservado de manera aceptable en el espacio reducido.

El `stressplot` compara las disimilitudes originales con las distancias representadas en el espacio NMDS.

La lectura esperada es que los puntos sigan una tendencia creciente: pares de flores más disímiles en el espacio original deberían aparecer más separados en el mapa NMDS.

Si los puntos se alejan mucho de esa tendencia, significa que el mapa está distorsionando demasiado la estructura original.

5.4 t-SNE: perplexity y estabilidad visual

En t-SNE, uno de los parámetros más importantes es `perplexity`. Este parámetro controla, de manera aproximada, cuántos vecinos considera el algoritmo al construir la representación.

Valores bajos de `perplexity` hacen que t-SNE preste más atención a vecindarios pequeños. Valores más altos hacen que considere vecindarios más amplios.

Como t-SNE es sensible a este parámetro, no conviene interpretar un único gráfico como si fuera una verdad definitiva. Es mejor probar varios valores y observar si la estructura visual principal se mantiene.


```
perp_vals <- c(5, 20, 40)

par(mfrow = c(1, 3))

for (p in perp_vals) {
  set.seed(42)

  tsne_tmp <- Rtsne(X_escalado,
                    dims = 2,
                    perplexity = p,
                    verbose = FALSE,
                    check_duplicates = FALSE)

  plot(tsne_tmp$Y[, 1],
       tsne_tmp$Y[, 2],
       col = as.numeric(grupo),
       pch = 19,
       xlab = "",
       ylab = "",
       xaxt = "n",
       yaxt = "n",
       main = paste("perplexity =", p))
  box()
}
```



```
par(mfrow = c(1, 1))
```

Si la separación de **setosa** aparece con distintos valores de **perplexity**, esa estructura puede considerarse visualmente estable. Si la separación entre **versicolor** y **virginica** cambia más, entonces esa estructura es más dependiente del parámetro elegido.

5.5 UMAP: **n_neighbors**, **min_dist** y estabilidad visual

En UMAP, dos parámetros importantes son **n_neighbors** y **min_dist**.

n_neighbors controla cuántos vecinos usa el algoritmo para construir la estructura local. Valores bajos priorizan vecindarios pequeños; valores altos incorporan una estructura más amplia.

min_dist controla qué tan cerca pueden quedar los puntos en la representación final. Valores bajos producen grupos más compactos; valores altos generan representaciones más abiertas o dispersas.

```
nn_vals <- c(5, 15, 50)

par(mfrow = c(1, 3))

for (nn in nn_vals) {
  set.seed(42)

  confia <- umap.defaults
```

```


config$n_neighbors <- nn

umap_tmp <- umap(X_escalado, config = config)


plot(umap_tmp$layout[, 1],
     umap_tmp$layout[, 2],
     col = as.numeric(grupo),
     pch = 19,
     xlab = "",
     ylab = "",
     xaxt = "n",
     yaxt = "n",
     main = paste("n_neighbors =", nn))
box()
}

```


n_neighbors = 5



n_neighbors = 15



n_neighbors = 50



```

par(mfrow = c(1, 1))

```

```

md_vals <- c(0.01, 0.1, 0.8)

```

```

par(mfrow = c(1, 3))

```

```

for (md in md_vals) {
  set.seed(42)

```

```

  confia <- umap.defaults

```


```

config$min_dist <- md

umap_tmp <- umap(X_escalado, config = config)

plot(umap_tmp$layout[, 1],
      umap_tmp$layout[, 2],
      col = as.numeric(grupo),
      pch = 19,
      xlab = "",
      ylab = "",
      xaxt = "n",
      yaxt = "n",
      main = paste("min_dist =", md))
box()
}

```



```

par(mfrow = c(1, 1))

```

Si una estructura visual aparece de manera parecida al cambiar los parámetros, tenemos más confianza exploratoria en ella. Si cambia mucho, debemos interpretarla con cautela.

En `iris`, esperamos que `setosa` se mantenga claramente separada. En cambio, la relación entre `versicolor` y `virginica` puede variar más según los parámetros, porque su separación es menos fuerte.

5.6 Comparacion global de distancias

Una forma de contrastar las representaciones es comparar las distancias originales entre flores con las distancias obtenidas en cada espacio reducido.

Para esto calculamos la correlación de Spearman entre:

- las distancias originales sobre `X_escalado`;
- las distancias en el espacio reducido de cada método.

La correlación de Spearman no compara los valores exactos de distancia, sino el orden relativo. Por eso resulta útil para evaluar si los pares de flores que estaban cerca o lejos en el espacio original conservan una relación parecida en el mapa reducido.

```
dist_original <- dist(X_escalado)

dist_pca2 <- dist(scores_pca[, 1:2])
dist_pcoa2 <- dist(scores_pcoa[, 1:2])
dist_nmds2 <- dist(scores_nmds[, 1:2])
dist_tsne2 <- dist(scores_tsne[, 1:2])
dist_umap2 <- dist(scores_umap[, 1:2])

cor_dist <- data.frame(
  metodo = c("PCA", "PCoA", "NMDS", "t-SNE", "UMAP"),
  spearman = c(
    cor(as.vector(dist_original), as.vector(dist_pca2), method = "spearman"),
    cor(as.vector(dist_original), as.vector(dist_pcoa2), method = "spearman"),
    cor(as.vector(dist_original), as.vector(dist_nmds2), method = "spearman"),
    cor(as.vector(dist_original), as.vector(dist_tsne2), method = "spearman"),
    cor(as.vector(dist_original), as.vector(dist_umap2), method = "spearman")
  )
)
```

cor_dist

	metodo	spearman
1	PCA	0.9933845
2	PCoA	0.9933845
3	NMDS	0.9951433
4	t-SNE	0.9294595
5	UMAP	0.8033491

Esta comparación no debe interpretarse como una competencia absoluta entre métodos, porque no todos intentan conservar lo mismo.

Sin embargo, sirve para mostrar una diferencia importante: algunos métodos pueden producir gráficos visualmente atractivos pero conservar peor el orden global de las distancias originales.

En un dataset simple y continuo como `iris`, es esperable que PCA y PCoA con distancia euclidiana tengan muy buen desempeño en esta comparación. Métodos como t-SNE y UMAP pueden mostrar agrupamientos claros, pero no necesariamente conservar mejor la geometría global.

5.7 Decisión analítica final

Luego de comparar visual y numéricamente los métodos, para este dataset el PCA aparece como el método principal de referencia.

La decisión se justifica porque *iris* contiene variables continuas, previamente estandarizadas, con relaciones lineales importantes entre algunas variables. Además, PCA permite interpretar tanto la posición de las observaciones como la contribución de las variables originales mediante los loadings.

PCoA con distancia euclidiana produce una representación muy similar, por lo que funciona como una comparación útil y como puente hacia métodos basados en distancias. NMDS, t-SNE y UMAP aportan visualizaciones alternativas, pero en este dataset simple no ofrecen una ventaja clara frente a PCA.

Por lo tanto, para *iris*, usaríamos PCA como método principal de interpretación, PCoA como contraste basado en distancias, y NMDS, t-SNE y UMAP como herramientas exploratorias complementarias.

5.8 Cierre de la hoja de ruta

Esta hoja de ruta permitió recorrer un análisis multivariado completo sin comenzar directamente por los métodos.

Primero reconocimos la estructura física de los datos. Luego revisamos escala y preparación. Después analizamos cómo medir distancias entre observaciones. Recién entonces aplicamos métodos de ordenamiento y reducción dimensional. Finalmente, contrastamos las representaciones visuales con medidas de validación.

La idea central es que los métodos no se eligen por costumbre ni porque produzcan gráficos atractivos. Se eligen según el tipo de dato, la distancia relevante, la estructura que queremos conservar y el objetivo analítico.
