

Hoja de ruta operativa 2: abundancias con Dune

Hoja de ruta operativa: Dune

Objetivo

En *iris* teníamos variables continuas medidas sobre flores. En *dune* tenemos abundancias de especies vegetales registradas en distintos sitios.

Esto cambia el centro del análisis. En datos de abundancia, muchas veces la decisión más importante no es aplicar rápidamente un método, sino elegir una medida de disimilitud adecuada.

La idea de esta hoja es recorrer el análisis por capas, manteniendo una pregunta sencilla en cada etapa:

Capa	Pregunta guía	Resultado esperado
Capa 1	¿Qué estructura inicial muestra el dataset?	Reconocer sitios, especies, abundancias, ceros y variables ambientales disponibles
Capa 2	¿Necesito transformar los datos?	Preparar matrices alternativas: abundancia y presencia/ausencia
Capa 3	¿Cómo mido la diferencia entre sitios?	Calcular y comparar disimilitudes adecuadas para abundancias
Capa 4	¿Qué método uso para ordenar los sitios?	Aplicar CA, PCoA y NMDS
Capa 5	¿Qué tan confiable es la representación y qué decisión tomo?	Revisar inercia, autovalores, stress, correlaciones de distancias y cerrar una decisión analítica

CAPA 1: Estructura inicial de los datos

Pregunta guía

¿Qué estructura física tiene el dataset?

1.1 Carga del dataset y exploración inicial

```
library(vegan)
```

Cargando paquete requerido: permute

```
data(dune)
data(dune.env)

str(dune)
```

```
'data.frame':  20 obs. of  30 variables:
 $ Achimill: num  1 3 0 0 2 2 2 0 0 4 ...
 $ Agrostol: num  0 0 4 8 0 0 0 4 3 0 ...
 $ Airaprae: num  0 0 0 0 0 0 0 0 0 0 ...
 $ Alop geni: num  0 2 7 2 0 0 0 5 3 0 ...
 $ Anthodor: num  0 0 0 0 4 3 2 0 0 4 ...
 $ Bellpere: num  0 3 2 2 2 0 0 0 0 2 ...
 $ Bromhord: num  0 4 0 3 2 0 2 0 0 4 ...
 $ Chenalbu: num  0 0 0 0 0 0 0 0 0 0 ...
 $ Cirsarve: num  0 0 0 2 0 0 0 0 0 0 ...
 $ Comapalu: num  0 0 0 0 0 0 0 0 0 0 ...
 $ Eleopal u: num  0 0 0 0 0 0 0 4 0 0 ...
 $ Elymrepe: num  4 4 4 4 4 0 0 0 6 0 ...
 $ Empenigr: num  0 0 0 0 0 0 0 0 0 0 ...
 $ Hyporadi: num  0 0 0 0 0 0 0 0 0 0 ...
 $ Juncarti: num  0 0 0 0 0 0 0 4 4 0 ...
 $ Juncbufo: num  0 0 0 0 0 0 2 0 4 0 ...
 $ Lolipere: num  7 5 6 5 2 6 6 4 2 6 ...
 $ Planlanc: num  0 0 0 0 5 5 5 0 0 3 ...
 $ Poaprat  : num  4 4 5 4 2 3 4 4 4 4 ...
 $ Poatriv  : num  2 7 6 5 6 4 5 4 5 4 ...
 $ Ranuflam: num  0 0 0 0 0 0 0 2 0 0 ...
 $ Rumeacet: num  0 0 0 0 5 6 3 0 2 0 ...
 $ Sagiproc: num  0 0 0 5 0 0 0 2 2 0 ...
 $ Salirepe: num  0 0 0 0 0 0 0 0 0 0 ...
 $ Scorausu: num  0 5 2 2 3 3 3 3 2 3 ...
 $ Trifprat: num  0 0 0 0 2 5 2 0 0 0 ...
 $ Trifrepe: num  0 5 2 1 2 5 2 2 3 6 ...
 $ Vicilath: num  0 0 0 0 0 0 0 0 0 1 ...
```

```
$ Bracruta: num 0 0 2 2 2 6 2 2 2 2 ...
$ Callcusp: num 0 0 0 0 0 0 0 0 0 0 ...
```

```
head(dune)
```

	Achimill	Agrostol	Airaprae	Alopgeni	Anthodor	Bellpere	Bromhord	
Chenalbu								
1	1	0	0	0	0	0	0	
0								
2	3	0	0	2	0	3	4	
0								
3	0	4	0	7	0	2	0	
0								
4	0	8	0	2	0	2	3	
0								
5	2	0	0	0	4	2	2	
0								
6	2	0	0	0	3	0	0	
0								
	Cirsarve	Comapalu	Eleopalul	Elymrepe	Empenigr	Hyporadi	Juncarti	
Juncbufo								
1	0	0	0	4	0	0	0	
0								
2	0	0	0	4	0	0	0	
0								
3	0	0	0	4	0	0	0	
0								
4	2	0	0	4	0	0	0	
0								
5	0	0	0	4	0	0	0	
0								
6	0	0	0	0	0	0	0	
0								
	Lolipere	Planlanc	Poaprat	Poatriv	Ranuflam	Rumeacet	Sagiprocc	Salirepe
1	7	0	4	2	0	0	0	0
2	5	0	4	7	0	0	0	0
3	6	0	5	6	0	0	0	0
4	5	0	4	5	0	0	5	0
5	2	5	2	6	0	5	0	0
6	6	5	3	4	0	6	0	0
	Scorautu	Trifprat	Trifrepe	Vicilath	Bracruta	Callcusp		
1	0	0	0	0	0	0		
2	5	0	5	0	0	0		
3	2	0	2	0	2	0		
4	2	0	1	0	2	0		
5	3	2	2	0	2	0		
6	3	5	5	0	6	0		

```
summary(dune)
```

Achimill	Agrostol	Airaprae	Alopgeni	Anthodor
Min. :0.0	Min. :0.0	Min. :0.00	Min. :0.00	Min. :0.00
1st Qu.:0.0	1st Qu.:0.0	1st Qu.:0.00	1st Qu.:0.00	1st Qu.:0.00
Median :0.0	Median :1.5	Median :0.00	Median :0.00	Median :0.00
Mean :0.8	Mean :2.4	Mean :0.25	Mean :1.80	Mean :1.05
3rd Qu.:2.0	3rd Qu.:4.0	3rd Qu.:0.00	3rd Qu.:3.25	3rd Qu.:2.25
Max. :4.0	Max. :8.0	Max. :3.00	Max. :8.00	Max. :4.00
Bellpere	Bromhord	Chenalbu	Cirsarve	Comapalu
Min. :0.00	Min. :0.00	Min. :0.00	Min. :0.0	Min. :0.0
1st Qu.:0.00	1st Qu.:0.00	1st Qu.:0.00	1st Qu.:0.0	1st Qu.:0.0
Median :0.00	Median :0.00	Median :0.00	Median :0.0	Median :0.0
Mean :0.65	Mean :0.75	Mean :0.05	Mean :0.1	Mean :0.2
3rd Qu.:2.00	3rd Qu.:0.50	3rd Qu.:0.00	3rd Qu.:0.0	3rd Qu.:0.0
Max. :3.00	Max. :4.00	Max. :1.00	Max. :2.0	Max. :2.0
Eleopalú	Elymrepe	Empenigr	Hyporadi	Juncarti
Min. :0.00	Min. :0.0	Min. :0.0	Min. :0.00	Min. :0.00
1st Qu.:0.00	1st Qu.:0.0	1st Qu.:0.0	1st Qu.:0.00	1st Qu.:0.00
Median :0.00	Median :0.0	Median :0.0	Median :0.00	Median :0.00
Mean :1.25	Mean :1.3	Mean :0.1	Mean :0.45	Mean :0.90
3rd Qu.:1.00	3rd Qu.:4.0	3rd Qu.:0.0	3rd Qu.:0.00	3rd Qu.:0.75
Max. :8.00	Max. :6.0	Max. :2.0	Max. :5.00	Max. :4.00
Juncbufo	Lolipere	Planlanc	Poaprat	Poatriv
Min. :0.00	Min. :0.0	Min. :0.0	Min. :0.0	Min. :0.00
1st Qu.:0.00	1st Qu.:0.0	1st Qu.:0.0	1st Qu.:0.0	1st Qu.:0.00
Median :0.00	Median :2.0	Median :0.0	Median :3.0	Median :4.00
Mean :0.65	Mean :2.9	Mean :1.3	Mean :2.4	Mean :3.15
3rd Qu.:0.00	3rd Qu.:6.0	3rd Qu.:3.0	3rd Qu.:4.0	3rd Qu.:5.00
Max. :4.00	Max. :7.0	Max. :5.0	Max. :5.0	Max. :9.00
Ranufлам	Rumeacet	Sagiproс	Salirepe	Scorautu
Min. :0.0	Min. :0.0	Min. :0	Min. :0.00	Min. :0.0
1st Qu.:0.0	1st Qu.:0.0	1st Qu.:0	1st Qu.:0.00	1st Qu.:2.0
Median :0.0	Median :0.0	Median :0	Median :0.00	Median :2.0
Mean :0.7	Mean :0.9	Mean :1	Mean :0.55	Mean :2.7
3rd Qu.:2.0	3rd Qu.:0.5	3rd Qu.:2	3rd Qu.:0.00	3rd Qu.:3.0
Max. :4.0	Max. :6.0	Max. :5	Max. :5.00	Max. :6.0
Trifprat	Trifrepe	Vicilath	Bracruta	Callcusp
Min. :0.00	Min. :0.00	Min. :0.0	Min. :0.00	Min. :0.0
1st Qu.:0.00	1st Qu.:1.00	1st Qu.:0.0	1st Qu.:1.50	1st Qu.:0.0
Median :0.00	Median :2.00	Median :0.0	Median :2.00	Median :0.0
Mean :0.45	Mean :2.35	Mean :0.2	Mean :2.45	Mean :0.5
3rd Qu.:0.00	3rd Qu.:3.00	3rd Qu.:0.0	3rd Qu.:4.00	3rd Qu.:0.0
Max. :5.00	Max. :6.00	Max. :2.0	Max. :6.00	Max. :4.0

```
# Revisión de valores faltantes
sum(is.na(dune))
```

```
[1] 0
```

El dataset `dune` contiene sitios de muestreo en las filas y especies vegetales en las columnas.

Cada celda indica la abundancia de una especie en un sitio. Por lo tanto, no estamos trabajando con medidas continuas como largo o ancho, sino con conteos o abundancias.

Esto es importante porque muchas especies pueden estar ausentes en muchos sitios. En esos casos aparecen muchos ceros, y eso cambia la forma de medir semejanza o diferencia entre observaciones.

1.2 Matriz de abundancias y variables ambientales

```
X <- dune
ambiente <- dune.env
```

En esta hoja, `X` será la matriz principal de abundancias. Las filas representan sitios y las columnas representan especies.

El objeto `ambiente` contiene variables ambientales o de manejo asociadas a los sitios. Estas variables no se usarán para construir los ordenamientos principales, pero pueden servir para colorear los gráficos e interpretar patrones.

1.3 ¿Cuántos ceros hay?

```
prop_ceros <- sum(X == 0) / length(as.matrix(X))
prop_ceros
```

```
[1] 0.6716667
```

La proporción de ceros indica qué parte de la matriz corresponde a ausencias de especies.

En datos ecológicos, muchos ceros son esperables. No significan necesariamente datos faltantes. Pueden indicar que una especie no fue observada en un sitio.

Este punto es clave porque algunas distancias funcionan mejor que otras cuando hay muchos ceros.

1.4 Abundancia total por sitio y frecuencia de especies

```
abund_sitio <- rowSums(X) # Abundancia por sitio
```

```
# Consideramos  $X > 0$  para calcular la frecuencia con que aparece cada
frec_especies <- colSums(X>0)

abund_sitio
```

```
1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20
18 42 40 45 43 48 40 40 42 43 32 35 33 24 23 33 15 27 31 31
```


```
frec_especies
```



```
Achimill Agrostol Airaprae Alopogeni Anthodor Bellpere Bromhord Chenalbu
      7      10      2      8      6      6      5      1
Cirsarve Comapalu Eleopalu Elymrepe Empenigr Hyporadi Juncarti Juncbufo
      1      2      5      6      1      3      5      4
Lolipere Planlanc Poaprat Poatriv Ranuflam Rumeacet Sagiproc Salirepe
      12      7      14      13      6      5      7      3
Scorautu Trifprat Trifrepe Vicilath Bracruta Callcusp
      18      3      16      3      15      3
```

```
par(mfrow = c(1, 2))

barplot(abund_sitio,
        main = "Abundancia total por sitio",
        xlab = "Sitio",
        ylab = "Abundancia total")

barplot(frec_especies,
        las = 2,
        main = "Frecuencia de especies",
        ylab = "Cantidad de sitios")
```





```
par(mfrow = c(1, 1))
```

La abundancia total por sitio muestra cuántos individuos o registros hay en cada sitio. Ayuda a ver si hay sitios muy abundantes o sitios pobres en especies

La frecuencia de especies muestra en cuántos sitios aparece cada especie. Esto ayuda a ver si hay especies muy frecuentes o detectar especies raras.

1.5 Variables ambientales disponibles

```
str(ambiente)
```

```
'data.frame':  20 obs. of  5 variables:
 $ A1          : num  2.8 3.5 4.3 4.2 6.3 4.3 2.8 4.2 3.7 3.3 ...
 $ Moisture    : Ord.factor w/ 4 levels "1"<"2"<"4"<"5": 1 1 2 2 1 1 1 4
3 2 ...
 $ Management: Factor w/ 4 levels "BF","HF","NM",...: 4 1 4 4 2 2 2 2 2
1 ...
 $ Use        : Ord.factor w/ 3 levels "Hayfield"<"Haypastu"<...: 2 2 2 2
1 2 3 3 1 1 ...
 $ Manure     : Ord.factor w/ 5 levels "0"<"1"<"2"<"3"<...: 5 3 5 5 3 3 4
4 2 2 ...
```

Las variables ambientales permiten interpretar los ordenamientos una vez que fueron construidos.

Por ejemplo, podemos colorear los sitios según **Management** para observar si los sitios con distinto manejo tienden a ubicarse en zonas diferentes del gráfico.

```
grupo <- ambiente$Management
table(grupo)
```

```
grupo
BF HF NM SF
3  5  6  6
```

En esta hoja usaremos **Management** como variable de referencia visual. No entra en los cálculos de distancia ni en los métodos de ordenamiento no supervisados.

Solo se usa después para interpretar.

1.6 Conclusiones de la Capa 1

En esta capa reconocimos que `dune` es una matriz de abundancias de especies por sitio.

A diferencia de `iris`, no tenemos variables continuas medidas sobre individuos, sino abundancias con muchos ceros. Por eso no conviene trasladar automáticamente la misma lógica de PCA y distancia euclidiana.

La exploración inicial muestra que la elección de la disimilitud será una decisión central. En particular, necesitaremos medidas adecuadas para abundancias y presencia/ausencia.

CAPA 2: Transformación y preparación de los datos

Pregunta inicial de la capa

¿Necesito transformar los datos antes de calcular disimilitudes u ordenamientos?

En `iris`, la preparación principal fue centrar y escalar variables continuas. En `dune`, la situación es distinta: las columnas son especies y las celdas son abundancias.

En datos ecológicos no siempre tiene sentido estandarizar columnas como si fueran variables continuas comunes. Muchas veces conviene preparar distintas versiones de la matriz según la pregunta.

2.1 Matriz de abundancias originales

```
X_abund <- X
head(X_abund)
```

```
      Achimill Agrostol Airaprae Alop geni Anthodor Bellpere Bromhord
Chenalbu
1         1         0         0         0         0         0         0
0
2         3         0         0         2         0         3         4
0
3         0         4         0         7         0         2         0
0
4         0         8         0         2         0         2         3
```


0								
5	2	0	0	0	4	2	2	
0								
6	2	0	0	0	3	0	0	
0								
	Cirsarve	Comapalu	Eleopalu	Elymrepe	Empenigr	Hyporadi	Juncarti	
	Juncbufo							
1	0	0	0	4	0	0	0	
0								
2	0	0	0	4	0	0	0	
0								
3	0	0	0	4	0	0	0	
0								
4	2	0	0	4	0	0	0	
0								
5	0	0	0	4	0	0	0	
0								
6	0	0	0	0	0	0	0	
0								
	Lolipere	Planlanc	Poaprat	Poatriv	Ranuflam	Rumeacet	Sagiprocc	Salirepe
1	7	0	4	2	0	0	0	0
2	5	0	4	7	0	0	0	0
3	6	0	5	6	0	0	0	0
4	5	0	4	5	0	0	5	0
5	2	5	2	6	0	5	0	0
6	6	5	3	4	0	6	0	0
	Scorautu	Trifprat	Trifrepe	Vicilath	Bracruta	Callcusp		
1	0	0	0	0	0	0		
2	5	0	5	0	0	0		
3	2	0	2	0	2	0		
4	2	0	1	0	2	0		
5	3	2	2	0	2	0		
6	3	5	5	0	6	0		

La matriz `X_abund` conserva las abundancias originales.

Esta versión será útil para disimilitudes que consideran cantidad y composición, como Bray-Curtis.

2.2 Matriz de presencia/ausencia

```
X_pa <- decostand(X, method = "pa")
head(X_pa)
```

	Achimill	Agrostol	Airaprae	Alopgeni	Anthodor	Bellpere	Bromhord	
	Chenalbu							
1	1	0	0	0	0	0	0	
0								

2030405060	100100	011000	000000	110000	001101	110000	100100
Cirsarve Comapalu Eleopalu Elymrepe Empenigr Hyporadi Juncarti							
Juncbufo							
102030405060	000100	000000	000000	110101	000000	000000	000000
Lolipere Planlanc Poaprat Poatriv Ranuflam Rumeacet Sagiprocc Salirepe							
123456	111111	000011	000111	111111	000000	001101	000000
Scorautu Trifprat Trifrepe Vicilath Bracruta Callcusp							
123456	011111	000011	000111	000000	001101	000000	

La matriz **X_{pa}** transforma las abundancias en presencia/ausencia.

Los valores mayores que cero pasan a 1. Los ceros quedan como 0.

Esta transformación responde otra pregunta. Ya no importa cuán abundante es una especie, sino si está presente o ausente en cada sitio.

2.3 Transformación de Hellinger como opción para datos de abundancia

de abundancia

```
X_hell <- decostand(X, method = "hellinger")
head(X_hell)
```

	Achimill	Agrostol	Airaprae	Alopgeni	Anthodor	Bellpere	Bromhord
Chenalbu							
1	0.2357023	0.0000000	0	0.0000000	0.0000000	0.0000000	0.0000000
0							
2	0.2672612	0.0000000	0	0.2182179	0.0000000	0.2672612	0.3086067
0							
3	0.0000000	0.3162278	0	0.4183300	0.0000000	0.2236068	0.0000000
0							
4	0.0000000	0.4216370	0	0.2108185	0.0000000	0.2108185	0.2581989
0							
5	0.2156655	0.0000000	0	0.0000000	0.3049971	0.2156655	0.2156655
0							
6	0.2041241	0.0000000	0	0.0000000	0.2500000	0.0000000	0.0000000
0							
	Cirsarve	Comapalu	Eleopal	Elymrepe	Empenigr	Hyporadi	Juncarti
Juncbufo							
1	0.0000000	0	0	0.4714045	0	0	0
0							
2	0.0000000	0	0	0.3086067	0	0	0
0							
3	0.0000000	0	0	0.3162278	0	0	0
0							
4	0.2108185	0	0	0.2981424	0	0	0
0							
5	0.0000000	0	0	0.3049971	0	0	0
0							
6	0.0000000	0	0	0.0000000	0	0	0
0							
	Lolipere	Planlanc	Poaprat	Poatriv	Ranuflam	Rumeacet	Sagiproc
Salirepe							
1	0.6236096	0.0000000	0.4714045	0.3333333	0	0.0000000	0.0000000
0							
2	0.3450328	0.0000000	0.3086067	0.4082483	0	0.0000000	0.0000000
0							
3	0.3872983	0.0000000	0.3535534	0.3872983	0	0.0000000	0.0000000
0							
4	0.3333333	0.0000000	0.2981424	0.3333333	0	0.0000000	0.3333333
0							
5	0.2156655	0.3409972	0.2156655	0.3735437	0	0.3409972	0.0000000
0							
6	0.3535534	0.3227486	0.2500000	0.2886751	0	0.3535534	0.0000000
0							
	Scorautu	Trifprat	Trifrepe	Vicilath	Bracruta	Callcusp	

1	0.0000000	0.0000000	0.0000000	0	0.0000000	0
2	0.3450328	0.0000000	0.3450328	0	0.0000000	0
3	0.2236068	0.0000000	0.2236068	0	0.2236068	0
4	0.2108185	0.0000000	0.1490712	0	0.2108185	0
5	0.2641353	0.2156655	0.2156655	0	0.2156655	0
6	0.2500000	0.3227486	0.3227486	0	0.3535534	0

La transformación de Hellinger hace dos cosas:

- Convierte las abundancias en **abundancias relativas**.
- Después aplica raíz cuadrada.

Hellinger transforma cada sitio para que importe más la composición relativa de especies que la abundancia total bruta. Sirve si queremos usar métodos que trabajan con distancia euclidiana, como PCA.

En esta hoja no será la matriz principal, pero conviene conocerla porque suaviza el peso de abundancias muy grandes y hace más tratables los datos de especies.

2.4 Conclusiones de la Capa 2

En esta capa preparamos tres versiones de la matriz:

- `X_abund`: abundancias originales;
- `X_pa`: presencia/ausencia;
- `X_hell`: abundancias transformadas con Hellinger.

Para esta hoja, las dos matrices principales serán `X_abund` y `X_pa`.

La decisión importante es que no existe una única transformación correcta. La preparación depende de la pregunta:

- si importa la abundancia, usamos `X_abund`;
- si importa solo la composición en términos de presencia/ausencia, usamos `X_pa`.

CAPA 3: Distancia, disimilitud o semejanza

Pregunta inicial de la capa

¿Cómo medimos la diferencia entre sitios?

En `dune`, cada sitio tiene una combinación de especies y abundancias. Entonces, comparar sitios significa comparar composiciones ecológicas.

En este tipo de datos, la distancia euclidiana no suele ser la primera opción, porque tiene muchos ceros y abundancias desbalanceadas pueden distorsionar la comparación.

Por eso vamos a trabajar principalmente con disimilitudes ecológicas.

¿Por qué decimos disimilitud y no distancia?

Una distancia matemática debe cumplir ciertas propiedades. Por ejemplo:

- La distancia de un sitio consigo mismo debe ser 0
- La distancia entre A y B debe ser igual que entre B y A;
- Y además debe cumplir una propiedad llamada desigualdad triangular.

Algunas medidas usadas en ecología, como Bray-Curtis, no siempre cumplen todas esas condiciones matemáticas. Por eso es más correcto llamarlas **disimilitudes**.

En la práctica, la idea sigue siendo muy parecida: valores bajos indican sitios parecidos, valores altos indican sitios diferentes.

Medidas útiles para este dataset

Tipo de dato	Medida	Qué compara	Cuándo usarla
Abundancias	Bray-Curtis	Diferencias en composición y abundancia	Cuando importa cuánto hay de cada especie
Presencia/ausencia	Jaccard	Presencias compartidas y no compartidas	Cuando importa qué especies están o no están
Frecuencias o perfiles	Chi-cuadrado	Diferencias entre perfiles	Base conceptual de CA

En esta hoja usaremos Bray-Curtis y Jaccard como disimilitudes principales.

3.1 Bray-Curtis sobre abundancias

```
dist_bray <- vegdist(X_abund, method = "bray")  
  
dim(as.matrix(dist_bray))
```

```
[1] 20 20
```

```
as.matrix(dist_bray)[1:6, 1:6]
```

	1	2	3	4	5	6
1	0.0000000	0.4666667	0.4482759	0.5238095	0.6393443	0.6363636
2	0.4666667	0.0000000	0.3414634	0.3563218	0.4117647	0.5111111
3	0.4482759	0.3414634	0.0000000	0.2705882	0.4698795	0.5681818
4	0.5238095	0.3563218	0.2705882	0.0000000	0.5000000	0.6344086
5	0.6393443	0.4117647	0.4698795	0.5000000	0.0000000	0.2967033
6	0.6363636	0.5111111	0.5681818	0.6344086	0.2967033	0.0000000

Bray-Curtis compara sitios usando las abundancias de especies.

Dos sitios serán parecidos si tienen especies similares con abundancias similares. Serán diferentes si cambian las especies presentes o sus abundancias.

Esta disimilitud es muy usada en ecología porque funciona bien con datos de abundancia y muchos ceros.

3.2 Jaccard sobre presencia/ausencia

```
dist_jacc <- vegdist(X_pa, method = "jaccard")  
  
as.matrix(dist_jacc)[1:6, 1:6]
```

	1	2	3	4	5	6
1	0.0000000	0.5000000	0.6363636	0.7142857	0.6428571	0.6666667
2	0.5000000	0.0000000	0.3333333	0.3571429	0.4000000	0.6000000
3	0.6363636	0.3333333	0.0000000	0.2307692	0.5000000	0.6000000
4	0.7142857	0.3571429	0.2307692	0.0000000	0.5000000	0.6666667
5	0.6428571	0.4000000	0.5000000	0.5000000	0.0000000	0.2142857
6	0.6666667	0.6000000	0.6000000	0.6666667	0.2142857	0.0000000

Jaccard compara sitios según presencia y ausencia de especies.

No le importa si una especie es muy abundante o poco abundante. Solo registra si está presente o ausente.

Por eso, Jaccard responde una pregunta distinta a Bray-Curtis.

3.3 Chi-Cuadrado sobre abundancia

Chi-cuadrado usa abundancias, pero compara perfiles y le da otro peso a las especies.

```
dist_chi <- vegdist(X_abund, method = "chisq")
as.matrix(dist_chi)[1:6, 1:6]
```

	1	2	3	4	5	6
1	0.000000	1.634559	1.520293	1.928839	1.9826957	2.1826805
2	1.634559	0.000000	1.140514	1.454467	1.3305770	1.7861398
3	1.520293	1.140514	0.000000	1.335238	1.5675920	1.8065306
4	1.928839	1.454467	1.335238	0.000000	1.7657897	2.0553906
5	1.982696	1.330577	1.567592	1.765790	0.0000000	0.9888915
6	2.182681	1.786140	1.806531	2.055391	0.9888915	0.0000000

En esta hoja usamos Bray-Curtis como disimilitud principal porque estamos trabajando con abundancias de especies y muchos ceros.

También podríamos calcular una disimilitud chi-cuadrado, porque es una opción posible para datos de abundancia o frecuencias. Pero no será el camino principal, porque su interpretación es menos directa y porque Bray-Curtis suele ser más cómoda para matrices ecológicas con muchas ausencias.

Chi-cuadrado puede quedar como comparación extra, especialmente si después queremos entender el Análisis de Correspondencias.

3.4 Comparación entre disimilitudes

Ahora comparamos las disimilitudes entre sí.

La pregunta es simple:

¿Cambian mucho las diferencias entre sitios según la medida que usemos?

Cada punto del gráfico compara dos sitios. Por ejemplo, sitio 1 contra sitio 2, sitio 1 contra sitio 3, y así con todas las combinaciones posibles.


Si los puntos siguen una línea clara, quiere decir que las dos medidas cuentan una historia parecida.

Si los puntos quedan muy dispersos, quiere decir que cada medida está mirando algo distinto.

3.4.1 Bray-Curtis vs Jaccard

```
plot(as.vector(dist_bray), as.vector(dist_jacc),
     pch = 19,
     xlab = "Bray-Curtis",
     ylab = "Jaccard",
     main = "Comparación de disimilitudes")
```

Comparación de disimilitudes



```
cor(as.vector(dist_bray), as.vector(dist_jacc), method = "spearman")
```

```
[1] 0.9573698
```

Bray-Curtis usa abundancias. Jaccard usa presencia/ausencia.

La correlación fue alta. Entonces, en estos datos, mirar abundancias o mirar solo presencia/ausencia da una lectura bastante parecida.

De todos modos, seguimos usando Bray-Curtis como disimilitud principal porque conserva más información: no solo dice qué especies aparecen, sino también cuánto aparecen.

3.4.2 Bray-Curtis vs Chi-Cuadrado


```
# Comparación Bray-Curtis vs Chi-cuadrado  
cor(as.vector(dist_bray), as.vector(dist_chi), method = "spearman")
```

```
[1] 0.8894901
```

```
plot(as.vector(dist_bray),  
     as.vector(dist_chi),  
     pch = 19,  
     xlab = "Bray-Curtis")
```



```
xlab = "Bray-Curtis",
ylab = "Chi-cuadrado",
main = "Bray-Curtis vs Chi-cuadrado")
```



Chi-cuadrado también usa abundancias, pero las lee como perfiles de composición.

La comparación con Bray-Curtis sirve para ver si ambas formas de usar las abundancias dan resultados parecidos o no.

Si la correlación es alta, las dos medidas separan los sitios de forma parecida.

Si la correlación es menor, chi-cuadrado está marcando diferencias que Bray-Curtis no marca tanto.


3.4.3 Comparación Jaccard vs Chi-cuadrado

```
# Comparación Jaccard vs Chi-cuadrado
cor(as.vector(dist_jacc), as.vector(dist_chi), method = "spearman")
```

```
[1] 0.8470192
```

```
plot(as.vector(dist_jacc),
     as.vector(dist_chi),
     pch = 19,
     xlab = "Jaccard")
```

```
xlab = "Jaccard",
ylab = "Chi-cuadrado",
main = "Jaccard vs Chi-cuadrado")
```





Esta comparación cruza una medida de presencia/ausencia con una medida basada en abundancias.

Sirve para ver si el patrón de composición aparece incluso cuando dejamos de mirar las cantidades.

3.5 Visualización exploratoria de las disimilitudes


```
heatmap(as.matrix(dist_bray),
        symm = TRUE,
        Rowv = NA,
        Colv = NA,
        main = "Bray-Curtis")
```






```
heatmap(as.matrix(dist_jacc),
        symm = TRUE,
        Rowv = NA,
        Colv = NA,
        main = "Jaccard")
```

Jaccard



```
heatmap(as.matrix(dist_chi),
        symm = TRUE,
        Rowv = NA,
        Colv = NA,
```

```
main = "Chi-cuadrado")
```



Los mapas de calor permiten mirar patrones generales de similitud o diferencia entre sitios.

No son una prueba formal. Solo ayudan a ver si hay bloques de sitios más parecidos entre sí.

3.6 Cierre de la Capa 3

En esta capa definimos cómo comparar sitios.

Bray-Curtis queda como disimilitud principal para trabajar con abundancias.

Jaccard queda como comparación útil cuando queremos mirar solo presencia/ausencia.

Chi-cuadrado queda como comparación extra, sobre todo porque ayuda a conectar con el Análisis de Correspondencias.

La idea importante es esta: antes de hacer PCoA, NMDS o cualquier ordenamiento, primero tenemos que decidir cómo vamos a medir la diferencia entre sitios.

Esa decisión no es un detalle técnico. Cambiar la disimilitud puede cambiar el resultado visual y también la interpretación.

CAPA 4: Ordenamiento, reducción dimensional e interpretación visual

Pregunta inicial de la capa

¿Cómo puedo representar la estructura de disimilitud entre sitios en menos dimensiones?

En esta capa aplicamos métodos de ordenamiento al dataset `dune`.

A diferencia de `iris`, acá el centro no será PCA como método principal. El foco estará en métodos que trabajan bien con abundancias y disimilitudes ecológicas: CA, PCoA y NMDS.

¿Qué aporta cada método?


Método	Pregunta que responde mejor	Ventaja principal	Cuidado
CA	¿Qué asociación hay entre sitios y especies?	Interpreta simultáneamente sitios y especies	Puede ser sensible a especies raras
PCoA	¿Cómo representar sitios desde una disimilitud elegida?	Permite usar Bray-Curtis o Jaccard	Puede requerir corrección si hay autovalores negativos
NMDS	¿Puedo conservar el orden relativo de las disimilitudes?	Muy flexible para datos ecológicos	Necesita revisar stress y estabilidad

En esta hoja no buscamos un método ganador automático. Queremos ver qué mapa construye cada método y qué lectura permite.

4.1 CA: Análisis de Correspondencias

```
ca_dune <- cca(X_abund)
```

```
ca_dune
```

Cada punto representa un sitio. El color muestra el tipo de manejo (Management), pero esa variable no fue usada para construir el CA.


La lectura visual busca observar si sitios con manejos similares tienden a ubicarse cerca.

4.2 PCoA con Bray-Curtis

```
pcoa_bray <- cmdscale(dist_bray, k = 2, eig = TRUE, add = TRUE)
scores_pcoa_bray <- pcoa_bray$points

plot(scores_pcoa_bray[, 1], scores_pcoa_bray[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "PCoA1", ylab = "PCoA2", main = "PCoA Bray-Curtis")

legend("topright",
     legend = levels(grupo),
     col = 1:nlevels(grupo),
     pch = 19)
```



PCoA1

PCoA con Bray-Curtis representa sitios a partir de diferencias en abundancia y composición.


Si dos sitios aparecen cerca, significa que tienen composiciones de especies similares según Bray-Curtis.

4.3 PCoA con Jaccard

```
pcoa_jacc <- cmdscale(dist_jacc, k = 2, eig = TRUE, add = TRUE)
scores_pcoa_jacc <- pcoa_jacc$points

plot(scores_pcoa_jacc[, 1], scores_pcoa_jacc[, 2],
     col = as.numeric(grupo),
     pch = 19,
     xlab = "PCoA1",
     ylab = "PCoA2",
     main = "PCoA Jaccard")

legend("topright",
     legend = levels(grupo),
     col = 1:nlevels(grupo),
     pch = 19)
```



PCoA con Jaccard representa sitios según presencia/ausencia.

Este gráfico puede diferir del PCoA con Bray-Curtis porque ignora las abundancias y solo considera qué especies están presentes.

4.4 NMDS con Bray-Curtis

```
set.seed(42)

nmds_bray <- metaMDS(dist_bray,
                     k = 2,
                     trymax = 100,
                     trace = FALSE)

nmds_bray
```

Call:

```
metaMDS(comm = dist_bray, k = 2, trymax = 100, trace = FALSE)
```

global Multidimensional Scaling using monoMDS

Data: dist_bray

Distance: bray

Dimensions: 2

Stress: 0.1183186

Stress type 1, weak ties

Best solution was repeated 4 times in 20 tries

The best solution was from try 3 (random start)

Scaling: centring, PC rotation, halfchange scaling

Species: scores missing

```
scores_nmds_bray <- scores(nmds_bray)

plot(scores_nmds_bray[, 1], scores_nmds_bray[, 2],
     col = as.numeric(grupo),
     pch = 19,
     xlab = "",
     ylab = "",
     xaxt = "n",
     yaxt = "n",
     main = "NMDS Bray-Curtis")
box()


legend("topright",
```

```

legend = levels(grupo),
col = 1:nlevels(grupo),
pch = 19)

```

NMDS Bray-Curtis



NMDS con Bray-Curtis intenta conservar el **orden relativo** de las disimilitudes de abundancia.

Los ejes no se interpretan como variables. Lo importante es la cercanía relativa entre sitios.

4.5 NMDS con Jaccard

```

set.seed(42)

nmds_jacc <- metaMDS(dist_jacc,
                     k = 2,
                     trymax = 100,
                     trace = FALSE)

nmds_jacc

```

Call:

```
metaMDS(comm = dist_jacc, k = 2, trymax = 100, trace = FALSE)
```

global Multidimensional Scaling using monoMDS

Data: dist_jacc

Distance: jaccard

Dimensions: 2

Stress: 0.1067169

Stress type 1, weak ties

Best solution was repeated 1 time in 20 tries

The best solution was from try 18 (random start)

Scaling: centring, PC rotation, halfchange scaling


Species: scores missing

```
scores_nmds_jacc <- scores(nmds_jacc)

plot(scores_nmds_jacc[, 1], scores_nmds_jacc[, 2],
     col = as.numeric(grupo),
     pch = 19,
     xlab = "",
     ylab = "",
     xaxt = "n",
     yaxt = "n",
     main = "NMDS Jaccard")
box()

legend("topright",
     legend = levels(grupo),
     col = 1:nlevels(grupo),
     pch = 19)
```

NMDS Jaccard



NMDS con Jaccard intenta conservar el orden relativo de las disimilitudes de presencia/ausencia.

Si este gráfico cambia mucho respecto al NMDS con Bray-Curtis, significa que las abundancias están aportando información importante.

4.6 Comparación visual conjunta

```
par(mfrow = c(2, 3))

plot(scores_ca[, 1], scores_ca[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "CA1", ylab = "CA2",
     main = "CA")


plot(scores_pcoa_bray[, 1], scores_pcoa_bray[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "PCoA1", ylab = "PCoA2",
     main = "PCoA Bray")

plot(scores_pcoa_jacc[, 1], scores_pcoa_jacc[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "PCoA1", ylab = "PCoA2",
     main = "PCoA Jaccard")

plot(scores_nmds_bray[, 1], scores_nmds_bray[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "", ylab = "", xaxt = "n", yaxt = "n",
     main = "NMDS Bray")
box()

plot(scores_nmds_jacc[, 1], scores_nmds_jacc[, 2],
     col = as.numeric(grupo), pch = 19,
     xlab = "", ylab = "", xaxt = "n", yaxt = "n",
     main = "NMDS Jaccard")
box()

plot.new()
legend("center",
     legend = levels(grupo),
     col = 1:nlevels(grupo),
     pch = 19,
     title = "Management")
```



```
par(mfrow = c(1, 1))
```

Esta comparación permite observar si los sitios se organizan de forma parecida según distintos métodos y disimilitudes.

La pregunta principal no es cuál gráfico se ve más lindo, sino qué decisión produjo cada estructura:

- CA trabaja con una lógica de perfiles y chi-cuadrado;
- PCoA representa distancias explícitas;
- NMDS representa el orden relativo de las disimilitudes;
- Bray-Curtis usa abundancias;
- Jaccard usa presencia/ausencia.

4.7 Cierre de la Capa 4

En esta capa construimos distintos mapas de los sitios de [dune](#).

La diferencia principal no está solo en el método, sino también en la disimilitud usada.

Si Bray-Curtis y Jaccard producen mapas parecidos, significa que la presencia/ausencia ya captura buena parte de la estructura. Si producen mapas distintos, significa que la abundancia aporta información adicional.

significa que la abundancia aporta información adicional.

CA permite una mirada clásica para tablas de abundancia. PCoA permite representar una disimilitud elegida. NMDS es especialmente útil cuando queremos conservar el orden relativo de las disimilitudes y no las distancias exactas.

CAPA 5: Validación, contraste y decisión analítica

Pregunta inicial de la capa

¿Qué tan confiables son las representaciones obtenidas y qué decisión analítica podemos tomar?

En la Capa 4 construimos distintos mapas de los sitios. Ahora necesitamos revisar si esos mapas son razonables.

Validar no significa buscar un único método ganador. Significa entender qué tan bien cada representación sostiene la lectura que estamos haciendo.

5.1 CA: inercia explicada

```
cumsum(ca_dune$CA$eig / sum(ca_dune$CA$eig))
```

	CA1	CA2	CA3	CA4	CA5	CA6	CA7
CA8	0.2533987	0.4425683	0.5653866	0.6485813	0.7170196	0.7680350	0.8117520
	0.8500044						
	CA9	CA10	CA11	CA12	CA13	CA14	CA15
CA16	0.8846650	0.9112792	0.9340955	0.9535957	0.9702491	0.9799545	0.9870036
	0.9912934						
	CA17	CA18	CA19				
	0.9950463	0.9983563	1.0000000				

En CA, los autovalores permiten ver cuánta inercia representa cada eje.

La inercia cumple un papel parecido a la varianza explicada en PCA, pero dentro de la lógica del análisis de correspondencias.

Si los dos primeros ejes acumulan una proporción importante, el gráfico CA1 vs CA2 resume una parte útil de la estructura.

5.2 PCoA: autovalores y proporción representada

```
cumsum(pcoa_bray$eig / sum(pcoa_bray$eig))
```

```
[1] 0.3026888 0.4895187 0.5844480 0.6644041 0.7306475 0.7857017  
0.8289621  
[8] 0.8587505 0.8857224 0.9100391 0.9324501 0.9492002 0.9650033  
0.9802720  
[15] 0.9886247 0.9946367 0.9989275 1.0000000 1.0000000 1.0000000
```

Estos valores permiten evaluar cuánto aporta cada eje del PCoA con Bray-Curtis.

No hace falta construir una tabla compleja. Lo importante es ver si los primeros ejes concentran buena parte de la estructura.

```
cumsum(pcoa_jacc$eig / sum(pcoa_jacc$eig))
```

```
[1] 0.2916418 0.4610831 0.5749192 0.6618131 0.7418205 0.7979191  
0.8460873  
[8] 0.8821098 0.9096548 0.9312529 0.9493813 0.9649869 0.9775055  
0.9856587  
[15] 0.9913318 0.9952041 0.9978171 1.0000000 1.0000000 1.0000000
```

Repetimos la lectura para PCoA con Jaccard.


Si Bray-Curtis y Jaccard muestran proporciones similares, ambos ordenamientos tienen una capacidad parecida de resumir la estructura en dos dimensiones. Si difieren mucho, hay que interpretarlos con cuidado.


5.3 NMDS: stress

```
nm.ds_bray$stress
```

```
[1] 0.1183186
```

```
stressplot(nm.ds_bray)
```





En NMDS, la medida principal de calidad es el **stress**.

El stress indica qué tan difícil fue representar en dos dimensiones el orden relativo de las disimilitudes originales.

Como regla práctica:


Stress	Interpretación orientativa
< 0.05	Excelente
0.05 - 0.10	Bueno
0.10 - 0.20	Aceptable, con cautela
> 0.20	Pobre o difícil de interpretar


El **stressplot** permite ver si las disimilitudes originales se relacionan de manera ordenada con las distancias del mapa NMDS.

```
nmds_jacc$stress
```

```
[1] 0.1067169
```

```
stressplot(nmds_jacc)
```





Revisamos también el stress para NMDS con Jaccard.

La comparación entre ambos valores ayuda a decidir qué disimilitud produjo una representación más confiable.

5.4 Comparación global de distancias

```
dist_pcoa_bray2 <- dist(scores_pcoa_bray)
dist_pcoa_jacc2 <- dist(scores_pcoa_jacc)
dist_nmds_bray2 <- dist(scores_nmds_bray)
dist_nmds_jacc2 <- dist(scores_nmds_jacc)
```

```
cor(as.vector(dist_bray), as.vector(dist_pcoa_bray2), method = "spearmanr")
```

```
[1] 0.9099555
```

```
cor(as.vector(dist_jacc), as.vector(dist_pcoa_jacc2), method = "spearmanr")
```

```
[1] 0.8520693
```

```
cor(as.vector(dist_bray), as.vector(dist_nmds_bray2), method = "spearmanr")
```

```
[1] 0.9528056
```

```
cor(as.vector(dist_jacc), as.vector(dist_nmds_jacc2), method = "spearmanr")
```

```
[1] 0.9498646
```

Estas correlaciones comparan el orden de las disimilitudes originales con el orden de las distancias en el mapa reducido.

No todos los métodos intentan conservar exactamente lo mismo, pero esta comparación ayuda a ver si la representación en dos dimensiones mantiene una estructura parecida a la original.

5.5 Decisión analítica final

Para **dune**, la decisión principal no es elegir un método por costumbre, sino elegir una disimilitud acorde a la pregunta.

Si queremos conservar información de abundancia, Bray-Curtis es la opción principal. Si queremos analizar solo composición en términos de presencia/ausencia, Jaccard es más adecuado.

Como método de ordenamiento, NMDS suele ser una opción fuerte para datos ecológicos porque no exige conservar distancias exactas y trabaja bien con disimilitudes como Bray-Curtis. PCoA es útil cuando queremos una representación más directa de una matriz de disimilitudes. CA es útil cuando queremos interpretar sitios y especies dentro de una lógica de correspondencias.

Para esta hoja de ruta, la decisión operativa sería:

- usar **NMDS con Bray-Curtis** como representación principal de la estructura de abundancias;
- usar **PCoA con Bray-Curtis** como contraste basado en distancias;
- usar **Jaccard** cuando la pregunta sea sobre presencia/ausencia;
- usar **CA** como análisis complementario para interpretar la asociación entre sitios y especies.

5.6 Cierre de la hoja de ruta

Esta hoja de ruta permitió recorrer un análisis multivariado con datos de abundancia sin comenzar directamente por los métodos.

Primero reconocimos la estructura del dataset. Luego preparamos distintas matrices según la pregunta. Después elegimos disimilitudes adecuadas para abundancias y presencia/ausencia. Recién entonces aplicamos métodos de ordenamiento y validamos sus representaciones.

La idea central es que en datos ecológicos la disimilitud elegida puede ser tan importante como el método de ordenamiento.

Por eso, antes de preguntar “¿uso PCoA o NMDS?”, conviene preguntar:

¿Qué significa que dos sitios sean parecidos en este análisis?