

MANOVA, permutaciones, ANOSIM, PERMDISP y Mantel

Resumen

En esta unidad, la dirección de la pregunta cambia respecto de clasificación.

En clasificación: variables medidas → grupo

En diferenciación: grupo → variables medidas

Por eso acá el grupo no es lo que queremos predecir. El grupo es la condición que usamos para preguntar si las variables respuesta cambian.

En la unidad anterior buscábamos formar grupos a partir de similitudes entre observaciones. En esta unidad ocurre algo distinto: los grupos ya están definidos y queremos evaluar si esos grupos se diferencian en otras variables.

Para evitar una comparación circular, conviene no usar las mismas variables para formar los grupos y para probar la diferencia. Por ejemplo, podemos agrupar personas según categorías de IMC, pero luego analizar si esos grupos difieren en valores de sangre.

La idea general de esta unidad es:

Tengo grupos definidos y quiero saber si esos grupos muestran diferencias.

MANOVA

MANOVA compara grupos usando varias variables respuesta al mismo tiempo. En vez de comparar una media por grupo, compara vectores de medias.

La hipótesis nula es:

Los vectores de medias son iguales entre grupos.

MANOVA queda como una rama histórica importante, pero en muchos análisis actuales fue desplazado por métodos basados en distancias y permutaciones, porque estos son más flexibles para trabajar con datos reales.

ANOSIM

En un ANOVA común tenemos:

un grupo → una variable respuesta

Por ejemplo, comparamos si la altura cambia entre tratamientos.

En análisis multivariado el problema es más complejo, porque tenemos:

un grupo → varias variables respuesta

Por ejemplo, podemos tener muchas especies medidas en cada sitio.

Entonces aparece una pregunta importante:

¿Cómo hacemos para representar muchas variables respuesta de una forma más simple?

Una solución es calcular una matriz de distancias o disimilitudes. Esa matriz resume qué tan distintos son los sitios entre sí considerando todas las variables juntas.

Cada distancia corresponde a un par de sitios. Según los grupos a los que pertenecen esos dos sitios, esa distancia puede ser:

- una distancia dentro del mismo grupo;
- una distancia entre grupos distintos.

ANOSIM trabaja con esa idea. Compara las distancias dentro de los grupos con las distancias entre grupos.

La hipótesis nula es:

Las distancias dentro y entre grupos no son diferentes.

Es decir, los grupos no están más separados de lo que esperaríamos si no hubiera una estructura clara.

Si las distancias dentro de los grupos son menores que las distancias entre grupos, entonces los sitios del mismo grupo se parecen más entre sí que a los sitios de otros grupos.

MRPP

Luego aparece otra idea importante: las permutaciones.

En vez de confiar en una distribución teórica, se mezclan las etiquetas de grupo muchas veces. Esto permite construir una referencia de azar.

La pregunta pasa a ser:

¿El resultado real es más fuerte que los resultados que aparecen cuando mezclamos los grupos al azar?

Con esta lógica, MRPP compara si los grupos reales son más compactos internamente que grupos armados al azar.

ANOSIM también usa permutaciones, pero MRPP ayuda a ver muy claro este razonamiento:

grupo real vs grupos mezclados al azar.

PERMANOVA

PERMANOVA combina dos ideas:

1. trabajar con distancias;
2. usar permutaciones.

Pero además agrega una lógica parecida al ANOVA.

PERMANOVA toma la diferencia total presente en la matriz de distancias y la separa en dos partes:

- una parte asociada al factor que estamos probando;
- una parte que queda sin explicar por ese factor.

Por eso aparece un R^2 . El R^2 indica qué proporción de las diferencias entre sitios queda asociada al factor.

Ejemplo ilustrativo

Tenemos 4 sitios y dos especies:

Sitio	Grupo	sp1	sp2
1	A	5	5
2	A	6	4
3	B	1	1
4	B	2	0

Calculamos distancias entre sitios:

distancia 1-2 = 1 dentro del grupo A
distancia 3-4 = 1 dentro del grupo B

distancia 1-3 = 6 entre A y B
distancia 1-4 = 7 entre A y B
distancia 2-3 = 5 entre A y B
distancia 2-4 = 6 entre A y B

Todas las distancias son:

1-2 = 1
1-3 = 6
1-4 = 7
2-3 = 5
2-4 = 6
3-4 = 1

Distancias dentro de los grupos:

1-2 = 1
3-4 = 1

Distancias entre grupos:

1-3 = 6
1-4 = 7
2-3 = 5
2-4 = 6

Entonces:

Dentro = 1 + 1 = 2

Entre = 6 + 7 + 5 + 6 = 24

Total = 1 + 6 + 7 + 5 + 6 + 1 = 26

En este ejemplo, gran parte de las diferencias aparecen cuando comparamos sitios de grupos distintos. Eso significa que el grupo ayuda mucho a entender las diferencias entre sitios.

Cálculo ilustrativo del R2:

R2 aproximado = diferencias entre grupos / total

R2 aproximado = 24 / 26 = 0.92

Esto indicaría que el grupo explica mucho de la diferencia total.

Este cálculo es solo para entender la idea. PERMANOVA real no suma distancias simples de esta manera, sino que trabaja con sumas de cuadrados calculadas a partir de la matriz de distancias.

PERMDISP

PERMDISP revisa la dispersión de los grupos.

Esto es necesario porque, cuando trabajamos con distancias, una diferencia entre grupos puede deberse a dos cosas distintas:

1. los grupos están en lugares diferentes;
2. un grupo está más desparramado que otro.

PERMDISP revisa justamente eso:

¿Los grupos tienen distinta dispersión interna?

La hipótesis nula es:

Los grupos tienen la misma dispersión.

Esto sirve como control, porque ANOSIM o PERMANOVA pueden mostrar diferencias entre grupos, pero parte de esa diferencia podría deberse a que un grupo está mucho más disperso que otro.

RRPP

RRPP es un método para ajustar modelos multivariados usando permutaciones.

La diferencia principal con ANOSIM, MRPP y PERMANOVA es que RRPP no parte directamente de una matriz de distancias. En RRPP volvemos a trabajar con las variables respuesta dentro de un modelo.

Por ejemplo, si tenemos sitios con varias especies:

sitio	grupo	sp1	sp2
1	A	5	4
2	A	6	5
3	B	1	2
4	B	2	1

La respuesta no es una sola variable, sino varias columnas juntas:

`sp1 + sp2`

Entonces RRPP ajusta un modelo parecido a un modelo lineal, pero con varias respuestas al mismo tiempo:

`sp1 + sp2 ~ grupo`

Una forma simple de pensarlo es:

`dato observado = parte explicada por el modelo + residuo`

El residuo es lo que el modelo no pudo explicar.

La idea importante es que RRPP no mezcla directamente las etiquetas de los grupos. Lo que mezcla son los residuos.

Pero hay un detalle clave: para probar si un factor importa, RRPP usa un modelo reducido y un modelo completo.

El modelo reducido es el modelo **sin el factor** que queremos probar.

El modelo completo es el modelo con el factor agregado.

Por ejemplo, si queremos probar si **grupo** ayuda a explicar la respuesta multivariada:

modelo reducido: `sp1 + sp2 ~ 1`

modelo completo: `sp1 + sp2 ~ grupo`

El modelo reducido solo usa una media general. No usa los grupos. Entonces representa la idea de que los grupos no importan.

RRPP toma los valores esperados por ese modelo reducido, mezcla sus residuos y vuelve a armar datos simulados:

`datos simulados = valores esperados del modelo reducido + residuos mezclados`

Después ajusta el modelo completo sobre esos datos simulados y calcula el estadístico de prueba. Repite este proceso muchas veces para construir una referencia de azar.

Finalmente compara:

resultado real del modelo completo
vs
resultados obtenidos con residuos mezclados

Si el resultado real es mucho más fuerte que los resultados simulados, el p-valor será bajo. En ese caso interpretamos que el grupo sí ayuda a explicar la respuesta multivariada.

Ejemplo ilustrativo

Supongamos una sola variable para simplificar la idea:

sitio	grupo	sp1
1	A	10
2	A	12
3	B	20
4	B	22

Queremos probar si **grupo** explica los valores de **sp1**.

El modelo completo sería:

$sp1 \sim grupo$

Pero para construir el azar, RRPP parte del modelo reducido:

$sp1 \sim 1$

Ese modelo reducido no usa los grupos. Solo calcula una media general:

$media\ general = (10 + 12 + 20 + 22) / 4 = 16$

Entonces los valores esperados por el modelo reducido son:

sitio	valor observado	valor esperado
1	10	16
2	12	16
3	20	16
4	22	16

Ahora calculamos los residuos:

$residuo = observado - esperado$

sitio	residuo
1	-6
2	-4
3	4
4	6

RRPP mezcla esos residuos. Por ejemplo:

residuos mezclados: 4, -6, 6, -4

Luego vuelve a armar datos simulados:

dato simulado = valor esperado + residuo mezclado

sitio	grupo	esperado	residuo mezclado	dato simulado
1	A	16	4	20
2	A	16	-6	10
3	B	16	6	22
4	B	16	-4	12

Con esta tabla simulada, RRPP vuelve a ajustar el modelo completo:

sp1_simulado ~ grupo

Y calcula cuánto parece explicar el grupo en esta tabla generada al azar.

Este proceso se repite muchas veces. Así se obtiene una distribución de resultados posibles si el grupo no tuviera un efecto real.

Luego se compara el resultado real contra esos resultados simulados.

Si el resultado real es mucho más fuerte que la mayoría de los resultados simulados, concluimos que el grupo ayuda a explicar la respuesta.

Idea final

RRPP ajusta modelos multivariados y evalúa los factores mezclando residuos de modelos reducidos.

En palabras simples:

1. Ajusta un modelo sin el factor que quiero probar.
2. Calcula lo que ese modelo no explicó.
3. Mezcla esa parte no explicada.
4. Rearma datos simulados.
5. Ajusta el modelo completo.
6. Compara el resultado real contra los resultados simulados.

La hipótesis nula general es:

El factor evaluado no ayuda a explicar las variables respuesta.


Si el p-valor es bajo, interpretamos que el factor sí aporta información para explicar la respuesta multivariada.

Recorrido general

ANOVA

|

└─ MANOVA



Mantel

Mantel compara dos matrices de distancia.

Pregunta:

¿Dos formas de medir distancia entre las mismas observaciones están relacionadas?

La hipótesis nula es:

No hay relación entre las dos matrices de distancia.

Por ejemplo, podemos comparar:

- distancia en composición de especies;
- distancia ambiental entre sitios.

Si Mantel da significativo, podemos decir que los sitios más parecidos ambientalmente también tienden a ser más parecidos en composición, o al revés.

Mantel parcial

Mantel parcial hace algo parecido, pero controlando una tercera matriz de distancia.

Pregunta:

¿La relación entre dos matrices se mantiene después de controlar una tercera?

La hipótesis nula es:

No hay relación entre las dos matrices después de controlar la tercera.

Por ejemplo, podríamos preguntar si la relación entre composición de especies y ambiente se mantiene después de controlar la distancia geográfica.

Paquetes

```
library(vegan)
```

Cargando paquete requerido: permute

```
library(mvShapiroTest)
library(biotools)
```

Cargando paquete requerido: MASS

biotools version 4.3

```
library(ggplot2)
library(MASS)
```

Repaso corto: ANOVA

Antes de MANOVA conviene recordar ANOVA. ANOVA compara si la media de una sola variable respuesta cambia entre grupos.

La forma mental es:

grupo -> una respuesta

Por ejemplo:

tratamiento -> altura

Ejemplo simple

```
datos <- data.frame(
  tratamiento = factor(c(
    rep("control", 5),
    rep("fertilizante_A", 5),
    rep("fertilizante_B", 5)
  )),
  altura = c(
```

```

    10, 11, 9, 10, 12,
    14, 15, 13, 14, 16,
    19, 20, 18, 21, 19
  )
)

datos

```

	tratamiento	altura
1	control	10
2	control	11
3	control	9
4	control	10
5	control	12
6	fertilizante_A	14
7	fertilizante_A	15
8	fertilizante_A	13
9	fertilizante_A	14
10	fertilizante_A	16
11	fertilizante_B	19
12	fertilizante_B	20
13	fertilizante_B	18
14	fertilizante_B	21
15	fertilizante_B	19

```
tapply(datos$altura, datos$tratamiento, mean)
```

control	fertilizante_A	fertilizante_B
10.4	14.4	19.4

```
tapply(datos$altura, datos$tratamiento, sd)
```


control	fertilizante_A	fertilizante_B
1.140175	1.140175	1.140175

```

boxplot(altura ~ tratamiento,
  data = datos,
  xlab = "Tratamiento",
  ylab = "Altura",
  main = "Altura según tratamiento")

```

Altura según tratamiento



ANOVA

Hipótesis:

H0: las medias de altura son iguales entre tratamientos.

H1: al menos una media es diferente.

Regla práctica:

$p < 0.05$ -> rechazo H0.

$p > 0.05$ -> no rechazo H0.

```
modelo_anova <- aov(altura ~ tratamiento, data = datos)
summary(modelo_anova)
```

```
          Df Sum Sq Mean Sq F value    Pr(>F)
tratamiento  2   203.3   101.7    78.2 1.31e-07 ***
Residuals   12    15.6     1.3
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interpretación:

El p-valor es muy bajo. Por lo tanto, se rechaza la hipótesis nula de igualdad de medias. Hay evidencia de que la altura promedio cambia entre tratamientos.

MANOVA

MANOVA es una extensión de ANOVA. La diferencia es que ahora no tenemos una respuesta, sino varias respuestas juntas.

La forma mental pasa a ser:

grupo -> varias respuestas

En este ejemplo con iris:

Species -> Sepal.Length + Sepal.Width + Petal.Length + Petal.Width

MANOVA compara **vectores de medias**. Un vector de medias es un conjunto de medias de varias variables.

Hipótesis global:

H0: los vectores de medias son iguales entre grupos.

H1: al menos un grupo tiene un vector de medias diferente.

MANOVA clásico tiene supuestos fuertes y fáciles de romper. Por eso sirve mucho para entender la lógica, pero en la práctica moderna suelen usarse métodos con distancias y permutaciones. Veamos el ejemplo:

Datos iris

```
data(iris)
head(iris)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa

```
Y <- as.matrix(iris[, 1:4])
grupos <- iris$Species

table(grupos)
```

```
grupos
      setosa versicolor  virginica
      50         50         50
```


Exploración inicial

```
aggregate(iris[, 1:4],
          by = list(especie = iris$Species),
          mean)
```

	especie	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
1	setosa	5.006	3.428	1.462	0.246
2	versicolor	5.936	2.770	4.260	1.326
3	virginica	6.588	2.974	5.552	2.026

```
pairs(iris[, 1:4],
      col = as.integer(iris$Species),
      pch = 19,
      main = "Iris: variables morfológicas por especie")

legend("topright",
      legend = levels(iris$Species),
      col = 1:3,
      pch = 19,
      bty = "n")
```



Supuesto 1: normalidad multivariada por grupo

Hipótesis del test:

H0: los datos del grupo siguen una normal multivariada.

H1: los datos del grupo no siguen una normal multivariada.

Regla:

$p < 0.05$ -> rechazo H0 -> hay evidencia de falta de normalidad multivariada.

$p > 0.05$ -> no rechazo H0 -> no hay evidencia suficiente contra normalidad.

```
mvShapiro.Test(as.matrix(Y[grupos == "setosa", ]))
```

Generalized Shapiro-Wilk test for Multivariate Normality by
Villasenor-Alva and Gonzalez-Estrada

```
data: as.matrix(Y[grupos == "setosa", ])
```

```
MVW = 0.96003, p-value = 0.01203
```

```
mvShapiro.Test(as.matrix(Y[grupos == "versicolor", ]))
```

Generalized Shapiro-Wilk test for Multivariate Normality by
Villasenor-Alva and Gonzalez-Estrada

```
data: as.matrix(Y[grupos == "versicolor", ])
```

```
MVW = 0.97415, p-value = 0.3183
```

```
mvShapiro.Test(as.matrix(Y[grupos == "virginica", ]))
```

Generalized Shapiro-Wilk test for Multivariate Normality by
Villasenor-Alva and Gonzalez-Estrada

```
data: as.matrix(Y[grupos == "virginica", ])
```

```
MVW = 0.98521, p-value = 0.9652
```

Setosa rechazó normalidad multivariada, mientras que versicolor y virginica no la rechazaron.

QQ-plot multivariado con Mahalanobis

Si los datos siguen una normal multivariada, las distancias de Mahalanobis deberían parecerse a cuantiles de una chi-cuadrado.




```
qq_mahalanobis <- function(X, titulo = "") {  
  centro <- colMeans(X)  
  S <- cov(X)  
  d2 <- mahalanobis(X, center = centro, cov = S)  
  q_teoricos <- qchisq(ppoints(nrow(X)), df = ncol(X))  
  plot(q_teoricos,  
       sort(d2),  
       pch = 19,  
       xlab = "Cuantiles teóricos chi-cuadrado",
```

```

    ylab = "Distancias de Mahalanobis ordenadas",
    main = titulo)
  abline(0, 1, lty = 2)
}

par(mfrow = c(1, 3))
qq_mahalanobis(Y[grupos == "setosa", ], "Setosa")
qq_mahalanobis(Y[grupos == "versicolor", ], "Versicolor")
qq_mahalanobis(Y[grupos == "virginica", ], "Virginica")

```



```
par(mfrow = c(1, 1))
```

Supuesto 2: homogeneidad de matrices de covarianza

Hipótesis de Box M:

H_0 : las matrices de covarianza son iguales entre grupos.

H_1 : al menos una matriz de covarianza difiere.

Regla:

$p < 0.05$ -> rechazo H_0 -> no hay homogeneidad de covarianzas.

$p > 0.05$ -> no rechazo H_0 .

```
boxM(Y, grupos)
```

Box's M-test for Homogeneity of Covariance Matrices

data: Y

Chi-Sq (approx.) = 140.94, df = 20, p-value < 2.2e-16

Las matrices de covarianza no son homogéneas entre especies.

IMOPORTANTE: si las matrices de covarianza son muy distintas, MANOVA puede mezclar diferencias de medias con diferencias de dispersión. Eso puede inflar el error tipo I.

Supuesto 3: independencia

Este supuesto no se resuelve con una función de R. Depende del diseño.

Pregunta práctica:

¿Cada observación es independiente de las demás?

Si hubiera medidas repetidas, bloques, parcelas o individuos relacionados, el modelo debería respetar esa estructura.

Ajuste del MANOVA

```
modelo_manova <- manova(Y ~ grupos)

summary(modelo_manova, test = "Wilks")
```

	Df	Wilks	approx F	num Df	den Df	Pr(>F)
grupos	2	0.023439	199.15	8	288	< 2.2e-16 ***
Residuals	147					

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1						

```
summary(modelo_manova, test = "Pillai")
```

	Df	Pillai	approx F	num Df	den Df	Pr(>F)
grupos	2	1.1919	53.466	8	290	< 2.2e-16 ***
Residuals	147					

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1						

```
summary(modelo_manova, test = "Hotelling")
```

	Df	Hotelling-Lawley	approx F	num Df	den Df	Pr(>F)
grupos	2	32.477	580.53	8	286	< 2.2e-16 ***
Residuals	147					

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
summary(modelo_manova, test = "Roy")
```

	Df	Roy approx F	num Df	den Df	Pr(>F)
grupos	2	32.192	1167	4	145 < 2.2e-16 ***
Residuals	147				

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Hipótesis en todos los estadísticos:

H0: los vectores de medias son iguales entre especies.

H1: los vectores de medias no son iguales entre especies.

Regla:

$p < 0.05$ -> rechazo H0 -> hay diferencia multivariada.

$p > 0.05$ -> no rechazo H0.

Wilks, Pillai, Hotelling-Lawley y Roy son formas distintas de resumir la separación multivariada. R los transforma a una F aproximada para calcular el p-valor.

En la práctica para este curso:

- mirar primero el p-valor;
- mirar F como apoyo dentro de cada prueba;
- si los supuestos fallan, darle más peso interpretativo a Pillai porque suele ser más robusta.

En iris, todos los estadísticos dan p-valores extremadamente bajos. La evidencia de diferencia multivariada entre especies es muy fuerte, aunque el MANOVA clásico debe interpretarse con cautela por la violación de supuestos.

Exploración posterior: ANOVAs por variable

Después del MANOVA global, podemos mirar qué variables aportan más a la diferencia.

```
summary.aov(modelo_manova)
```

Response Sepal.Length :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
grupos	2	63.212	31.606	119.26	< 2.2e-16 ***
Residuals	147	38.956	0.265		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Response Sepal.Width :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
grupos	2	11.345	5.6725	49.16	< 2.2e-16 ***
Residuals	147	16.962	0.1154		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Response Petal.Length :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
grupos	2	437.10	218.551	1180.2	< 2.2e-16 ***
Residuals	147	27.22	0.185		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Response Petal.Width :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
grupos	2	80.413	40.207	960.01	< 2.2e-16 ***
Residuals	147	6.157	0.042		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Hipótesis para cada ANOVA:

H0: la media de esa variable es igual entre especies.

H1: al menos una especie tiene media diferente en esa variable.

Esto ya no es MANOVA global. Son ANOVAs separados. Sirven para explorar, pero si se reportan formalmente hay que considerar comparaciones múltiples.

En iris, las variables del pétalo suelen mostrar los F más altos. Eso indica que **Petal.Length** y **Petal.Width** separan mucho más a las especies que las variables del sépal.

ANOSIM

ANOSIM cambia la lógica. Ya no compara vectores de medias. Ahora compara **distancias**.

Pregunta general:

¿Las observaciones del mismo grupo son más parecidas entre sí que las observaciones de grupos diferentes?

Hipótesis:

H0: no hay diferencia entre grupos; las distancias dentro y entre grupos no muestran separación.

H1: hay diferencia entre grupos; las distancias dentro de grupos tienden a ser menores que entre grupos.

Lectura del estadístico R:

R cerca de 0 -> no hay separación clara.

R positivo y alto -> mayor separación.

R cerca de 1 -> separación fuerte.

R negativo -> los grupos no están separados, o están más mezclados de lo esperable.

Regla con p-valor:

$p < 0.05$ -> rechazo H_0 .
 $p > 0.05$ -> no rechazo H_0 .

En pruebas de permutación, bajo H_0 las etiquetas son intercambiables. Se mezclan muchas veces, se recalcula el estadístico y se compara el valor real contra esa distribución de valores permutados.

Ejemplo 1: grupos simulados separados

```
set.seed(123)


X_sep <- rbind(
  mvrnorm(30, mu = c(0, 0), Sigma = diag(0.5, 2)),
  mvrnorm(30, mu = c(5, 5), Sigma = diag(0.5, 2)),
  mvrnorm(30, mu = c(0, 5), Sigma = diag(0.5, 2))
)

grupos_sim <- factor(rep(c("G1", "G2", "G3"), each = 30))


plot(X_sep,
     col = as.integer(grupos_sim),
     pch = 19,
     main = "Grupos simulados separados",
     xlab = "Variable 1",
     ylab = "Variable 2")

legend("bottomright",
     legend = levels(grupos_sim),
     col = 1:3,
     pch = 19,
     bty = "n")
```

Grupos simulados separados



```
dist_sep <- dist(X_sep, method = "euclidean")
anosim_sep <- anosim(dist_sep, grupos_sim, permutations = 999)
plot(anosim_sep, main = "ANOSIM: grupos separados")
```

ANOSIM: grupos separados

Interpretación esperada:

```
summary(anosim_sep)
```

Call:

```
anosim(x = dist_sep, grouping = grupos_sim, permutations = 999)
```

Dissimilarity: euclidean

ANOSIM statistic R: 0.9997

Significance: 0.001

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.0258	0.0396	0.0544	0.0696

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	1231	1980.75	2655.5	3330.25	4005	2700
G1	2	320.50	627.0	954.50	1337	435
G2	1	295.50	586.0	913.00	1355	435
G3	5	380.50	746.0	1060.50	1350	435

R muy alto y p bajo -> separación fuerte y significativa.

Ejemplo 2: grupos simulados solapados

```
set.seed(123)

X_sol <- rbind(
  mvrnorm(30, mu = c(0, 0), Sigma = diag(2.0, 2)),
  mvrnorm(30, mu = c(1, 1), Sigma = diag(2.0, 2)),
  mvrnorm(30, mu = c(0, 1), Sigma = diag(2.0, 2))
)

dist_sol <- dist(X_sol, method = "euclidean")
anosim_sol <- anosim(dist_sol, grupos_sim, permutations = 999)
summary(anosim_sol)
```

Call:

```
anosim(x = dist_sol, grouping = grupos_sim, permutations = 999)
```

Dissimilarity: euclidean

ANOSIM statistic R: 0.114

Significance: 0.001

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):


	90%	95%	97.5%	99%
	0.0189	0.0282	0.0358	0.0478

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	1	1076.5	2129.5	3079.25	4005	2700
G1	5	841.0	1703.0	2734.50	3964	435
G2	4	780.5	1575.0	2611.50	3980	435
G3	10	1020.5	2007.0	3101.00	3976	435


```
plot(X_sol,
     col = as.integer(grupos_sim),
     pch = 19,
     main = "Grupos solapados",
     xlab = "Variable 1",
     ylab = "Variable 2")
```

Grupos solapados



```
plot(anosim_sol, main = "ANOSIM: grupos solapados")
```

ANOSIM: grupos solapados



El aprendizaje clave es que el p-valor puede ser bajo aunque R sea bajo. En ese caso hay diferencia detectable, pero la separación es débil.

ANOSIM con datos reales: vegetación y pH

Usamos dos matrices del paquete **vegan**:

varespec -> sitios x especies

varechem -> sitios x variables ambientales

La pregunta será:

¿Los sitios de pH bajo y pH alto difieren en composición vegetal?

Cargar y explorar

```
data(varespec)
data(varechem)

head(varespec)
```

	Callvulg	Empenigr	Rhodontome	Vaccmyrt	Vaccviti	Pinusylv	Descflex	Betupube
18	0.55	11.13	0.00	0.00	17.80	0.07	0.00	0
15	0.67	0.17	0.00	0.35	12.13	0.12	0.00	0

24	0.10	1.55	0.00	0.00	13.47	0.25	0.00	0	
27	0.00	15.13	2.42	5.92	15.97	0.00	3.70	0	
23	0.00	12.68	0.00	0.00	23.73	0.03	0.00	0	
19	0.00	8.92	0.00	2.42	10.28	0.12	0.02	0	
Vacculig Diphcomp Dicrsp Dicrfusc Dicrpoly Hylosple Pleuschr Polypili									
18	1.60	2.07	0.00	1.62	0.00	0.0	4.67	0.02	
15	0.00	0.00	0.33	10.92	0.02	0.0	37.75	0.02	
24	0.00	0.00	23.43	0.00	1.68	0.0	32.92	0.00	
27	1.12	0.00	0.00	3.63	0.00	6.7	58.07	0.00	
23	0.00	0.00	0.00	3.42	0.02	0.0	19.42	0.02	
19	0.00	0.00	0.00	0.32	0.02	0.0	21.03	0.02	
Polyjuni Polycomm Pohlnuta Ptilcili Barbhatc Cladarbu Cladrang Cladstel									
18	0.13	0.00	0.13	0.12	0.00	21.73	21.47	3.50	
15	0.23	0.00	0.03	0.02	0.00	12.05	8.13	0.18	
24	0.23	0.00	0.32	0.03	0.00	3.58	5.52	0.07	
27	0.00	0.13	0.02	0.08	0.08	1.42	7.63	2.55	
23	2.12	0.00	0.17	1.80	0.02	9.08	9.22	0.05	
19	1.58	0.18	0.07	0.27	0.02	7.23	4.95	22.08	
Cladunci Cladcocc Cladcorn Cladgrac Cladfimb Cladcris Cladchlo Cladbotr									
18	0.30	0.18	0.23	0.25	0.25	0.23	0.00	0.00	
15	2.65	0.13	0.18	0.23	0.25	1.23	0.00	0.00	
24	8.93	0.00	0.20	0.48	0.00	0.07	0.10	0.02	
27	0.15	0.00	0.38	0.12	0.10	0.03	0.00	0.02	
23	0.73	0.08	1.42	0.50	0.17	1.78	0.05	0.05	
19	0.25	0.10	0.25	0.18	0.10	0.12	0.05	0.02	
Cladamau Cladsp Cetreric Cetrisla Flavniva Nepharct Stersp Peltapht Icmaeric									
18	0.08	0.02	0.02	0.00	0.12	0.02	0.62	0.02	0
15	0.00	0.00	0.15	0.03	0.00	0.00	0.85	0.00	0
24	0.00	0.00	0.78	0.12	0.00	0.00	0.03	0.00	0
27	0.00	0.02	0.00	0.00	0.00	0.00	0.00	0.07	0
23	0.00	0.00	0.00	0.00	0.02	0.00	1.58	0.33	0
19	0.00	0.00	0.00	0.00	0.02	0.00	0.28	0.00	0
Cladcerv Claddefo Cladphyl									
18	0	0.25	0						
15	0	1.00	0						
24	0	0.33	0						
27	0	0.15	0						
23	0	1.97	0						
19	0	0.37	0						

```
head(varechem)
```

	N	P	K	Ca	Mg	S	Al	Fe	Mn	Zn	Mo	Baresoil	Humdepth
18	19.8	42.1	139.9	519.4	90.0	32.3	39.0	40.9	58.1	4.5	0.3	43.9	2.2
15	13.4	39.1	167.3	356.7	70.7	35.2	88.1	39.0	52.4	5.4	0.3	23.6	2.2
24	20.2	67.7	207.1	973.3	209.1	58.1	138.0	35.4	32.1	16.8	0.8	21.2	2.0
27	20.6	60.8	233.7	834.0	127.2	40.7	15.4	4.4	132.0	10.7	0.2	18.7	2.9
23	23.8	54.5	180.6	777.0	125.8	39.5	24.2	3.0	50.1	6.6	0.3	46.0	3.0
19	22.8	40.9	171.4	691.8	151.4	40.8	104.8	17.6	43.6	9.1	0.4	40.5	3.8
pH													
18	2.7												
15	2.8												
24	3.0												

27 2.8
23 2.7
19 2.7

Antes de elegir una distancia, conviene mirar la estructura de la matriz de especies.

```
dim(varespec)
```

```
[1] 24 44
```

```
mean(varespec == 0)
```

```
[1] 0.4185606
```

```
summary(rowMeans(varespec == 0))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.2955	0.3864	0.4091	0.4186	0.4545	0.5909

```
summary(colMeans(varespec == 0))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.00000	0.07292	0.45833	0.41856	0.75000	0.87500

```
summary(rowSums(varespec))
```


Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
64.11	89.67	100.53	100.74	111.39	125.61

```
summary(colSums(varespec))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.100	1.812	5.830	54.948	23.655	486.710

```
hist(as.matrix(varespec),  
     main = "Distribución de abundancias/coberturas",  
     xlab = "Valor")
```

Distribución de abundancias/coberturas



Crear grupos por pH

```
varechem$grupo_pH <- ifelse(varechem$pH < median(varechem$pH),  
                             "pH_bajo",  
                             "pH_alto")  
  
varechem$grupo_pH <- factor(varechem$grupo_pH)  
  
table(varechem$grupo_pH)
```

```
pH_alto pH_bajo  
      14      10
```

Bray-Curtis

Para abundancia/cobertura de especies, Bray-Curtis suele ser una distancia adecuada.

```
dist_BC <- vegdist(varespec, method = "bray")  
  
anosim_BC <- anosim(dist_BC,  
                    varechem$grupo_pH,  
                    permutations = 999)
```

```
summary(anosim_BC)
```

Call:

```
anosim(x = dist_BC, grouping = varechem$grupo_pH, permutations = 999)
```

Dissimilarity: bray

ANOSIM statistic R: 0.1936

Significance: 0.013

Permutation: free

Number of permutations: 999


Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
0.0904	0.1258	0.1628	0.1952

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	11	83.5	157	214.75	276	140
pH_alto	1	54.5	136	212.50	271	91
pH_bajo	10	53.0	97	137.00	263	45

```
plot(anosim_BC, main = "ANOSIM Bray-Curtis: pH bajo vs alto")
```



Hipótesis:

H0: no hay diferencia en composición vegetal entre pH bajo y pH alto.

H1: hay diferencia en composición vegetal entre pH bajo y pH alto.

En la corrida revisada, Bray-Curtis detectó una diferencia significativa pero débil a moderada.

Comparación de distancias

Esta parte agrega una capa crítica: cambiar la distancia cambia la pregunta.

```
# 1. Bray-Curtis: abundancia/cobertura
# ya calculada como dist_BC

# 2. Jaccard: presencia-ausencia
varespec_pa <- decostand(varespec, method = "pa")
dist_jac <- vegdist(varespec_pa, method = "jaccard")

# 3. Hellinger + Euclidiana
varespec_hel <- decostand(varespec, method = "hellinger")
dist_hel <- dist(varespec_hel, method = "euclidean")

anosim_jac <- anosim(dist_jac,
                     varechem$grupo_pH,
                     permutations = 999)

anosim_hel <- anosim(dist_hel,
                     varechem$grupo_pH,
                     permutations = 999)

summary(anosim_BC)
```

Call:

```
anosim(x = dist_BC, grouping = varechem$grupo_pH, permutations = 999)
```

Dissimilarity: bray

ANOSIM statistic R: 0.1936

Significance: 0.013

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
0.0904	0.1258	0.1628	0.1952	

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	11	83.5	157	214.75	276	140
pH_alto	1	54.5	136	212.50	271	91
pH_bajo	10	53.0	97	137.00	263	45

```
summary(anosim_jac)
```

Call:

```
anosim(x = dist_jac, grouping = varechem$grupo_pH, permutations = 999)
```

Dissimilarity: jaccard

ANOSIM statistic R: -0.02868

Significance: 0.66

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.0839	0.1162	0.1387	0.1797

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	3	67.0	137	199.5	276	140
pH_alto	7	92.5	161	219.5	271	91
pH_bajo	1	56.5	101	173.5	267	45

```
summary(anosim_hel)
```

Call:

```
anosim(x = dist_hel, grouping = varechem$grupo_pH, permutations = 999)
```

Dissimilarity: euclidean

ANOSIM statistic R: 0.2485

Significance: 0.005

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.0852	0.1309	0.1715	0.2031

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	9	94.75	162	217.5	276	140
pH_alto	1	47.50	140	212.0	269	91
pH_bajo	7	53.00	82	123.0	257	45

```
tabla_anosim <- data.frame(
  distancia = c("Bray-Curtis", "Jaccard", "Hellinger + Euclidiana"),
  pregunta = c("abundancia/cobertura", "presencia-ausencia", "composición transformada"),
  R = c(anosim_BC$statistic,
        anosim_jac$statistic,
        anosim_hel$statistic),
  p_valor = c(anosim_BC$signif,
              anosim_jac$signif,
              anosim_hel$signif)
```

)

tabla_anosim

	distancia	pregunta	R	p_valor
1	Bray-Curtis	abundancia/cobertura	0.19359244	0.013
2	Jaccard	presencia-ausencia	-0.02867647	0.660
3	Hellinger + Euclidiana	composición transformada	0.24852941	0.005

Interpretación integrada:

Si Bray-Curtis y Hellinger dan significativo, pero Jaccard no, la diferencia no está tanto en qué especies aparecen, sino en cuánto pesan o abundan esas especies.

ANOSIM restringido por bloques de Al

Ahora usamos `strata`. Esto restringe las permutaciones dentro de bloques.

Hipótesis del ANOSIM restringido:

H0: dentro de bloques de Al, no hay diferencia de composición entre pH bajo y pH alto.

H1: dentro de bloques de Al, sí hay diferencia de composición entre pH bajo y pH alto.

El profe remarcó que esta idea viene de diseños con bloques: si hay una estructura que no conviene romper, las permutaciones deben respetarla. En este ejemplo, el bloqueo por Al es ficticio y se usa para mostrar el procedimiento.

```
varechem$bloque_Al <- cut(
  varechem$Al,
  breaks = quantile(varechem$Al,
                    probs = c(0, 1/3, 2/3, 1)),
  include.lowest = TRUE,
  labels = c("Al_bajo", "Al_medio", "Al_alto")
)
```

```
table(varechem$bloque_Al)
```

```
Al_bajo Al_medio Al_alto
      8       8       8
```

```
table(varechem$bloque_Al, varechem$grupo_pH)
```

```
      pH_alto pH_bajo
Al_bajo      3      5
Al_medio      4      4
Al_alto      7      1
```

```
anosim_restringido <- anosim(
  dist_BC,
  varechem$grupo_pH,
  strata = varechem$bloque_Al,
  permutations = 999
)

summary(anosim_restringido)
```

Call:

```
anosim(x = dist_BC, grouping = varechem$grupo_pH, permutations = 999, strata =
varechem$bloque_Al)
Dissimilarity: bray
```

ANOSIM statistic R: 0.1936
Significance: 0.086

Blocks: strata
Permutation: free
Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.180	0.241	0.296	0.345

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	11	83.5	157	214.75	276	140
pH_alto	1	54.5	136	212.50	271	91
pH_bajo	10	53.0	97	137.00	263	45

Si el ANOSIM libre es significativo pero el restringido deja de serlo, la evidencia por pH no es tan robusta al respetar la estructura asociada a Al.

Frase clave:

strata no cambia el R observado; cambia la distribución nula contra la que se compara ese R.

PERMDISP

PERMDISP revisa un supuesto importante de ANOSIM: que los grupos no tengan dispersiones multivariadas muy diferentes.

Hipótesis:

H0: los grupos tienen dispersión multivariada similar.
H1: los grupos tienen dispersión multivariada diferente.

Regla:

$p < 0.05$ -> rechazo H_0 -> cuidado, hay diferencias de dispersión.

$p > 0.05$ -> no rechazo H_0 -> no hay evidencia de dispersiones distintas.

```
permdisp <- betadisper(dist_BC, varechem$grupo_pH)
permutest(permdisp, permutations = 999)
```

Permutation test for homogeneity of multivariate dispersions

Permutation: free


Number of permutations: 999

Response: Distances

	Df	Sum Sq	Mean Sq	F	N.Perm	Pr(>F)
Groups	1	0.01184	0.011837	0.7847	999	0.384
Residuals	22	0.33185	0.015084			

```
plot(permdisp, main = "PERMDISP: dispersión según grupo de pH")
```

PERMDISP: dispersión según grupo de pH



En la corrida revisada, PERMDISP no fue significativo. Entonces la diferencia de ANOSIM con Bray-Curtis no parece deberse solo a que un grupo sea más disperso que el otro.

Mantel

Mantel compara dos matrices de distancia calculadas sobre las mismas unidades.

Pregunta general:

¿Dos formas de medir diferencias entre los mismos sitios están relacionadas?

En este ejemplo:

¿Los sitios ambientalmente más diferentes también son más diferentes en composición vegetal?

Hipótesis:

H0: no hay correlación entre la matriz de distancia biológica y la matriz de distancia ambiental.

H1: sí hay correlación entre ambas matrices.

Matriz biológica y matriz ambiental

```
dist_bio <- vegdist(varespec, method = "bray")

varechem_num <- varechem[, sapply(varechem, is.numeric)]
varechem_std <- scale(varechem_num)
dist_amb <- dist(varechem_std, method = "euclidean")
```

```
mantel_resultado <- mantel(dist_bio,
                           dist_amb,
                           method = "pearson",
                           permutations = 999)

mantel_resultado
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = dist_amb, method = "pearson", permutations = 999)
```

Mantel statistic r: 0.3047

Significance: 0.001

Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
0.107	0.145	0.177	0.210

Permutation: free

Number of permutations: 999

Interpretación:

$r > 0$ -> sitios más distintos ambientalmente tienden a ser más distintos biológicamente.

r cerca de 0 -> no hay relación clara.


$p < 0.05$ -> rechazo H0.

El profe aclaró que el gráfico de distancias sirve para visualizar, pero los puntos no son independientes: una misma observación participa en muchas distancias. Por eso usamos Mantel con permutaciones y no una regresión común como prueba principal.

```
df_mantel <- data.frame(
  dist_biológica = as.vector(dist_bio),
  dist_ambiental = as.vector(dist_amb)
)

ggplot(df_mantel, aes(x = dist_ambiental, y = dist_biológica)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = TRUE) +
  labs(
    x = "Distancia ambiental",
    y = "Distancia biológica",
    title = "Relación entre distancia ambiental y biológica"
  ) +
  theme_minimal()
```

`geom\_smooth()` using formula = 'y ~ x'



Mantel parcial

Mantel parcial controla una tercera matriz de distancia.

Pregunta:

¿La distancia ambiental se relaciona con la distancia biológica incluso después de controlar la distancia geográfica?

Hipótesis:

H0: no hay correlación entre distancia biológica y ambiental luego de controlar la tercera matriz.

H1: sí hay correlación parcial.

En este ejemplo, las coordenadas son simuladas. Entonces sirve para aprender el procedimiento, no para sacar una conclusión ecológica real sobre espacio.

```
set.seed(123)

coordenadas <- data.frame(
  x = runif(nrow(varespec), 0, 100),
  y = runif(nrow(varespec), 0, 100)
)

dist_geo <- dist(coordenadas, method = "euclidean")

mantel_parcial <- mantel.partial(
  dist_bio,
  dist_amb,
  dist_geo,
  method = "pearson",
  permutations = 999
)

mantel_parcial
```

Partial Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel.partial(xdis = dist_bio, ydis = dist_amb, zdis = dist_geo, method =
"pearson", permutations = 999)
```

Mantel statistic r: 0.3098

Significance: 0.001

Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
0.111	0.143	0.164	0.196

Permutation: free

Number of permutations: 999

Si Mantel estándar es significativo pero Mantel parcial no, la relación ambiente-comunidad podría estar explicada por estructura espacial. Si ambos son significativos, la relación se mantiene aun controlando la tercera matriz.

Mantel para validar dendrogramas

Otra aplicación de Mantel es comparar la matriz de distancia original con las distancias cofenéticas de un dendrograma.

La distancia cofenética entre dos objetos es la altura del árbol en la que se unen por primera vez.

Pregunta:

¿Qué dendrograma conserva mejor las distancias originales?

Hipótesis de Mantel en cada comparación:

H0: no hay correlación entre las distancias originales y las cofenéticas.

H1: sí hay correlación entre ambas matrices.

Para elegir entre dendrogramas, lo más útil es comparar el valor de r : mayor r significa mejor representación de la matriz original.

```
hclust_ward <- hclust(dist_bio, method = "ward.D2")
hclust_single <- hclust(dist_bio, method = "single")
hclust_average <- hclust(dist_bio, method = "average")

cofenetica_ward <- cophenetic(hclust_ward)
cofenetica_single <- cophenetic(hclust_single)
cofenetica_average <- cophenetic(hclust_average)

mantel_ward <- mantel(dist_bio,
                      as.dist(cofenetica_ward),
                      permutations = 999)

mantel_single <- mantel(dist_bio,
                       as.dist(cofenetica_single),
                       permutations = 999)

mantel_average <- mantel(dist_bio,
                        as.dist(cofenetica_average),
                        permutations = 999)

mantel_ward
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = as.dist(cofenetica_ward), permutations = 999)
```

Mantel statistic r : 0.7032

Significance: 0.001

Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
0.0708	0.1019	0.1455	0.1836

Permutation: free

Number of permutations: 999

```
mantel_single
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = as.dist(cofenetica_single), permutations = 999)
```

Mantel statistic r: 0.5306

Significance: 0.001

Upper quantiles of permutations (null model):

90% 95% 97.5% 99%

0.121 0.161 0.199 0.229

Permutation: free

Number of permutations: 999

```
mantel_average
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = as.dist(cofenetica_average), permutations = 999)
```

Mantel statistic r: 0.7606

Significance: 0.001

Upper quantiles of permutations (null model):

90% 95% 97.5% 99%

0.0722 0.1044 0.1320 0.1747

Permutation: free

Number of permutations: 999

```
tabla_dendro <- data.frame(
  metodo = c("Ward.D2", "Single", "Average"),
  r_mantel = c(mantel_ward$statistic,
               mantel_single$statistic,
               mantel_average$statistic),
  p_valor = c(mantel_ward$signif,
               mantel_single$signif,
               mantel_average$signif)
)

tabla_dendro
```

	metodo	r_mantel	p_valor
1	Ward.D2	0.7032459	0.001

2	Single	0.5306190	0.001
3	Average	0.7606220	0.001

En la corrida revisada, **average** tuvo el mayor r , seguido por Ward.D2, y **single** fue el más débil. Esto coincide con la advertencia del profe: single linkage suele representar peor la estructura global porque puede generar efecto cadena.

Cierre de la unidad

La unidad se puede resumir así:

MANOVA:

compara vectores de medias entre grupos.

ANOSIM:

compara distancias dentro vs entre grupos.

PERMDISP:

revisa si los grupos tienen dispersiones parecidas.

Mantel:

compara dos matrices de distancia.

Mantel parcial:

compara dos matrices controlando una tercera.

Mantel para dendrogramas:

compara distancias originales vs distancias del árbol.

La clave para no confundirse es escribir siempre:

1. ¿Cuál es la pregunta?
 2. ¿Cuál es H_0 ?
 3. ¿Qué estadístico miro?
 4. ¿Rechazo o no rechazo H_0 ?
 5. ¿Qué conclusión puedo escribir sin exagerar?
-

Ejercicios propuestos

Ejercicio 1: **crabs**

Dataset: **crabs** del paquete **MASS**. Tiene 200 cangrejos con 5 medidas morfológicas y dos factores: **sp** y **sex**.

1. Evaluar si existen diferencias multivariadas en las medidas morfológicas entre especies.
2. Revisar normalidad multivariada dentro de cada especie usando QQ-plots de Mahalanobis.
3. Repetir el MANOVA usando sexo como factor.
4. Correr ANOSIM para comparar las especies.

5. Revisar homogeneidad de dispersiones con `betadisper()`.
6. Probar una métrica alternativa y comparar el estadístico R.

Ejercicio 2: `mite`

Dataset: `mite` del paquete `vegan`. Contiene abundancias de ácaros en 70 sitios. `mite.xy` contiene coordenadas espaciales.

1. Calcular distancia geográfica y distancia biológica. Correr Mantel.
2. Visualizar la relación entre distancia geográfica y biológica.
3. Cargar `mite.env` y correr Mantel parcial: biología ~ ambiente | espacio.
4. Construir dendrogramas con `ward.D2`, `single` y `average`.
5. Comparar correlaciones cofenéticas usando distintas distancias.