

MANOVA, permutaciones, ANOSIM, PERMDISP y Mantel

Resumen

En la unidad anterior buscábamos formar grupos a partir de similitudes entre observaciones. En esta unidad los grupos ya están definidos y queremos evaluar si se diferencian en otras variables.

Para evitar una comparación circular, conviene no usar las mismas variables para formar los grupos y para probar la diferencia. Por ejemplo, podemos agrupar personas según categorías de IMC, pero luego analizar si esos grupos difieren en valores de sangre.

La idea general es:

Tengo grupos definidos y quiero saber si esos grupos muestran diferencias.

Cada método mira una diferencia distinta.

MANOVA compara grupos usando varias variables respuesta al mismo tiempo. Compara vectores de medias.

H0: los vectores de medias son iguales entre grupos.

ANOSIM trabaja con distancias.

Compara:

- distancias dentro de los grupos,
- distancias entre grupos.

H0: las distancias dentro y entre grupos no son diferentes.

PERMDISP revisa la dispersión de los grupos.

H0: los grupos tienen la misma dispersión.

Esto sirve como control, porque ANOSIM puede dar diferencia si un grupo está mucho más disperso que otro.

Mantel compara dos matrices de distancia.

Pregunta:

¿Dos formas de medir distancia entre las mismas observaciones están relacionadas?

H0: no hay relación entre las dos matrices de distancia.

Mantel parcial hace algo parecido, pero controlando una tercera matriz de distancia.

Pregunta:

¿La relación entre dos matrices se mantiene después de controlar una tercera?

H0: no hay relación entre las dos matrices después de controlar la tercera.

Muchas pruebas de esta unidad usan permutaciones. La idea es mezclar etiquetas muchas veces y comparar el resultado real contra esos resultados mezclados.

Si el p-valor es bajo, el resultado observado es raro bajo la hipótesis nula.

Si el p-valor es alto, no hay suficiente diferencia para rechazar la hipótesis nula.

La clave de la unidad es recordar qué compara cada prueba:

- MANOVA: medias.
 - ANOSIM: distancias dentro y entre grupos.
 - PERMDISP: dispersión.
 - Mantel: dos matrices de distancia.
 - Mantel parcial: dos matrices de distancia controlando una tercera.
-

Paquetes

```
library(vegan)
```

Cargando paquete requerido: permute

```
library(mvShapiroTest)
library(biotools)
```

Cargando paquete requerido: MASS

biotools version 4.3

```
library(ggplot2)
library(MASS)
```

Repaso corto: ANOVA

Antes de MANOVA conviene recordar ANOVA. ANOVA compara si la media de una sola variable respuesta cambia entre grupos.

La forma mental es:

grupo -> una respuesta

Por ejemplo:

tratamiento -> altura

Ejemplo simple

```
datos <- data.frame(  
  tratamiento = factor(c(  
    rep("control", 5),  
    rep("fertilizante_A", 5),  
    rep("fertilizante_B", 5)  
  )),  
  altura = c(  
    10, 11, 9, 10, 12,  
    14, 15, 13, 14, 16,  
    19, 20, 18, 21, 19  
  )  
)
```

datos

	tratamiento	altura
1	control	10
2	control	11
3	control	9
4	control	10
5	control	12
6	fertilizante_A	14
7	fertilizante_A	15
8	fertilizante_A	13
9	fertilizante_A	14
10	fertilizante_A	16
11	fertilizante_B	19
12	fertilizante_B	20
13	fertilizante_B	18
14	fertilizante_B	21
15	fertilizante_B	19

```
tapply(datos$altura, datos$tratamiento, mean)
```


control	fertilizante_A	fertilizante_B
10.4	14.4	19.4

```
tapply(datos$altura, datos$tratamiento, sd)
```

control	fertilizante_A	fertilizante_B
1.140175	1.140175	1.140175

```
boxplot(altura ~ tratamiento,  
  data = datos,  
  xlab = "Tratamiento",  
  ylab = "Altura",  
  main = "Altura según tratamiento")
```

Altura según tratamiento



ANOVA

Hipótesis:

H0: las medias de altura son iguales entre tratamientos.

H1: al menos una media es diferente.

Regla práctica:

$p < 0.05$ -> rechazo H0.

$p > 0.05$ -> no rechazo H0.

```
modelo_anova <- aov(altura ~ tratamiento, data = datos)
summary(modelo_anova)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
tratamiento	2	203.3	101.7	78.2	1.31e-07 ***
Residuals	12	15.6	1.3		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interpretación:

El p-valor es muy bajo. Por lo tanto, se rechaza la hipótesis nula de igualdad de medias. Hay evidencia de que la altura promedio cambia entre tratamientos.

MANOVA

MANOVA es una extensión de ANOVA. La diferencia es que ahora no tenemos una respuesta, sino varias respuestas juntas.

La forma mental pasa a ser:

grupo -> varias respuestas

En este ejemplo con iris:

Species -> Sepal.Length + Sepal.Width + Petal.Length + Petal.Width

MANOVA compara **vectores de medias**. Un vector de medias es un conjunto de medias de varias variables.

Hipótesis global:

H0: los vectores de medias son iguales entre grupos.

H1: al menos un grupo tiene un vector de medias diferente.

MANOVA clásico tiene supuestos fuertes y fáciles de romper. Por eso sirve mucho para entender la lógica, pero en la práctica moderna suelen usarse métodos con distancias y permutaciones. Veamos el ejemplo:

Datos iris

```
data(iris)
head(iris)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa

```
Y <- as.matrix(iris[, 1:4])
grupos <- iris$Species

table(grupos)
```

```
grupos
      setosa versicolor virginica
       50         50         50
```

Exploración inicial

```
aggregate(iris[, 1:4],
          by = list(especie = iris$Species),
```


```
mean)
```

	especie	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
1	setosa	5.006	3.428	1.462	0.246
2	versicolor	5.936	2.770	4.260	1.326
3	virginica	6.588	2.974	5.552	2.026

```
pairs(iris[, 1:4],
      col = as.integer(iris$Species),
      pch = 19,
      main = "Iris: variables morfológicas por especie")

legend("topright",
      legend = levels(iris$Species),
      col = 1:3,
      pch = 19,
      bty = "n")
```

Iris: variables morfológicas por especie



Supuesto 1: normalidad multivariada por grupo

Hipótesis del test:

- H_0 : los datos del grupo siguen una normal multivariada.
- H_1 : los datos del grupo no siguen una normal multivariada.

Regla:

$p < 0.05$ -> rechazo H_0 -> hay evidencia de falta de normalidad multivariada.
 $p > 0.05$ -> no rechazo H_0 -> no hay evidencia suficiente contra normalidad.

```
mvShapiro.Test(as.matrix(Y[grupos == "setosa", ]))
```

Generalized Shapiro-Wilk test for Multivariate Normality by
Villasenor-Alva and Gonzalez-Estrada

```
data: as.matrix(Y[grupos == "setosa", ])  
MVW = 0.96003, p-value = 0.01203
```

```
mvShapiro.Test(as.matrix(Y[grupos == "versicolor", ]))
```

Generalized Shapiro-Wilk test for Multivariate Normality by
Villasenor-Alva and Gonzalez-Estrada

```
data: as.matrix(Y[grupos == "versicolor", ])  
MVW = 0.97415, p-value = 0.3183
```

```
mvShapiro.Test(as.matrix(Y[grupos == "virginica", ]))
```

Generalized Shapiro-Wilk test for Multivariate Normality by
Villasenor-Alva and Gonzalez-Estrada

```
data: as.matrix(Y[grupos == "virginica", ])  
MVW = 0.98521, p-value = 0.9652
```


Setosa rechazó normalidad multivariada, mientras que versicolor y virginica no la rechazaron.

QQ-plot multivariado con Mahalanobis

Si los datos siguen una normal multivariada, las distancias de Mahalanobis deberían parecerse a cuantiles de una chi-cuadrado.

```
qq_mahalanobis <- function(X, titulo = "") {  
  centro <- colMeans(X)  
  S <- cov(X)  
  d2 <- mahalanobis(X, center = centro, cov = S)  
  q_teoricos <- qchisq(ppoints(nrow(X)), df = ncol(X))  
  plot(q_teoricos,  
       sort(d2),  
       pch = 19,  
       xlab = "Cuantiles teóricos chi-cuadrado",  
       ylab = "Distancias de Mahalanobis ordenadas",  
       main = titulo)  
  abline(0, 1, lty = 2)  
}  
  
par(mfrow = c(1, 3))  
qq_mahalanobis(Y[grupos == "setosa", ], "Setosa")
```

```
qq_mahalanobis(Y[grupos == "versicolor", ], "Versicolor")
qq_mahalanobis(Y[grupos == "virginica", ], "Virginica")
```



```
par(mfrow = c(1, 1))
```

Supuesto 2: homogeneidad de matrices de covarianza

Hipótesis de Box M:

H_0 : las matrices de covarianza son iguales entre grupos.

H_1 : al menos una matriz de covarianza difiere.

Regla:

$p < 0.05 \rightarrow$ rechazo $H_0 \rightarrow$ no hay homogeneidad de covarianzas.

$p > 0.05 \rightarrow$ no rechazo H_0 .

```
boxM(Y, grupos)
```

Box's M-test for Homogeneity of Covariance Matrices

data: Y

Chi-Sq (approx.) = 140.94, df = 20, p-value < 2.2e-16

Las matrices de covarianza no son homogéneas entre especies.

IMOPORTANTE: si las matrices de covarianza son muy distintas, MANOVA puede mezclar diferencias de medias con diferencias de dispersión. Eso puede inflar el error tipo I.

Supuesto 3: independencia

Este supuesto no se resuelve con una función de R. Depende del diseño.

Pregunta práctica:

¿Cada observación es independiente de las demás?

Si hubiera medidas repetidas, bloques, parcelas o individuos relacionados, el modelo debería respetar esa estructura.

Ajuste del MANOVA

```
modelo_manova <- manova(Y ~ grupos)

summary(modelo_manova, test = "Wilks")
```

```
              Df      Wilks approx F num Df den Df      Pr(>F)
grupos         2 0.023439   199.15      8    288 < 2.2e-16 ***
Residuals 147
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(modelo_manova, test = "Pillai")
```

```
              Df Pillai approx F num Df den Df      Pr(>F)
grupos         2 1.1919   53.466      8    290 < 2.2e-16 ***
Residuals 147
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(modelo_manova, test = "Hotelling")
```

```
              Df Hotelling-Lawley approx F num Df den Df      Pr(>F)
grupos         2      32.477   580.53      8    286 < 2.2e-16 ***
Residuals 147
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(modelo_manova, test = "Roy")
```

```
              Df      Roy approx F num Df den Df      Pr(>F)
grupos         2 32.192   1167      4    145 < 2.2e-16 ***
Residuals 147
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Hipótesis en todos los estadísticos:

H0: los vectores de medias son iguales entre especies.
H1: los vectores de medias no son iguales entre especies.

Regla:

$p < 0.05$ -> rechazo H0 -> hay diferencia multivariada.
 $p > 0.05$ -> no rechazo H0.

Wilks, Pillai, Hotelling-Lawley y Roy son formas distintas de resumir la separación multivariada. R los transforma a una F aproximada para calcular el p-valor.

En la práctica para este curso:

- mirar primero el p-valor;
- mirar F como apoyo dentro de cada prueba;
- si los supuestos fallan, darle más peso interpretativo a Pillai porque suele ser más robusta.

En iris, todos los estadísticos dan p-valores extremadamente bajos. La evidencia de diferencia multivariada entre especies es muy fuerte, aunque el MANOVA clásico debe interpretarse con cautela por la violación de supuestos.

Exploración posterior: ANOVAs por variable

Después del MANOVA global, podemos mirar qué variables aportan más a la diferencia.

```
summary.aov(modelo_manova)
```

```
Response Sepal.Length :
      Df Sum Sq Mean Sq F value    Pr(>F)
grupos    2  63.212   31.606  119.26 < 2.2e-16 ***
Residuals 147  38.956    0.265
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Response Sepal.Width :
      Df Sum Sq Mean Sq F value    Pr(>F)
grupos    2  11.345    5.6725   49.16 < 2.2e-16 ***
Residuals 147  16.962    0.1154
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Response Petal.Length :
      Df Sum Sq Mean Sq F value    Pr(>F)
grupos    2 437.10  218.551  1180.2 < 2.2e-16 ***
Residuals 147   27.22    0.185
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Response Petal.Width :
      Df Sum Sq Mean Sq F value    Pr(>F)
grupos    2  80.413   40.207  960.01 < 2.2e-16 ***
Residuals 147   6.157    0.042
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Hipótesis para cada ANOVA:

H0: la media de esa variable es igual entre especies.

H1: al menos una especie tiene media diferente en esa variable.

Esto ya no es MANOVA global. Son ANOVAs separados. Sirven para explorar, pero si se reportan formalmente hay que considerar comparaciones múltiples.

En iris, las variables del pétalo suelen mostrar los F más altos. Eso indica que `Petal.Length` y `Petal.Width` separan mucho más a las especies que las variables del sépalo.

ANOSIM

ANOSIM cambia la lógica. Ya no compara vectores de medias. Ahora compara **distancias**.

Pregunta general:

¿Las observaciones del mismo grupo son más parecidas entre sí que las observaciones de grupos diferentes?

Hipótesis:

H0: no hay diferencia entre grupos; las distancias dentro y entre grupos no muestran separación.

H1: hay diferencia entre grupos; las distancias dentro de grupos tienden a ser menores que entre grupos.

Lectura del estadístico R:

R cerca de 0 -> no hay separación clara.

R positivo y alto -> mayor separación.

R cerca de 1 -> separación fuerte.

R negativo -> los grupos no están separados, o están más mezclados de lo esperable.

Regla con p-valor:

$p < 0.05$ -> rechazo H0.

$p > 0.05$ -> no rechazo H0.

En pruebas de permutación, bajo H0 las etiquetas son intercambiables. Se mezclan muchas veces, se recalcula el estadístico y se compara el valor real contra esa distribución de valores permutados.

Ejemplo 1: grupos simulados separados

```
set.seed(123)

X_sep <- rbind(
  mvrnorm(30, mu = c(0, 0), Sigma = diag(0.5, 2)),
  mvrnorm(30, mu = c(5, 5), Sigma = diag(0.5, 2)),
  mvrnorm(30, mu = c(0, 5), Sigma = diag(0.5, 2))
)


grupos_sim <- factor(rep(c("G1", "G2", "G3"), each = 30))
```

```

plot(X_sep,
     col = as.integer(grupos_sim),
     pch = 19,
     main = "Grupos simulados separados",
     xlab = "Variable 1",
     ylab = "Variable 2")

legend("bottomright",
     legend = levels(grupos_sim),
     col = 1:3,
     pch = 19,
     bty = "n")

```




```

dist_sep <- dist(X_sep, method = "euclidean")
anosim_sep <- anosim(dist_sep, grupos_sim, permutations = 999)
plot(anosim_sep, main = "ANOSIM: grupos separados")

```

ANOSIM: grupos separados



Interpretación esperada:

```
summary(anosim_sep)
```

Call:

```
anosim(x = dist_sep, grouping = grupos_sim, permutations = 999)
```

Dissimilarity: euclidean

ANOSIM statistic R: 0.9997

Significance: 0.001

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.0258	0.0396	0.0544	0.0696

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	1231	1980.75	2655.5	3330.25	4005	2700
G1	2	320.50	627.0	954.50	1337	435
G2	1	295.50	586.0	913.00	1355	435
G3	5	380.50	746.0	1060.50	1350	435

R muy alto y p bajo -> separación fuerte y significativa.

Ejemplo 2: grupos simulados solapados

```
set.seed(123)

X_sol <- rbind(
  mvrnorm(30, mu = c(0, 0), Sigma = diag(2.0, 2)),
  mvrnorm(30, mu = c(1, 1), Sigma = diag(2.0, 2)),
  mvrnorm(30, mu = c(0, 1), Sigma = diag(2.0, 2))
)

dist_sol <- dist(X_sol, method = "euclidean")
anosim_sol <- anosim(dist_sol, grupos_sim, permutations = 999)
summary(anosim_sol)
```

Call:

```
anosim(x = dist_sol, grouping = grupos_sim, permutations = 999)
```

Dissimilarity: euclidean

ANOSIM statistic R: 0.114

Significance: 0.001

Permutation: free

Number of permutations: 999

Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
-----	-----	-------	-----


0.0189	0.0282	0.0358	0.0478
--------	--------	--------	--------

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	1	1076.5	2129.5	3079.25	4005	2700
G1	5	841.0	1703.0	2734.50	3964	435
G2	4	780.5	1575.0	2611.50	3980	435
G3	10	1020.5	2007.0	3101.00	3976	435

```
plot(X_sol,
     col = as.integer(grupos_sim),
     pch = 19,
     main = "Grupos solapados",
     xlab = "Variable 1",
     ylab = "Variable 2")
```


Grupos solapados



```
plot(anosim_sol, main = "ANOSIM: grupos solapados")
```

ANOSIM: grupos solapados

R = 0.114 , P = 0.001



El aprendizaje clave es que el p-valor puede ser bajo aunque R sea bajo. En ese caso hay diferencia detectable, pero la separación es débil.

ANOSIM con datos reales: vegetación y pH

Usamos dos matrices del paquete `vegan`:

`varespec` -> sitios x especies
`varechem` -> sitios x variables ambientales

La pregunta será:

¿Los sitios de pH bajo y pH alto difieren en composición vegetal?

Cargar y explorar

```
data(varespec)
data(varechem)

head(varespec)
```

	Callvulg	Empenigr	Rhodontome	Vaccmyrt	Vaccviti	Pinusylv	Descflex	Betupube	
18	0.55	11.13	0.00	0.00	17.80	0.07	0.00	0	
15	0.67	0.17	0.00	0.35	12.13	0.12	0.00	0	
24	0.10	1.55	0.00	0.00	13.47	0.25	0.00	0	
27	0.00	15.13	2.42	5.92	15.97	0.00	3.70	0	
23	0.00	12.68	0.00	0.00	23.73	0.03	0.00	0	
19	0.00	8.92	0.00	2.42	10.28	0.12	0.02	0	
	Vacculig	Diphcomp	Dicrsp	Dicrfusc	Dicrpoly	Hylosple	Pleuschr	Polypili	
18	1.60	2.07	0.00	1.62	0.00	0.0	4.67	0.02	
15	0.00	0.00	0.33	10.92	0.02	0.0	37.75	0.02	
24	0.00	0.00	23.43	0.00	1.68	0.0	32.92	0.00	
27	1.12	0.00	0.00	3.63	0.00	6.7	58.07	0.00	
23	0.00	0.00	0.00	3.42	0.02	0.0	19.42	0.02	
19	0.00	0.00	0.00	0.32	0.02	0.0	21.03	0.02	
	Polyjuni	Polycomm	Pohnluta	Ptilcili	Barbhatc	Cladarbu	Cladrang	Cladstel	
18	0.13	0.00	0.13	0.12	0.00	21.73	21.47	3.50	
15	0.23	0.00	0.03	0.02	0.00	12.05	8.13	0.18	
24	0.23	0.00	0.32	0.03	0.00	3.58	5.52	0.07	
27	0.00	0.13	0.02	0.08	0.08	1.42	7.63	2.55	
23	2.12	0.00	0.17	1.80	0.02	9.08	9.22	0.05	
19	1.58	0.18	0.07	0.27	0.02	7.23	4.95	22.08	
	Cladunci	Cladcocc	Cladcorn	Cladgrac	Cladfimb	Cladcris	Cladchlo	Cladbotr	
18	0.30	0.18	0.23	0.25	0.25	0.23	0.00	0.00	
15	2.65	0.13	0.18	0.23	0.25	1.23	0.00	0.00	
24	8.93	0.00	0.20	0.48	0.00	0.07	0.10	0.02	
27	0.15	0.00	0.38	0.12	0.10	0.03	0.00	0.02	
23	0.73	0.08	1.42	0.50	0.17	1.78	0.05	0.05	
19	0.25	0.10	0.25	0.18	0.10	0.12	0.05	0.02	
	Cladamau	Cladsp	Cetreric	Cetrisla	Flavniva	Nepharct	Sterisp	Peltapht	Icmaeric
18	0.08	0.02	0.02	0.00	0.12	0.02	0.62	0.02	0
15	0.00	0.00	0.15	0.03	0.00	0.00	0.85	0.00	0

24	0.00	0.00	0.78	0.12	0.00	0.00	0.03	0.00	0
27	0.00	0.02	0.00	0.00	0.00	0.00	0.00	0.07	0
23	0.00	0.00	0.00	0.00	0.02	0.00	1.58	0.33	0
19	0.00	0.00	0.00	0.00	0.02	0.00	0.28	0.00	0

	Cladcerv	Claddefo	Cladphyl
18	0	0.25	0
15	0	1.00	0
24	0	0.33	0
27	0	0.15	0
23	0	1.97	0
19	0	0.37	0

head(varechem)

	N	P	K	Ca	Mg	S	Al	Fe	Mn	Zn	Mo	Baresoil	Humdepth
18	19.8	42.1	139.9	519.4	90.0	32.3	39.0	40.9	58.1	4.5	0.3	43.9	2.2
15	13.4	39.1	167.3	356.7	70.7	35.2	88.1	39.0	52.4	5.4	0.3	23.6	2.2
24	20.2	67.7	207.1	973.3	209.1	58.1	138.0	35.4	32.1	16.8	0.8	21.2	2.0
27	20.6	60.8	233.7	834.0	127.2	40.7	15.4	4.4	132.0	10.7	0.2	18.7	2.9
23	23.8	54.5	180.6	777.0	125.8	39.5	24.2	3.0	50.1	6.6	0.3	46.0	3.0
19	22.8	40.9	171.4	691.8	151.4	40.8	104.8	17.6	43.6	9.1	0.4	40.5	3.8

pH

18	2.7
15	2.8
24	3.0
27	2.8
23	2.7
19	2.7

Antes de elegir una distancia, conviene mirar la estructura de la matriz de especies.

dim(varespec)

[1] 24 44

mean(varespec == 0)

[1] 0.4185606

summary(rowMeans(varespec == 0))

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.2955	0.3864	0.4091	0.4186	0.4545	0.5909

summary(colMeans(varespec == 0))

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.00000	0.07292	0.45833	0.41856	0.75000	0.87500

summary(rowSums(varespec))


Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
64.11	89.67	100.53	100.74	111.39	125.61

```
summary(colSums(varespec))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.100	1.812	5.830	54.948	23.655	486.710

```
hist(as.matrix(varespec),  
     main = "Distribución de abundancias/coberturas",  
     xlab = "Valor")
```

Distribución de abundancias/coberturas



Crear grupos por pH

```
varechem$grupo_pH <- ifelse(varechem$pH < median(varechem$pH),  
                             "pH_bajo",  
                             "pH_alto")  
  
varechem$grupo_pH <- factor(varechem$grupo_pH)  
  
table(varechem$grupo_pH)
```

pH_alto	pH_bajo
14	10

Bray-Curtis

Para abundancia/coertura de especies, Bray-Curtis suele ser una distancia adecuada.

```
dist_BC <- vegdist(varespec, method = "bray")

anosim_BC <- anosim(dist_BC,
                    varechem$grupo_pH,
                    permutations = 999)

summary(anosim_BC)
```

Call:

```
anosim(x = dist_BC, grouping = varechem$grupo_pH, permutations = 999)
Dissimilarity: bray
```

```
ANOSIM statistic R: 0.1936
Significance: 0.013
```

```
Permutation: free
Number of permutations: 999
```

Upper quantiles of permutations (null model):


	90%	95%	97.5%	99%
	0.0904	0.1258	0.1628	0.1952

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	11	83.5	157	214.75	276	140
pH_alto	1	54.5	136	212.50	271	91
pH_bajo	10	53.0	97	137.00	263	45

```
plot(anosim_BC, main = "ANOSIM Bray-Curtis: pH bajo vs alto")
```

ANOSIM Bray-Curtis: pH bajo vs alto



Hipótesis:

H0: no hay diferencia en composición vegetal entre pH bajo y pH alto.

H1: hay diferencia en composición vegetal entre pH bajo y pH alto.

En la corrida revisada, Bray-Curtis detectó una diferencia significativa pero débil a moderada.

Comparación de distancias

Esta parte agrega una capa crítica: cambiar la distancia cambia la pregunta.

```
# 1. Bray-Curtis: abundancia/cobertura
# ya calculada como dist_BC

# 2. Jaccard: presencia-ausencia
varespec_pa <- decostand(varespec, method = "pa")
dist_jac <- vegdist(varespec_pa, method = "jaccard")

# 3. Hellinger + Euclidiana
varespec_hel <- decostand(varespec, method = "hellinger")
dist_hel <- dist(varespec_hel, method = "euclidean")

anosim_jac <- anosim(dist_jac,
                     varechem$grupo_pH,
                     permutations = 999)

anosim_hel <- anosim(dist_hel,
                     varechem$grupo_pH,
```

```
permutations = 999)
```

```
summary(anosim_BC)
```

Call:

```
anosim(x = dist_BC, grouping = varechem$grupo_pH, permutations = 999)
Dissimilarity: bray
```

```
ANOSIM statistic R: 0.1936
Significance: 0.013
```

```
Permutation: free
Number of permutations: 999
```

Upper quantiles of permutations (null model):

```
 90%   95%  97.5%   99%
0.0904 0.1258 0.1628 0.1952
```

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	11	83.5	157	214.75	276	140
pH_alto	1	54.5	136	212.50	271	91
pH_bajo	10	53.0	97	137.00	263	45

```
summary(anosim_jac)
```

Call:

```
anosim(x = dist_jac, grouping = varechem$grupo_pH, permutations = 999)
Dissimilarity: jaccard
```

```
ANOSIM statistic R: -0.02868
Significance: 0.66
```

```
Permutation: free
Number of permutations: 999
```

Upper quantiles of permutations (null model):

```
 90%   95%  97.5%   99%
0.0839 0.1162 0.1387 0.1797
```

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	3	67.0	137	199.5	276	140
pH_alto	7	92.5	161	219.5	271	91
pH_bajo	1	56.5	101	173.5	267	45

```
summary(anosim_hel)
```

Call:

```
anosim(x = dist_hel, grouping = varechem$grupo_pH, permutations = 999)
Dissimilarity: euclidean
```

ANOSIM statistic R: 0.2485
Significance: 0.005

Permutation: free
Number of permutations: 999

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.0852	0.1309	0.1715	0.2031

Dissimilarity ranks between and within classes:

	0%	25%	50%	75%	100%	N
Between	9	94.75	162	217.5	276	140
pH_alto	1	47.50	140	212.0	269	91
pH_bajo	7	53.00	82	123.0	257	45

```
tabla_anosim <- data.frame(  
  distancia = c("Bray-Curtis", "Jaccard", "Hellinger + Euclidiana"),  
  pregunta = c("abundancia/cobertura", "presencia-ausencia", "composición transformada"),  
  R = c(anosim_BC$statistic,  
        anosim_jac$statistic,  
        anosim_hel$statistic),  
  p_valor = c(anosim_BC$signif,  
              anosim_jac$signif,  
              anosim_hel$signif)  
)  
  
tabla_anosim
```

	distancia	pregunta	R	p_valor
1	Bray-Curtis	abundancia/cobertura	0.19359244	0.013
2	Jaccard	presencia-ausencia	-0.02867647	0.660
3	Hellinger + Euclidiana	composición transformada	0.24852941	0.005

Interpretación integrada:

Si Bray-Curtis y Hellinger dan significativo, pero Jaccard no, la diferencia no está tanto en qué especies aparecen, sino en cuánto pesan o abundan esas especies.

ANOSIM restringido por bloques de Al

Ahora usamos `strata`. Esto restringe las permutaciones dentro de bloques.

Hipótesis del ANOSIM restringido:

H0: dentro de bloques de Al, no hay diferencia de composición entre pH bajo y pH alto.
H1: dentro de bloques de Al, sí hay diferencia de composición entre pH bajo y pH alto.

El profe remarcó que esta idea viene de diseños con bloques: si hay una estructura que no conviene romper, las permutaciones deben respetarla. En este ejemplo, el bloqueo por Al es ficticio y se usa para mostrar el procedimiento.

```
varechem$bloque_Al <- cut(
  varechem$Al,
  breaks = quantile(varechem$Al,
                    probs = c(0, 1/3, 2/3, 1)),
  include.lowest = TRUE,
  labels = c("Al_bajo", "Al_medio", "Al_alto")
)

table(varechem$bloque_Al)
```

```
Al_bajo Al_medio Al_alto
      8      8      8
```

```
table(varechem$bloque_Al, varechem$grupo_pH)
```

```
      pH_alto pH_bajo
Al_bajo      3      5
Al_medio      4      4
Al_alto      7      1
```

```
anosim_restringido <- anosim(
  dist_BC,
  varechem$grupo_pH,
  strata = varechem$bloque_Al,
  permutations = 999
)

summary(anosim_restringido)
```

Call:

```
anosim(x = dist_BC, grouping = varechem$grupo_pH, permutations = 999, strata =
varechem$bloque_Al)
Dissimilarity: bray
```

```
ANOSIM statistic R: 0.1936
Significance: 0.086
```

```
Blocks: strata
Permutation: free
Number of permutations: 999
```

```
Upper quantiles of permutations (null model):
 90%  95% 97.5% 99%
0.180 0.241 0.296 0.345
```

```
Dissimilarity ranks between and within classes:
      0%  25% 50%   75% 100%  N
Between 11 83.5 157 214.75 276 140
pH_alto  1 54.5 136 212.50 271  91
pH_bajo 10 53.0  97 137.00 263  45
```

Si el ANOSIM libre es significativo pero el restringido deja de serlo, la evidencia por pH no es tan robusta al respetar la estructura asociada a Al.

Frase clave:

strata no cambia el R observado; cambia la distribución nula contra la que se compara ese R.

PERMDISP

PERMDISP revisa un supuesto importante de ANOSIM: que los grupos no tengan dispersiones multivariadas muy diferentes.

Hipótesis:

H0: los grupos tienen dispersión multivariada similar.

H1: los grupos tienen dispersión multivariada diferente.

Regla:

$p < 0.05$ -> rechazo H0 -> cuidado, hay diferencias de dispersión.

$p > 0.05$ -> no rechazo H0 -> no hay evidencia de dispersiones distintas.

```
permdisp <- betadisper(dist_BC, varechem$grupo_pH)
permutest(permdisp, permutations = 999)
```

Permutation test for homogeneity of multivariate dispersions

Permutation: free


Number of permutations: 999

Response: Distances

	Df	Sum Sq	Mean Sq	F	N.Perm	Pr(>F)
Groups	1	0.01184	0.011837	0.7847	999	0.384
Residuals	22	0.33185	0.015084			

```
plot(permdisp, main = "PERMDISP: dispersión según grupo de pH")
```


PERMDISP: dispersión según grupo de pH



En la corrida revisada, PERMDISP no fue significativo. Entonces la diferencia de ANOSIM con Bray-Curtis no parece deberse solo a que un grupo sea más disperso que el otro.

Mantel

Mantel compara dos matrices de distancia calculadas sobre las mismas unidades.

Pregunta general:

¿Dos formas de medir diferencias entre los mismos sitios están relacionadas?

En este ejemplo:

¿Los sitios ambientalmente más diferentes también son más diferentes en composición vegetal?

Hipótesis:

H0: no hay correlación entre la matriz de distancia biológica y la matriz de distancia ambiental.

H1: sí hay correlación entre ambas matrices.

Matriz biológica y matriz ambiental

```
dist_bio <- vegdist(varespec, method = "bray")
```

```
varechem_num <- varechem[, sapply(varechem, is.numeric)]
varechem_std <- scale(varechem_num)
dist_amb <- dist(varechem_std, method = "euclidean")
```

```
mantel_resultado <- mantel(dist_bio,
                           dist_amb,
                           method = "pearson",
                           permutations = 999)
```

```
mantel_resultado
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = dist_amb, method = "pearson", permutations = 999)
```

Mantel statistic r: 0.3047

Significance: 0.001

Upper quantiles of permutations (null model):

```
 90%   95% 97.5%   99%
0.107 0.145 0.177 0.210
```

Permutation: free

Number of permutations: 999

Interpretación:

$r > 0$ -> sitios más distintos ambientalmente tienden a ser más distintos biológicamente.

r cerca de 0 -> no hay relación clara.

$p < 0.05$ -> rechazo H_0 .


El profe aclaró que el gráfico de distancias sirve para visualizar, pero los puntos no son independientes: una misma observación participa en muchas distancias. Por eso usamos Mantel con permutaciones y no una regresión común como prueba principal.

```
df_mantel <- data.frame(
  dist_biológica = as.vector(dist_bio),
  dist_ambiental = as.vector(dist_amb)
)

ggplot(df_mantel, aes(x = dist_ambiental, y = dist_biológica)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = TRUE) +
  labs(
    x = "Distancia ambiental",
    y = "Distancia biológica",
    title = "Relación entre distancia ambiental y biológica"
  ) +
  theme_minimal()
```

`geom\_smooth()` using formula = 'y ~ x'

Relación entre distancia ambiental y biológica



Mantel parcial

Mantel parcial controla una tercera matriz de distancia.

Pregunta:

¿La distancia ambiental se relaciona con la distancia biológica incluso después de controlar la distancia geográfica?

Hipótesis:

H0: no hay correlación entre distancia biológica y ambiental luego de controlar la tercera matriz.

H1: sí hay correlación parcial.

En este ejemplo, las coordenadas son simuladas. Entonces sirve para aprender el procedimiento, no para sacar una conclusión ecológica real sobre espacio.

```
set.seed(123)

coordenadas <- data.frame(
  x = runif(nrow(varespec), 0, 100),
  y = runif(nrow(varespec), 0, 100)
)

dist_geo <- dist(coordenadas, method = "euclidean")
```

```
mantel_parcial <- mantel.partial(  
  dist_bio,  
  dist_amb,  
  dist_geo,  
  method = "pearson",  
  permutations = 999  
)  
  
mantel_parcial
```

Partial Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel.partial(xdis = dist_bio, ydis = dist_amb, zdis = dist_geo, method = "pearson",  
permutations = 999)
```

Mantel statistic r: 0.3098

Significance: 0.001

Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
0.111	0.143	0.164	0.196

Permutation: free

Number of permutations: 999

Si Mantel estándar es significativo pero Mantel parcial no, la relación ambiente-comunidad podría estar explicada por estructura espacial. Si ambos son significativos, la relación se mantiene aun controlando la tercera matriz.

Mantel para validar dendrogramas

Otra aplicación de Mantel es comparar la matriz de distancia original con las distancias cofenéticas de un dendrograma.

La distancia cofenética entre dos objetos es la altura del árbol en la que se unen por primera vez.

Pregunta:

¿Qué dendrograma conserva mejor las distancias originales?

Hipótesis de Mantel en cada comparación:

H0: no hay correlación entre las distancias originales y las cofenéticas.

H1: sí hay correlación entre ambas matrices.

Para elegir entre dendrogramas, lo más útil es comparar el valor de r : mayor r significa mejor representación de la matriz original.

```
hclust_ward <- hclust(dist_bio, method = "ward.D2")  
hclust_single <- hclust(dist_bio, method = "single")  
hclust_average <- hclust(dist_bio, method = "average")
```

```

cofenetica_ward <- cophenetic(hclust_ward)
cofenetica_single <- cophenetic(hclust_single)
cofenetica_average <- cophenetic(hclust_average)

mantel_ward <- mantel(dist_bio,
                      as.dist(cofenetica_ward),
                      permutations = 999)

mantel_single <- mantel(dist_bio,
                       as.dist(cofenetica_single),
                       permutations = 999)

mantel_average <- mantel(dist_bio,
                        as.dist(cofenetica_average),
                        permutations = 999)

mantel_ward

```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = as.dist(cofenetica_ward), permutations = 999)
```

Mantel statistic r: 0.7032

Significance: 0.001

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.0708	0.1019	0.1455	0.1836

Permutation: free

Number of permutations: 999

```
mantel_single
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = as.dist(cofenetica_single), permutations = 999)
```

Mantel statistic r: 0.5306

Significance: 0.001

Upper quantiles of permutations (null model):

	90%	95%	97.5%	99%
	0.121	0.161	0.199	0.229

Permutation: free

Number of permutations: 999

```
mantel_average
```

Mantel statistic based on Pearson's product-moment correlation

Call:

```
mantel(xdis = dist_bio, ydis = as.dist(cofenetica_average), permutations = 999)
```

Mantel statistic r: 0.7606

Significance: 0.001

Upper quantiles of permutations (null model):

90%	95%	97.5%	99%
0.0722	0.1044	0.1320	0.1747

Permutation: free

Number of permutations: 999

```
tabla_dendro <- data.frame(  
  metodo = c("Ward.D2", "Single", "Average"),  
  r_mantel = c(mantel_ward$statistic,  
               mantel_single$statistic,  
               mantel_average$statistic),  
  p_valor = c(mantel_ward$signif,  
              mantel_single$signif,  
              mantel_average$signif)  
)
```

tabla_dendro

	metodo	r_mantel	p_valor
1	Ward.D2	0.7032459	0.001
2	Single	0.5306190	0.001
3	Average	0.7606220	0.001

En la corrida revisada, **average** tuvo el mayor r, seguido por Ward.D2, y **single** fue el más débil. Esto coincide con la advertencia del profe: single linkage suele representar peor la estructura global porque puede generar efecto cadena.

Cierre de la unidad

La unidad se puede resumir así:

MANOVA:

compara vectores de medias entre grupos.

ANOSIM:

compara distancias dentro vs entre grupos.

PERMDISP:

revisa si los grupos tienen dispersiones parecidas.

Mantel:

compara dos matrices de distancia.

Mantel parcial:

compara dos matrices controlando una tercera.

Mantel para dendrogramas:
compara distancias originales vs distancias del árbol.

La clave para no confundirse es escribir siempre:

1. ¿Cuál es la pregunta?
 2. ¿Cuál es H_0 ?
 3. ¿Qué estadístico miro?
 4. ¿Rechazo o no rechazo H_0 ?
 5. ¿Qué conclusión puedo escribir sin exagerar?
-

Ejercicios propuestos

Ejercicio 1: `crabs`

Dataset: `crabs` del paquete `MASS`. Tiene 200 cangrejos con 5 medidas morfológicas y dos factores: `sp` y `sex`.

1. Evaluar si existen diferencias multivariadas en las medidas morfológicas entre especies.
2. Revisar normalidad multivariada dentro de cada especie usando QQ-plots de Mahalanobis.
3. Repetir el MANOVA usando sexo como factor.
4. Correr ANOSIM para comparar las especies.
5. Revisar homogeneidad de dispersiones con `betadisper()`.
6. Probar una métrica alternativa y comparar el estadístico R.

Ejercicio 2: `mite`

Dataset: `mite` del paquete `vegan`. Contiene abundancias de ácaros en 70 sitios. `mite.xy` contiene coordenadas espaciales.

1. Calcular distancia geográfica y distancia biológica. Correr Mantel.
2. Visualizar la relación entre distancia geográfica y biológica.
3. Cargar `mite.env` y correr Mantel parcial: biología ~ ambiente | espacio.
4. Construir dendrogramas con `ward.D2`, `single` y `average`.
5. Comparar correlaciones cofenéticas usando distintas distancias.