

Diferenciación multivariada II: MRPP, PERMANOVA, PERMDISP y RRPP

Objetivo de esta segunda parte

En la primera parte vimos el mapa conceptual general de diferenciación multivariada.

En esta segunda parte trabajamos con el dataset **dune** y aplicamos los métodos de forma práctica:

- MRPP
- PERMANOVA
- PERMDISP
- NMDS como visualización
- RRPP
- comparaciones de a pares
- comparación final entre métodos

La pregunta general es:

¿Los grupos definidos por variables ambientales o de manejo ayudan a explicar diferencias en la composición de especies?

Paquetes y datos

```
library(vegan)
```

Cargando paquete requerido: permute

```
library(RRPP)
library(ggplot2)
library(RColorBrewer)
library(pairwiseAdonis)
```

Cargando paquete requerido: cluster

Si **pairwiseAdonis** no se instala de forma normal, se puede instalar desde GitHub. Esto solo hace falta una vez.

```
# install.packages("devtools")
# library(devtools)
# install_github("pmartinezarbizu/pairwiseAdonis/pairwiseAdonis")
```

Cargamos los datos:

```
data(dune)
data(dune.env)
```

dune es la matriz de especies:

- filas = sitios;
- columnas = especies;
- valores = abundancia o cobertura.

dune.env contiene información ambiental de esos mismos sitios.

```
head(dune)
```

	Achimill	Agrostol	Airaprae	Alopgeni	Anthodor	Bellpere	Bromhord	Chenalbu
1	1	0	0	0	0	0	0	0
2	3	0	0	2	0	3	4	0
3	0	4	0	7	0	2	0	0
4	0	8	0	2	0	2	3	0
5	2	0	0	0	4	2	2	0
6	2	0	0	0	3	0	0	0

	Cirsarve	Comapalu	Eleopal	Elymrepe	Empenigr	Hyporadi	Juncarti	Juncbufo
1	0	0	0	4	0	0	0	0
2	0	0	0	4	0	0	0	0
3	0	0	0	4	0	0	0	0
4	2	0	0	4	0	0	0	0
5	0	0	0	4	0	0	0	0
6	0	0	0	0	0	0	0	0

	Lolipere	Planlanc	Poaprat	Poatriv	Ranuflam	Rumeacet	Sagiproc	Salirepe
1	7	0	4	2	0	0	0	0
2	5	0	4	7	0	0	0	0
3	6	0	5	6	0	0	0	0
4	5	0	4	5	0	0	5	0
5	2	5	2	6	0	5	0	0
6	6	5	3	4	0	6	0	0

	Scorautu	Trifprat	Trifrepe	Vicilath	Bracruta	Callesc
1	0	0	0	0	0	0
2	5	0	5	0	0	0
3	2	0	2	0	2	0
4	2	0	1	0	2	0
5	3	2	2	0	2	0
6	3	5	5	0	6	0

```
head(dune.env)
```

	A1	Moisture	Management	Use	Manure
1	2.8	1	SF	Haypastu	4
2	3.5	1	BF	Haypastu	2
3	4.3	2	SF	Haypastu	4
4	4.2	2	SF	Haypastu	4
5	6.3	1	HF	Hayfield	2
6	4.3	1	HF	Haypastu	2

```
str(dune.env)
```

```
'data.frame':  20 obs. of  5 variables:
 $ A1      : num  2.8 3.5 4.3 4.2 6.3 4.3 2.8 4.2 3.7 3.3 ...
 $ Moisture : Ord.factor w/ 4 levels "1"<"2"<"4"<"5": 1 1 2 2 1 1 1 4 3 2 ...
 $ Management: Factor w/ 4 levels "BF","HF","NM",...: 4 1 4 4 2 2 2 2 1 ...
 $ Use      : Ord.factor w/ 3 levels "Hayfield"<"Haypastu"<...: 2 2 2 2 1 2 3 3 1 1
 ...
 $ Manure   : Ord.factor w/ 5 levels "0"<"1"<"2"<"3"<...: 5 3 5 5 3 3 4 4 2 2 ...
```

La variable **Moisture** viene como factor ordenado. Para algunos análisis la usamos también como número.

```
dune.env$Moisture_num <- as.numeric(as.character(dune.env$Moisture))

table(dune.env$Moisture)
```

```
1 2 4 5
7 4 2 7
```

```
dune.env$Moisture_num
```

```
[1] 1 1 2 2 1 1 1 5 4 2 1 4 5 5 5 5 2 1 5 5
```

Calculamos la matriz de disimilitud Bray-Curtis.

```
dist_bc <- vegdist(dune, method = "bray")

as.matrix(dist_bc)[1:5, 1:5]
```

	1	2	3	4	5
1	0.0000000	0.4666667	0.4482759	0.5238095	0.6393443
2	0.4666667	0.0000000	0.3414634	0.3563218	0.4117647
3	0.4482759	0.3414634	0.0000000	0.2705882	0.4698795
4	0.5238095	0.3563218	0.2705882	0.0000000	0.5000000
5	0.6393443	0.4117647	0.4698795	0.5000000	0.0000000

Bray-Curtis mide qué tan distinta es la composición de especies entre dos sitios.

- distancia baja = sitios parecidos;
- distancia alta = sitios distintos.

MRPP

MRPP usa una matriz de distancias.

La pregunta es:

¿Los sitios del mismo grupo se parecen más entre sí que si los grupos fueran armados al azar?

La hipótesis nula es:

Agrupar los sitios de esta manera no mejora nada respecto al azar.

Si el p-valor es bajo, interpretamos que los sitios dentro de cada grupo se parecen más entre sí de lo esperado por azar.

MRPP con Management

```
mrpp_management <- mrpp(  
  dist_bc,  
  dune.env$Management,  
  permutations = 999  
)  
  
mrpp_management
```

Call:

```
mrpp(dat = dist_bc, grouping = dune.env$Management, permutations = 999)
```

Dissimilarity index: bray

Weights for groups: n

Class means and counts:

	BF	HF	NM	SF
delta	0.416	0.4418	0.6882	0.5813
n	3	5	6	6

Chance corrected within-group agreement A: 0.1424

Based on observed delta 0.5537 and expected delta 0.6456

Significance of delta: 0.002

Permutation: free

Number of permutations: 999

Interpretación esperada:

- si el p-valor es bajo, **Management** agrupa sitios que se parecen internamente;
- el valor **A** sirve sobre todo para comparar factores, no para leerlo aislado como alto o bajo.

MRPP con Moisture

```
mrpp_moisture <- mrpp(  
  dist_bc,  
  dune.env$Moisture,
```

```

    permutations = 999
  )

mrpp_moisture

```

Call:

```
mrpp(dat = dist_bc, grouping = dune.env$Moisture, permutations = 999)
```

Dissimilarity index: bray

Weights for groups: n

Class means and counts:

	1	2	4	5
delta	0.4911	0.6049	0.3506	0.5775
n	7	4	2	7

Chance corrected within-group agreement A: 0.179

Based on observed delta 0.5301 and expected delta 0.6456

Significance of delta: 0.001

Permutation: free

Number of permutations: 999

Comparamos **A** entre factores:

```
mrpp_management$A
```

```
[1] 0.1423836
```

```
mrpp_moisture$A
```

```
[1] 0.1790282
```

En las salidas trabajadas, **Moisture** tuvo un **A** un poco mayor que **Management**. Por lo tanto, según MRPP, la humedad agrupó los sitios un poco mejor que el manejo.

PERMANOVA con un factor

PERMANOVA trabaja con una matriz de distancias, pero usa una lógica parecida al ANOVA.

Pregunta:

¿El factor ayuda a explicar las diferencias entre sitios?

En esta salida, el valor **R²** indica qué proporción de las diferencias entre sitios queda asociada al factor.

PERMANOVA con Management

```
perm_management <- adonis2(
  dist_bc ~ Management,
  data = dune.env,
  permutations = 999,
  by = "terms"
)

perm_management
```

Permutation test for adonis under reduced model

Terms added sequentially (first to last)

Permutation: free

Number of permutations: 999

```
adonis2(formula = dist_bc ~ Management, data = dune.env, permutations = 999, by =
"terms")
```

	Df	SumOfSqs	R2	F	Pr(>F)
Management	3	1.4686	0.34161	2.7672	0.003 **
Residual	16	2.8304	0.65839		
Total	19	4.2990	1.00000		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Lectura:

- **R2**: parte de las diferencias entre sitios asociada a **Management**;
- **Pr(>F)**: p-valor por permutaciones.

PERMANOVA con Moisture_num

```
perm_moisture <- adonis2(
  dist_bc ~ Moisture_num,
  data = dune.env,
  permutations = 999,
  by = "terms"
)

perm_moisture
```

Permutation test for adonis under reduced model

Terms added sequentially (first to last)

Permutation: free

Number of permutations: 999

```
adonis2(formula = dist_bc ~ Moisture_num, data = dune.env, permutations = 999, by =
"terms")
```

	Df	SumOfSqs	R2	F	Pr(>F)
Moisture_num	1	1.3916	0.32369	8.6152	0.001 ***
Residual	18	2.9075	0.67631		

```
Total      19    4.2990 1.00000
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En las salidas trabajadas, ambos factores dieron p-valores bajos y R2 parecidos:

```
Management -> R2 cercano a 0.34
```

```
Moisture    -> R2 cercano a 0.32
```

Entonces, en modelos separados, ambos factores ayudan a explicar diferencias en la composición de especies.

PERMANOVA con dos variables explicativas

Cuando usamos más de una variable explicativa, aparece un problema nuevo:

las variables pueden compartir parte de la explicación.

Por ejemplo, parte de las diferencias entre sitios puede estar relacionada tanto con **Management** como con **Moisture_num**.

by = "terms": importa el orden

Con **by = "terms"**, las variables entran en orden.

La primera variable toma primero la variación que puede explicar. La segunda explica lo que queda.

```
perm_complex <- adonis2(
  dist_bc ~ Management * Moisture_num,
  data = dune.env,
  permutations = 999,
  by = "terms"
)
```

```
perm_complex
```

Permutation test for adonis under reduced model

Terms added sequentially (first to last)

Permutation: free

Number of permutations: 999

```
adonis2(formula = dist_bc ~ Management * Moisture_num, data = dune.env, permutations =
999, by = "terms")
```

	Df	SumOfSqs	R2	F	Pr(>F)
Management	3	1.4686	0.34161	3.7483	0.001 ***
Moisture_num	1	0.9425	0.21924	7.2166	0.001 ***
Management:Moisture_num	3	0.3207	0.07460	0.8186	0.661
Residual	12	1.5672	0.36455		
Total	19	4.2990	1.00000		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ahora invertimos el orden:

```
perm_complex2 <- adonis2(
  dist_bc ~ Moisture_num * Management,
  data = dune.env,
  permutations = 999,
  by = "terms"
)

perm_complex2
```

Permutation test for adonis under reduced model

Terms added sequentially (first to last)

Permutation: free

Number of permutations: 999

```
adonis2(formula = dist_bc ~ Moisture_num * Management, data = dune.env, permutations =
999, by = "terms")
```

	Df	SumOfSqs	R2	F	Pr(>F)	
Moisture_num	1	1.3916	0.32369	10.6551	0.001	***
Management	3	1.0195	0.23715	2.6021	0.005	**
Moisture_num:Management	3	0.3207	0.07460	0.8186	0.631	
Residual	12	1.5672	0.36455			
Total	19	4.2990	1.00000			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

La comparación entre ambos modelos muestra si el orden cambia cuánto se le asigna a cada variable.

Si el R2 cambia al invertir el orden, eso indica que las variables comparten parte de la explicación.

by = "margin": cada variable considerando la otra

```
perm_complex_typeIII <- adonis2(
  dist_bc ~ Moisture_num + Management,
  data = dune.env,
  permutations = 999,
  by = "margin"
)

perm_complex_typeIII
```

Permutation test for adonis under reduced model

Marginal effects of terms

Permutation: free

Number of permutations: 999

```
adonis2(formula = dist_bc ~ Moisture_num + Management, data = dune.env, permutations =
```

```
999, by = "margin")
      Df SumOfSqs      R2      F Pr(>F)
Moisture_num  1    0.9425 0.21924 7.4883  0.001 ***
Management   3    1.0195 0.23715 2.7001  0.007 **
Residual     15    1.8879 0.43915
Total        19    4.2990 1.00000
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Con `by = "margin"`, la pregunta es:

- ¿`Moisture_num` aporta algo después de considerar `Management`?
- ¿`Management` aporta algo después de considerar `Moisture_num`?

En las salidas trabajadas, ambos factores siguieron siendo importantes. Esto indica que humedad y manejo aportan información propia, aunque comparten parte de la explicación.

Sumas de cuadrados: tipo I, II y III

Este tema aparece porque, cuando hay más de una variable explicativa, hay que decidir cómo repartir la parte de variación que puede estar compartida.

Tipo I = importa el orden.

Tipo II = cada término se evalúa considerando los otros términos principales.

Tipo III = cada término se evalúa considerando todo lo demás, incluidas interacciones.

SS tipo I

Evalúa los términos en orden.

La primera variable toma primero la variación que puede explicar, y la segunda explica lo que queda.

Sirve cuando el orden tiene sentido.

SS tipo II

Evalúa cada término teniendo en cuenta los otros términos principales, pero sin considerar interacciones.

Sirve para preguntar si cada variable aporta algo propio sin depender tanto del orden de escritura.

SS tipo III

Evalúa cada término teniendo en cuenta todos los demás términos del modelo, incluidas las interacciones.

Es útil en modelos complejos, pero puede ser difícil de interpretar si hay interacción.

En `adonis2`, `by = "margin"` se parece a una evaluación marginal para modelos simples, pero el script aclara que `adonis2` no maneja bien sumas tipo III con interacciones. Para modelos más complejos, especialmente con interacciones, se usa RRPP.

Ejemplo con A1 y Management

Este bloque repite la idea anterior usando A1 como variable ambiental previa.

La pregunta es:

Después de considerar A1, ¿Management todavía ayuda a explicar diferencias en composición?

```
perm_ancova <- adonis2(
  dist_bc ~ A1 + Management,
  data = dune.env,
  by = "terms"
)

perm_ancova
```

Permutation test for adonis under reduced model
 Terms added sequentially (first to last)
 Permutation: free
 Number of permutations: 999

```
adonis2(formula = dist_bc ~ A1 + Management, data = dune.env, by = "terms")
```

	Df	SumOfSqs	R2	F	Pr(>F)	
A1	1	0.7230	0.16817	4.5382	0.001	***
Management	3	1.1865	0.27600	2.4828	0.004	**
Residual	15	2.3895	0.55583			
Total	19	4.2990	1.00000			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Con `by = "terms"`, A1 entra primero y Management explica lo que queda.

```
perm_tipoIII <- adonis2(
  dist_bc ~ A1 + Management,
  data = dune.env,
  by = "margin"
)

perm_tipoIII
```

Permutation test for adonis under reduced model
 Marginal effects of terms
 Permutation: free
 Number of permutations: 999

```
adonis2(formula = dist_bc ~ A1 + Management, data = dune.env, by = "margin")
      Df SumOfSqs      R2      F Pr(>F)
A1      1   0.4409 0.10256 2.7676  0.028 *
Management 3   1.1865 0.27600 2.4828  0.005 **
Residual 15   2.3895 0.55583
Total    19   4.2990 1.00000
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Con `by = "margin"`, cada término se evalúa considerando el otro.

PERMDISP

PERMANOVA puede dar significativa por dos razones:

1. los grupos están ubicados en lugares distintos;
2. algún grupo está mucho más desparramado que otro.

PERMDISP revisa la segunda posibilidad.

Pregunta:

¿Los grupos tienen distinta dispersión interna?

Hipótesis nula:

Los grupos tienen la misma dispersión.

PERMDISP para Management

```
disp_management <- betadisper(
  dist_bc,
  dune.env$Management
)

disp_management
```

Homogeneity of multivariate dispersions

Call: `betadisper(d = dist_bc, group = dune.env$Management)`

No. of Positive Eigenvalues: 14

No. of Negative Eigenvalues: 5

Average distance to median:

BF	HF	NM	SF
0.2196	0.2791	0.4510	0.3640

Eigenvalues for PCoA axes:

(Showing 8 of 19 eigenvalues)

PCoA1	PCoA2	PCoA3	PCoA4	PCoA5	PCoA6	PCoA7	PCoA8
1.71627	1.02240	0.46146	0.38225	0.27913	0.23663	0.16912	0.09625

La parte más importante del resumen es **Average distance to median**. Esa distancia funciona como una medida de desparramo interno.

```
permutest(
  disp_management,
  permutations = 999
)
```

Permutation test for homogeneity of multivariate dispersions

Permutation: free

Number of permutations: 999

Response: Distances

	Df	Sum Sq	Mean Sq	F	N.Perm	Pr(>F)
Groups	3	0.13831	0.046104	1.9506	999	0.16
Residuals	16	0.37816	0.023635			

Si el p-valor no es bajo, no encontramos evidencia clara de diferencias de dispersión entre los grupos.

También se puede hacer un ANOVA clásico sobre esas distancias al centro del grupo:

```
anova(disp_management)
```

Analysis of Variance Table

Response: Distances


	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Groups	3	0.13831	0.046104	1.9506	0.1622
Residuals	16	0.37816	0.023635		

Como venimos trabajando con permutaciones, usamos **permutest()** como referencia principal.

Gráficos de dispersión


```
boxplot(
  disp_management,
  main = "Dispersión intragrupo por Management",
  ylab = "Distancia al centro del grupo",
  col = brewer.pal(4, "Set2"),
  las = 2
)
```

Dispersión intragrupo por Management



```
plot(  
  disp_management,  
  hull = FALSE,  
  ellipse = TRUE,  
  main = "PCoA - Dispersión por Management",  
  col = brewer.pal(4, "Set2")  
)
```

PCoA - Dispersión por Management



PERMDISP para Moisture

```
disp_moisture <- betadisper(
  dist_bc,
  dune.env$Moisture
)

disp_moisture
```

Homogeneity of multivariate dispersions

Call: betadisper(d = dist_bc, group = dune.env\$Moisture)

No. of Positive Eigenvalues: 14

No. of Negative Eigenvalues: 5

Average distance to median:

	1	2	4	5
Average distance to median:	0.3211	0.3605	0.1753	0.3706

Eigenvalues for PCoA axes:

(Showing 8 of 19 eigenvalues)

PCoA1	PCoA2	PCoA3	PCoA4	PCoA5	PCoA6	PCoA7	PCoA8
1.71627	1.02240	0.46146	0.38225	0.27913	0.23663	0.16912	0.09625

```
permutest(
  disp_moisture,
  permutations = 999
)
```

Permutation test for homogeneity of multivariate dispersions

Permutation: free

Number of permutations: 999

Response: Distances

	Df	Sum Sq	Mean Sq	F	N.Perm	Pr(>F)
Groups	3	0.06361	0.021205	0.8443	999	0.491
Residuals	16	0.40182	0.025114			

En las salidas trabajadas, PERMDISP no fue significativo ni para **Management** ni para **Moisture**. Esto permite interpretar con más tranquilidad los resultados de PERMANOVA: las diferencias no parecen deberse principalmente a distinto desparramo interno de los grupos.

NMDS como visualización

NMDS no es otro test. Es una visualización.

Sirve para dibujar los sitios en dos dimensiones tratando de respetar las distancias originales.

sitios parecidos -> quedan cerca

sitios distintos -> quedan lejos

```
nMDS <- metaMDS(
  dune,
  distance = "bray",
  k = 2,
  trymax = 100
)
```

```
Run 0 stress 0.1192678
Run 1 stress 0.1812933
Run 2 stress 0.1183186
... New best solution
... Procrustes: rmse 0.02027181 max resid 0.06496881
Run 3 stress 0.1889641
Run 4 stress 0.1183186
... New best solution
... Procrustes: rmse 2.276756e-05 max resid 7.292226e-05
... Similar to previous best
Run 5 stress 0.1192678
Run 6 stress 0.1192679
Run 7 stress 0.1183186
... New best solution
... Procrustes: rmse 6.34368e-06 max resid 2.060584e-05
... Similar to previous best
```

```
Run 8 stress 0.1183186
... Procrustes: rmse 1.878986e-05  max resid 5.354683e-05
... Similar to previous best
Run 9 stress 0.1809577
Run 10 stress 0.1183186
... Procrustes: rmse 1.665597e-05  max resid 5.350812e-05
... Similar to previous best
Run 11 stress 0.192224
Run 12 stress 0.2375255
Run 13 stress 0.1183186
... New best solution
... Procrustes: rmse 4.155377e-06  max resid 1.363527e-05
... Similar to previous best
Run 14 stress 0.1183186
... Procrustes: rmse 1.981569e-06  max resid 6.867498e-06
... Similar to previous best
Run 15 stress 0.1192678
Run 16 stress 0.1192678
Run 17 stress 0.1192678
Run 18 stress 0.1192678
Run 19 stress 0.1192678
Run 20 stress 0.1183186
... Procrustes: rmse 1.894142e-06  max resid 5.867212e-06
... Similar to previous best
*** Best solution repeated 3 times
```

```
nMDS$stress
```

```
[1] 0.1183186
```

El **stress** indica qué tan bien el gráfico en dos dimensiones representa las distancias originales.

```
stress < 0.10  -> muy bueno
stress < 0.20  -> aceptable
stress > 0.20  -> interpretar con cuidado
```

```
scores_sites <- as.data.frame(scores(nMDS, display = "sites"))
scores_sites$Management <- dune.env$Management
scores_sites$Moisture <- dune.env$Moisture
```


Gráfico por Management

```
ggplot(
  scores_sites,
  aes(
    x = NMDS1,
    y = NMDS2,
    color = Management,
    shape = Management
  )
) +
```

```
geom_point(size = 4, alpha = 0.85) +
stat_ellipse(
  aes(group = Management),
  level = 0.7,
  linetype = 2
) +
scale_color_brewer(palette = "Set2") +
theme_minimal(base_size = 13) +
labs(
  title = "NMDS por tipo de manejo",
  x = "NMDS1",
  y = "NMDS2"
)
```

Too few points to calculate an ellipse

Warning: Removed 1 row containing missing values or values outside the scale range (`geom\_path()`).



El NMDS ayuda a visualizar si los grupos aparecen separados, mezclados o con distinta dispersión. No reemplaza a PERMANOVA ni a PERMDISP.

RRPP

RRPP ajusta modelos multivariados usando permutaciones.

La diferencia principal con ANOSIM, MRPP y PERMANOVA es que RRPP no parte directamente de una matriz de distancias. En RRPP volvemos a trabajar con las variables respuesta dentro de un modelo.

En **dune**, las variables respuesta son las especies. El grupo o factor puede ser **Management**.

`respuesta multivariada ~ grupo o factor`

Por ejemplo:

`abundancias de especies ~ Management`

Una forma simple de pensarlo es:

`dato observado = parte explicada por el modelo + residuo`

El residuo es lo que el modelo no pudo explicar.

Modelo reducido y modelo completo

Para probar si un factor importa, RRPP usa dos modelos:

`modelo reducido = modelo sin el factor que queremos probar`

`modelo completo = modelo con el factor agregado`

Si queremos probar si **Management** aporta información:

`modelo reducido: composición ~ 1`

`modelo completo: composición ~ Management`

El modelo reducido no usa **Management**. Representa la idea de que el manejo no importa.

RRPP toma los valores esperados por ese modelo reducido, mezcla sus residuos y vuelve a armar datos simulados:

`datos simulados = valores esperados del modelo reducido + residuos mezclados`

Después ajusta el modelo completo sobre esos datos simulados y calcula el estadístico de prueba. Repite esto muchas veces para construir una referencia de azar.

Ejemplo de juguete

Supongamos una sola variable para ver la mecánica:

sitio	grupo	sp1
1	A	10
2	A	12
3	B	20
4	B	22

Queremos probar si **grupo** explica **sp1**.

El modelo completo sería:

```
sp1 ~ grupo
```

Pero para construir el azar, RRPP parte del modelo reducido:

```
sp1 ~ 1
```

Ese modelo reducido solo calcula una media general:

media general = $(10 + 12 + 20 + 22) / 4 = 16$

Residuos:

sitio	observado	esperado	residuo
1	10	16	-6
2	12	16	-4
3	20	16	4
4	22	16	6

RRPP mezcla esos residuos. Por ejemplo:

residuos mezclados: 4, -6, 6, -4

Rearma datos simulados:

sitio	grupo	esperado	residuo mezclado	simulado
1	A	16	4	20
2	A	16	-6	10
3	B	16	6	22
4	B	16	-4	12

Con esa tabla simulada vuelve a ajustar el modelo completo:

```
sp1_simulado ~ grupo
```

Si el resultado real es mucho más fuerte que la mayoría de los resultados simulados, el p-valor será bajo.

Transformación Hellinger

En **dune** tenemos abundancias de especies. Para RRPP usamos transformación Hellinger:

```
dune_hel <- as.matrix(
  decostand(dune, method = "hellinger")
)
```

Hellinger prepara datos de abundancia para analizarlos con una lógica euclidiana. No se usa siempre; acá tiene sentido porque estamos trabajando con abundancias de especies.

RRPP con **Management**

```
fit_management <- lm.rrpp(
  dune_hel ~ Management,
  data = dune.env
)

anova(fit_management)
```

Analysis of Variance, using Residual Randomization

Permutation procedure: Randomization of null model residuals

Number of permutations: 1000

Estimation method: Ordinary Least Squares

Sums of Squares and Cross-products: Type I

Effect sizes (Z) based on F distributions

	Df	SS	MS	Rsqr	F	Z	Pr(>F)
Management	3	3.1672	1.05572	0.29986	2.2842	2.7403	0.002 **
Residuals	16	7.3950	0.46219	0.70014			
Total	19	10.5621					

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Call: lm.rrpp(f1 = dune_hel ~ Management, data = dune.env)

Interpretación:

- **Rsqr**: proporción de la variación asociada a **Management**;
- **F**: comparación entre lo explicado por **Management** y lo que queda sin explicar;
- **Z**: tamaño de efecto estandarizado respecto de la distribución por permutación;
- **Pr(>F)**: p-valor.

Si el p-valor es bajo, interpretamos que la composición de especies se relaciona con el tipo de manejo.

Comparación con PERMANOVA

Después de Hellinger, podemos comparar RRPP con PERMANOVA usando distancia euclidiana.

```
adonis2(
  dune_hel ~ Management,
  data = dune.env,
  method = "euclidean"
)
```

Permutation test for adonis under reduced model

Permutation: free

Number of permutations: 999

```
adonis2(formula = dune_hel ~ Management, data = dune.env, method = "euclidean")
```

	Df	SumOfSqs	R2	F	Pr(>F)
Model	3	3.1672	0.29986	2.2842	0.002 **

```
Residual 16    7.3950 0.70014
```

```
Total    19   10.5621 1.00000
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En las salidas trabajadas, RRPP y PERMANOVA dieron resultados prácticamente iguales para este caso simple. Eso muestra que ambos métodos apuntan a la misma conclusión.

RRPP con SS tipo I y tipo II

SS tipo I

```
fit_ancova <- lm.rrpp(
  dune_hel ~ Moisture_num + Management,
  data = dune.env,
  SS.type = "I"
)

anova(fit_ancova)
```

Analysis of Variance, using Residual Randomization

Permutation procedure: Randomization of null model residuals

Number of permutations: 1000

Estimation method: Ordinary Least Squares

Sums of Squares and Cross-products: Type I

Effect sizes (Z) based on F distributions

	Df	SS	MS	Rsqr	F	Z	Pr(>F)
Moisture_num	1	2.6702	2.67016	0.25281	7.2355	4.0503	0.001 ***
Management	3	2.3564	0.78548	0.22310	2.1285	2.9148	0.003 **
Residuals	15	5.5355	0.36904	0.52409			
Total	19	10.5621					

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Call: lm.rrpp(f1 = dune_hel ~ Moisture_num + Management, SS.type = "I",
  data = dune.env)
```

Con tipo I, importa el orden:

```
primero Moisture_num
luego Management
```

La pregunta sobre **Management** es:

Después de considerar la humedad, ¿el manejo todavía aporta información?

SS tipo II

```
fit_tipo2 <- lm.rrpp(
  dune_hel ~ Management + Moisture_num,
  data = dune.env,
  SS.type = "II"
)

anova(fit_tipo2)
```

Analysis of Variance, using Residual Randomization

Permutation procedure: Randomization of null model residuals

Number of permutations: 1000

Estimation method: Ordinary Least Squares

Sums of Squares and Cross-products: Type II

Effect sizes (Z) based on F distributions

	Df	SS	MS	Rsqr	F	Z	Pr(>F)
Management	3	2.3564	0.78548	0.22310	2.1285	2.9148	0.003 **
Moisture_num	1	1.8594	1.85944	0.17605	5.0387	3.5098	0.001 ***
Residuals	15	5.5355	0.36904	0.52409			
Total	19	10.5621					

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
Call: lm.rrpp(f1 = dune_hel ~ Management + Moisture_num, SS.type = "II",
  data = dune.env)
```

Con tipo II, cada término se evalúa considerando los otros términos principales.

La pregunta es:

- ¿Management aporta algo considerando Moisture_num?
- ¿Moisture_num aporta algo considerando Management?

En las salidas trabajadas, ambos factores siguieron siendo importantes. Esto indica que humedad y manejo aportan información propia.

Coeficientes del modelo RRPP

Esta parte no es el test principal. El test principal es `anova(fit_management)`.

Los coeficientes sirven para explorar qué variables respuesta cambian más entre grupos.

En `dune`, las variables respuesta son especies. Entonces podemos mirar qué especies diferencian más a un grupo.

```
coefs <- coef(fit_management)
coefs
```

	Achimill	Agrostol	Airaprae	Alopgeni	Anthodor	Bellpere
(Intercept)	0.1907528	0.0000000	0.0000000	0.07273930	0.10166571	0.16097560

	Bromhord	Chenalbu	Cirsarve	Comapalu	Eleopal	Elymrepe
ManagementHF	-0.0620735	0.1166978	0.0000000	0.05142363	0.05405507	-0.11784249
ManagementNM	-0.1298947	0.2044811	0.1127056	-0.07273930	0.04426902	-0.11561467
ManagementSF	-0.1514691	0.3209570	0.0000000	0.23470150	-0.10166571	-0.08857138
(Intercept)	0.2045346	0.00000000	0.00000000	0.00000000	0.00000000	0.10286890

	Empenigr	Hyporadi	Juncarti	Juncbufo	Lolipere
ManagementHF	-0.1166801	0.00000000	0.00000000	0.00000000	0.06324555
ManagementNM	-0.2045346	0.00000000	0.00000000	0.09725984	0.20561855
ManagementSF	-0.1615015	0.02901294	0.03513642	0.00000000	0.08206099
(Intercept)	0.00000000	0.08333333	0.00000000	0.00000000	0.39542788

	Planlanc	Poaprat	Poatriv	Ranuflam	Rumeacet
ManagementHF	0.01335267	-0.04104019	0.09765807	0.04472136	0.23732595
ManagementNM	-0.07369355	-0.22379704	-0.23774848	0.15712828	0.00000000
ManagementSF	-0.19010716	-0.09417186	0.12232530	0.08206099	0.03984095
(Intercept)	0.19010716	0.32238574	0.23774848	0.00000000	0.00000000

	Sagiproc	Salirepe	Scorautu	Trifprat	Trifrepe
ManagementHF	0.005031604	0.00000000	-0.07880244	0.1524042	-0.09100976
ManagementNM	-0.031485749	0.1743381	0.01067916	0.00000000	-0.13580753
ManagementSF	0.069596336	0.00000000	-0.18154192	0.00000000	-0.18964906
(Intercept)	0.083333333	0.00000000	0.33481759	0.00000000	0.34158756

	Vicilath	Bracruta	Callcusp
ManagementHF	-0.1341662	0.057190439	0.00000000
ManagementNM	-0.1020912	0.070048598	0.11988897
ManagementSF	-0.1341662	-0.002965925	0.05025189
(Intercept)	0.1341662	0.189739646	0.00000000

Como **Management** es un factor, R toma un nivel como referencia.

El intercepto representa el grupo de referencia.

Los coeficientes **ManagementHF**, **ManagementNM**, **ManagementSF**, etc., indican cuánto cambia cada grupo respecto al grupo de referencia, especie por especie.

Especies que más diferencian a **NM**


```
coef_NM <- coefs["ManagementNM", ]

top10 <- sort(
  abs(coef_NM),
  decreasing = TRUE
)[1:10]

barplot(
  coef_NM[names(top10)],
  horiz = TRUE,
  las = 1,
  xlab = "Coeficiente",
  main = "Especies que más diferencian al grupo NM"
)
```

```
abline(v = 0, lty = 1)
```

Especies que más diferencian al grupo NM



Lectura:

- barras positivas = especies con mayor valor en NM que en el grupo de referencia;
- barras negativas = especies con menor valor en NM que en el grupo de referencia.

Comparaciones de a pares

Cuando el análisis global da significativo, sabemos que hay diferencias entre grupos, pero no sabemos entre cuáles.

Las comparaciones de a pares responden:

¿Qué grupos difieren entre sí?

Pairwise con PERMANOVA

```
pares_adonis <- pairwise.adonis2(
  dist_bc ~ Management,
  data = dune.env
)
```

pares_adonis

```
$parent_call
[1] "dist_bc ~ Management , strata = Null , permutations 999"
```

\$SF_vs_BF

	Df	SumOfSqs	R2	F	Pr(>F)
Model	1	0.40166	0.26431	2.5149	0.048 *
Residual	7	1.11800	0.73569		
Total	8	1.51966	1.00000		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

\$SF_vs_HF

	Df	SumOfSqs	R2	F	Pr(>F)
Model	1	0.28288	0.17108	1.8575	0.114
Residual	9	1.37063	0.82892		
Total	10	1.65351	1.00000		

\$SF_vs_NM

	Df	SumOfSqs	R2	F	Pr(>F)
Model	1	0.75757	0.25516	3.4257	0.007 **
Residual	10	2.21144	0.74484		
Total	11	2.96902	1.00000		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

\$BF_vs_HF

	Df	SumOfSqs	R2	F	Pr(>F)
Model	1	0.16171	0.20714	1.5675	0.194
Residual	6	0.61899	0.79286		
Total	7	0.78070	1.00000		

\$BF_vs_NM

	Df	SumOfSqs	R2	F	Pr(>F)
Model	1	0.56625	0.27948	2.7152	0.024 *
Residual	7	1.45980	0.72052		
Total	8	2.02605	1.00000		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

\$HF_vs_NM

	Df	SumOfSqs	R2	F	Pr(>F)
Model	1	0.65131	0.27554	3.4231	0.028 *
Residual	9	1.71243	0.72446		
Total	10	2.36374	1.00000		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
attr("class")
```

```
[1] "pwadstrata" "list"
```

Corrección por comparaciones múltiples

Como hacemos muchas comparaciones, aumenta la posibilidad de encontrar diferencias por azar. Por eso corregimos los p-valores.

```
p_vals <- sapply(
  pares_adonis[-1],
  function(x) x$`Pr(>F)`[1]
)

tabla_pares <- data.frame(
  p_original = round(p_vals, 4),
  p_bonferroni = round(p.adjust(p_vals, "bonferroni"), 4),
  p_holm = round(p.adjust(p_vals, "holm"), 4),
  p_BH = round(p.adjust(p_vals, "BH"), 4)
)

tabla_pares
```

	p_original	p_bonferroni	p_holm	p_BH
SF_vs_BF	0.048	0.288	0.144	0.0720
SF_vs_HF	0.114	0.684	0.228	0.1368
SF_vs_NM	0.007	0.042	0.042	0.0420
BF_vs_HF	0.194	1.000	0.228	0.1940
BF_vs_NM	0.024	0.144	0.120	0.0560
HF_vs_NM	0.028	0.168	0.120	0.0560

Lectura esperada:

- si los p-valores corregidos siguen bajos, la comparación es más sólida;
- si solo los p-valores originales son bajos, la conclusión debe ser prudente.

Pairwise con RRPP

```
fit_reducido <- lm.rrpp(
  dune_hel ~ 1,
  data = dune.env
)

pares_rrpp <- pairwise(
  fit = fit_management,
  fit.null = fit_reducido,
  groups = dune.env$Management
)

summary(pares_rrpp)
```

Pairwise comparisons

Groups: BF HF NM SF

RRPP: 1000 permutations

LS means:

Vectors hidden (use `show.vectors = TRUE` to view)

Pairwise distances between means, plus statistics

	d	UCL (95%)	Z	Pr > d
BF:HF	0.4772439	0.7448397	-0.4422805	0.666
BF:NM	0.7438183	0.7197926	1.8234433	0.035
BF:SF	0.6730646	0.7159854	1.3830865	0.089
HF:NM	0.7021404	0.6181481	2.2632438	0.008
HF:SF	0.5147286	0.6198228	0.8464591	0.200
NM:SF	0.7279207	0.6001468	2.4825507	0.006

Este resumen compara diferencias entre medias multivariadas de los grupos.

Pairwise RRPP de dispersión

```
summary(
  pares_rrpp,
  test.type = "var"
)
```

Pairwise comparisons

Groups: BF HF NM SF

RRPP: 1000 permutations

Observed variances by group

	BF	HF	NM	SF
	0.2200206	0.2703407	0.5064440	0.3907578

Pairwise distances between variances, plus statistics

	d	UCL (95%)	Z	Pr > d
BF:HF	0.05032013	0.2572930	-0.6275096	0.721
BF:NM	0.28642347	0.2443617	1.9441913	0.015
BF:SF	0.17073723	0.2508085	0.9352249	0.203
HF:NM	0.23610334	0.2147762	1.7851724	0.022
HF:SF	0.12041711	0.2160314	0.5889948	0.297
NM:SF	0.11568623	0.2047301	0.6542039	0.284

Este análisis no compara medias multivariadas. Compara dispersión interna entre pares de grupos.

Sirve como complemento, parecido a PERMDISP.

Comparación final entre métodos

Esta tabla sirve como cierre.

No todos los estadísticos están en la misma escala, por lo que no se deben comparar directamente como si fueran iguales.

La tabla sirve para ver si los métodos coinciden en la conclusión general.

```
anosim_management <- anosim(
  dist_bc,
  dune.env$Management,
  permutations = 999
)

tabla_metodos <- data.frame(
  metodo = c(
    "ANOSIM - R",
    "MRPP - A",
    "PERMANOVA - R2",
    "RRPP - Z"
  ),
  efecto = c(
    anosim_management$statistic,
    mrpp_management$A,
    perm_management$R2[1],
    anova(fit_management)$table$Z[1]
  ),
  p_valor = c(
    anosim_management$signif,
    mrpp_management$Pvalue,
    perm_management$`Pr(>F)`[1],
    anova(fit_management)$table$`Pr(>F)`[1]
  )
)

tabla_metodos
```

	metodo	efecto	p_valor
1	ANOSIM - R	0.2578706	0.009
2	MRPP - A	0.1423836	0.002
3	PERMANOVA - R2	0.3416107	0.003
4	RRPP - Z	2.7402791	0.002

También podemos mirar el R2 de RRPP:

```
anova(fit_management)$table$Rsq[1]
```

```
[1] 0.2998597
```

Lectura:

- ANOSIM usa **R**;

- MRPP usa **A**;
- PERMANOVA usa **R²**;
- RRPP usa **Z** y también tiene **Rsq**.

La tabla no sirve para decir qué método tiene “más efecto”. Sirve para ver si todos apuntan a la misma conclusión.

Ejercicio integrador: pingüinos

Este ejercicio queda para resolver después de entender la lógica con **dune**.

```
data(penguins)
?penguins

peng <- na.omit(penguins)

table(peng$species, peng$island)
```

Consignas:

1. Probar la existencia de diferencias entre especies.
2. Probar la existencia de diferencias entre islas. Pensar qué puede estar generando una confusión de efectos.
3. Ajustar un modelo con islas y especie. Comparar SS tipo I y tipo III.
4. Ajustar un modelo con sexo, especie e interacción.
5. Realizar comparaciones de a pares si son necesarias.
6. Proponer una visualización para los resultados.